FFT-based Dynamic Token Mixer for Vision

Yuki Tatsunami[1 2] **Masato Taki**[1]

[1]Rikkyo University
[2]AnyTech Co., Ltd.
y.tatsunami@rikkyo.ac.jp, taki_m@rikkyo.ac.jp

AAAI2024 的一篇文章。在 token mixer 部分使用了一个自己提出的频域模块。

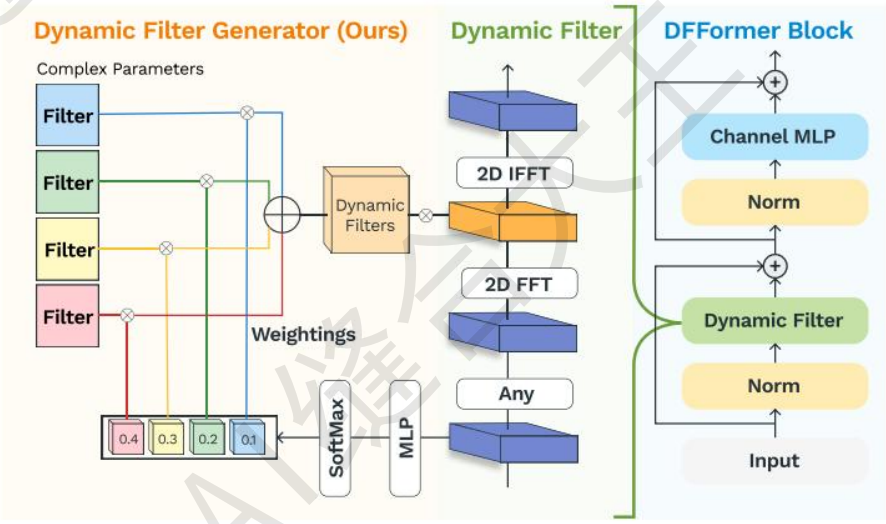

Figure 3: **Dynamic Filter** is our proposed component where "Any" modules are allowed continuous real maps. **DFFormer Block** is a MetaFormer block equipped with the dynamic filter.

采用多头自注意力（MHSA）的模型在计算机视觉领域取得了显著的性能。然而，它们的计算复杂度与输入特征图中像素数量的二次方成正比，导致处理速度较慢，尤其是在处理高分辨率图像时。

为了解决这一问题，论文提出了新型 token mixer 作为 MHSA 的替

代方案：基于快速傅里叶变换（FFT）的 token mixer 涉及与 MHSA 类似的全局操作，但计算复杂度更低。然而，尽管具有这些吸引人的特性，但基于 FFT 的 token mixer 在与快速发展的 MetaFormer 架构的兼容性方面尚未得到仔细研究。在此，论文提出了一种新颖的 token mixer，称为动态滤波器，以及新颖的图像识别模型，以弥补上述差距。图像分类和下游任务的结果、分析和可视化表明，论文提出的模型是有效的。特别是，它们在处理高分辨率图像识别时的吞吐量和内存效率非常显著。

在 token mixer 部分，我们可以使用各种模块，因为就像 MetaFormer 里面说的，视觉 Transformer 的成功，不只是注意力机制的使用，Transformer 的整体架构，对模型的效果提升有着更关键的作用。

改进多头自注意力（MHSA）的模型，都会提到多头自注意力的缺点，就是二次方计算复杂度，对这方面的改进，有窗口注意力机制、线性注意力机制、频域模块和最近使用较多的 Mamba 等等。

所以，我们未来在 token mixer 部分，可以使用频域的模块，我们从频域的角度提取出丰富的频域信息，和通过 attention、cnn 等提取的特征相互补充，提取不同尺度的信息。

AI缝合大王