ai缝合交流Q群：994264161

AFPN: Asymptotic Feature Pyramid Network for Object Detection

Guoyu Yang[1], Jie Lei[1*], Zhikuan Zhu[1], Siyu Cheng[1], Zunlei Feng[2], Ronghua Liang[1]
[1]*College of Computer Science, Zhejiang University of Technology, Hangzhou, P.R. China*
[2]*College of of Computer Science, Zhejiang University, Hangzhou, P.R. China*
{gyyang, *jasonlei, zzkuan, sycheng, rhliang}@zjut.edu.cn
zunleifeng@zju.edu.cn

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

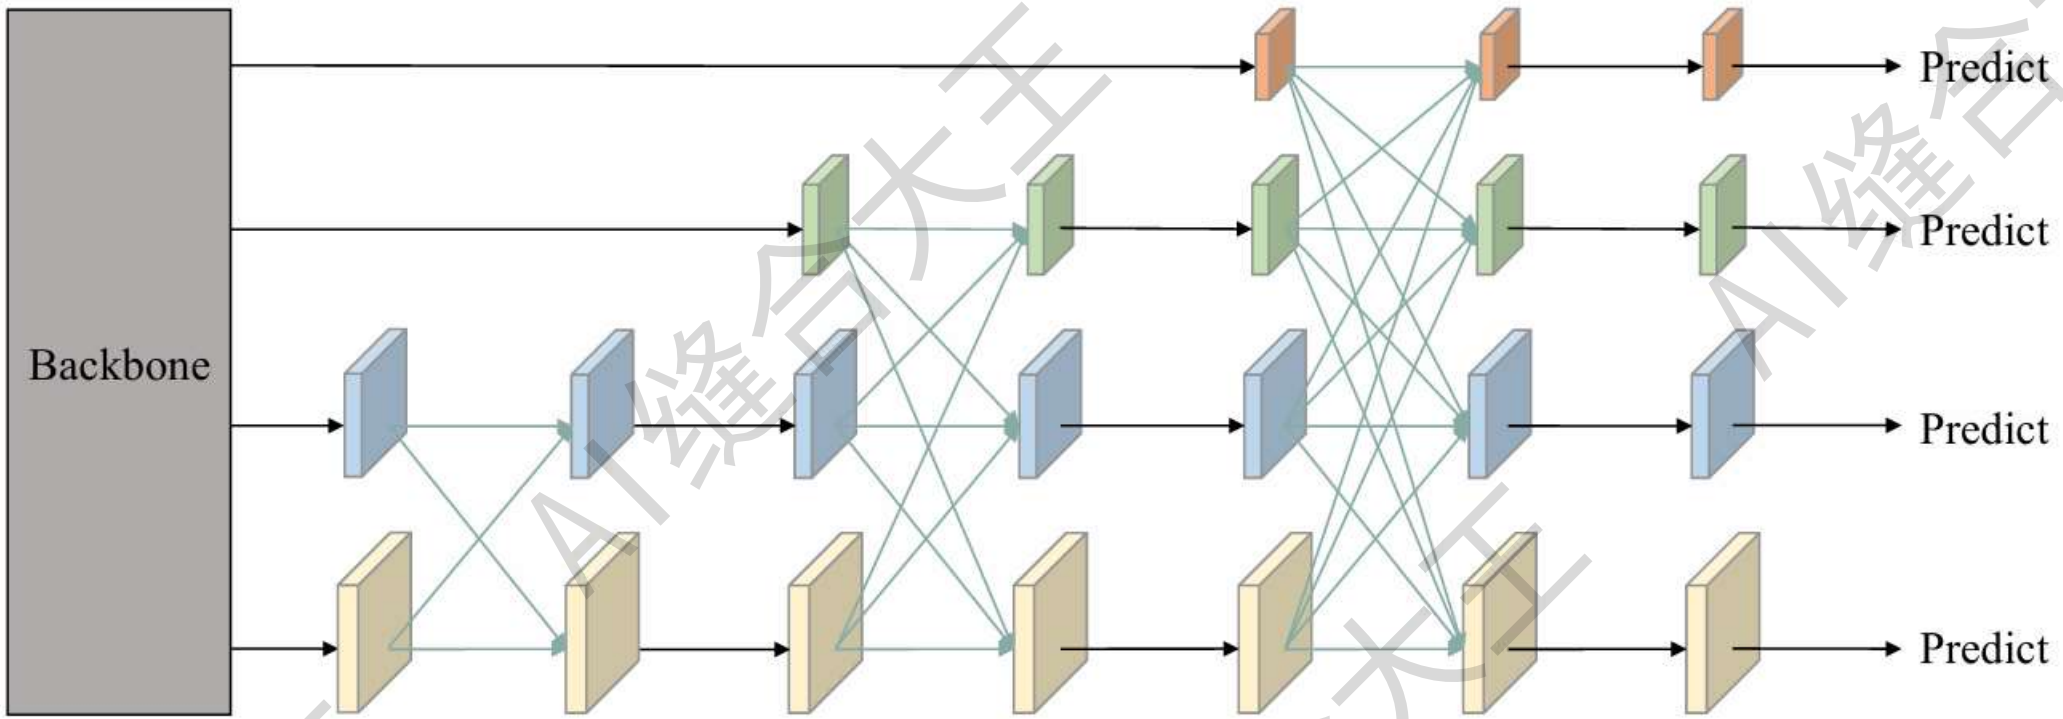

整体结构

AFPN模型通过逐步融合不同尺度的特征，首先从相邻的低层特征开始，逐步加入高层特征，形成渐进式特征融合结构。模型同时采用自适应空间融合模块（ASF），为每个尺度特征分配权重，以解决不同尺度间的矛盾信息，从而实现更高效、精确的多尺度特征融合，用于目标检测任务。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

TABLE V

ABLATION STUDIES ON THE FUSION OPERATION.

Fusion Operation	AP	AP_{50}	AP_{75}	AP_S	AP_M	AP_L
concat	38.8	57.3	42.0	**19.6**	42.7	54.6
sum	38.5	57.2	41.6	18.8	42.6	54.1
adaptive spatial fusion	**39.0**	**57.6**	**42.1**	19.4	**43.0**	**55.0**

实验对比了三种融合方法：元素级的拼接（concat）、元素级的求和（sum）和自适应空间融合（adaptive spatial fusion）。结果显示，自适应空间融合方法在平均精度（AP）、AP50、AP75、APM和APL指标上均表现最佳。这表明自适应空间融合在处理多层特征信息冲突时效果更好，可以提升模型的检测精度

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

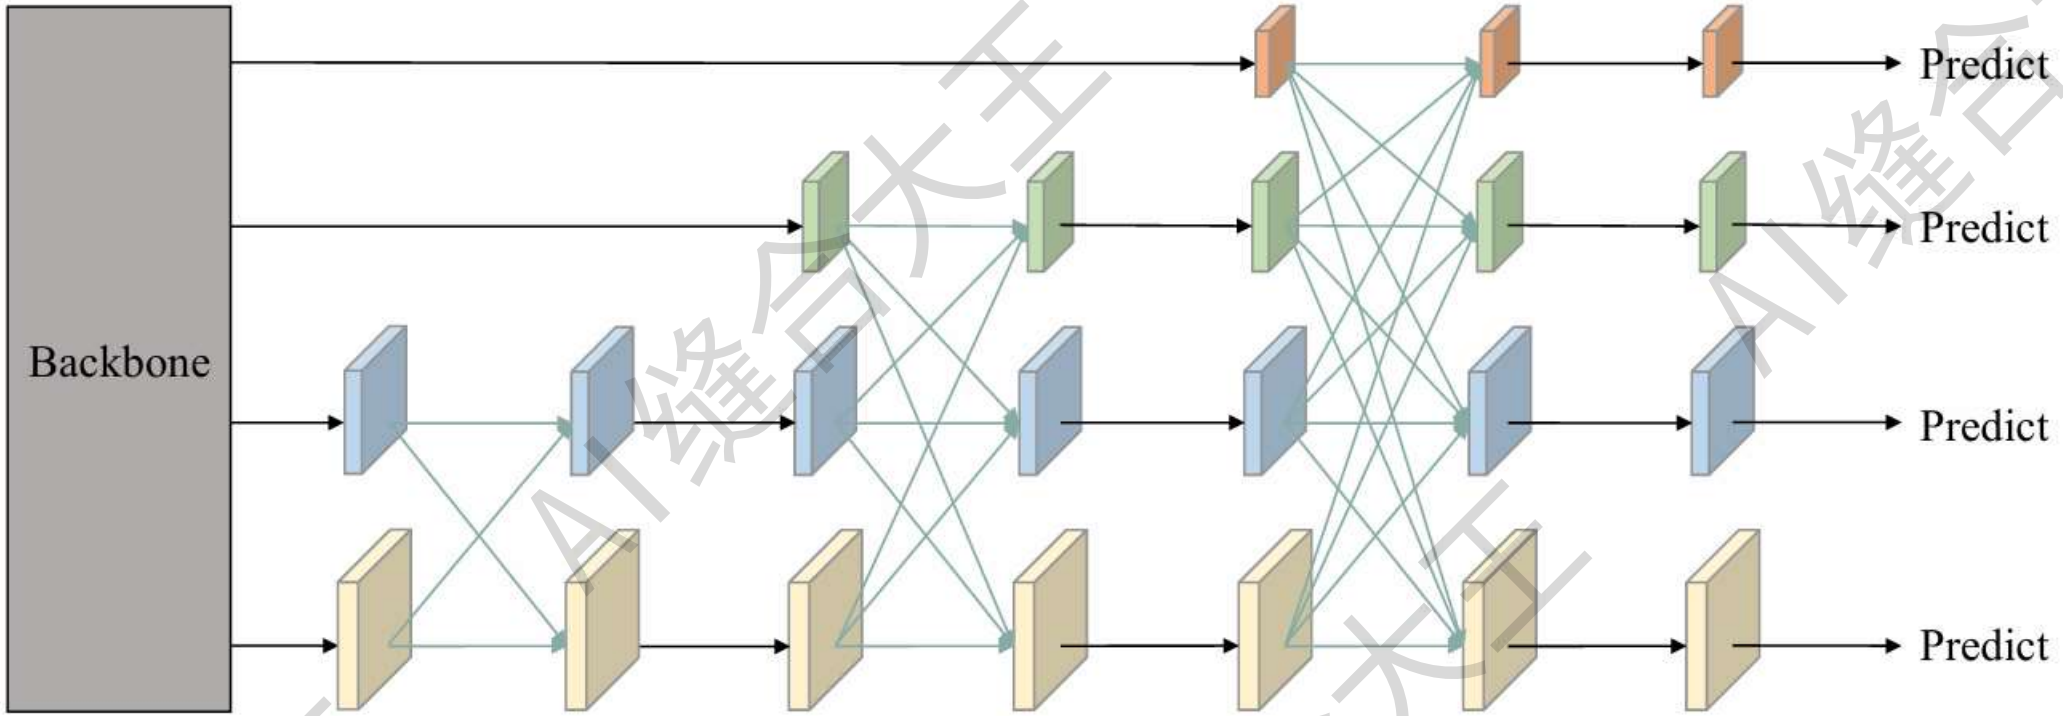

AFPN模块适用于：

目标检测、实时性要求高的任务、计算资源有限的场景

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

EMCAD: Efficient Multi-scale Convolutional Attention Decoding for Medical Image Segmentation

Md Mostafijur Rahman, Mustafa Munir, and Radu Marculescu
The University of Texas at Austin
Austin, Texas, USA
mostafijur.rahman, mmunir, radum@utexas.edu

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

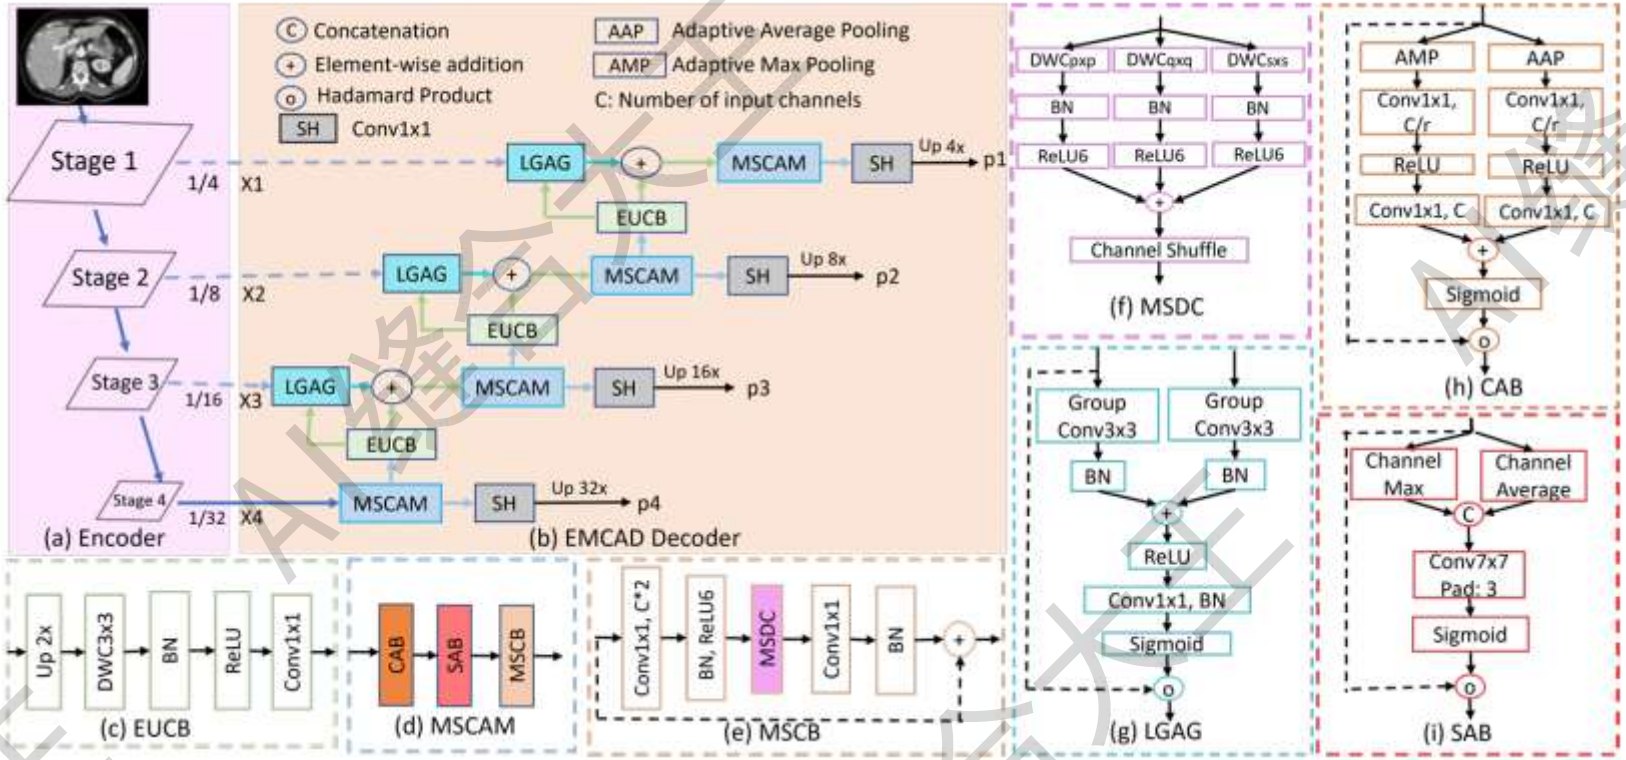

整体结构

该模型整体采用U型架构，由预训练的层次化编码器和高效的EMCAD解码器构成。编码器（如PVTv2-B0/B2）负责提取多尺度、多分辨率的特征图，而解码器则利用多尺度卷积注意力模块（MSCAM）、大核分组注意力门（LGAG）、高效上采样块（EUCB）以及分割头（SH），通过逐层级联的方式对编码器的特征进行融合和细化，从而在降低参数和计算量的同时实现精细的医学图像分割。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Components			#FLOPs(G)		#Params	Avg
Cascaded	LGAG	MSCAM	224	256	(M)	DICE
No	No	No	0	0	0	80.10±0.2
Yes	No	No	0.100	0.131	0.224	81.08±0.2
Yes	Yes	No	0.108	0.141	0.235	81.92±0.2
Yes	No	Yes	0.373	0.487	1.898	82.86±0.3
Yes	Yes	Yes	0.381	0.498	1.91	**83.63±0.3**

展示了在Synapse多器官数据集上，逐步添加级联结构、LGAG（大核分组注意力门）和MSCAM（多尺度卷积注意力模块）对性能（DICE分数）、参数量和FLOPs的影响。结果表明，采用级联结构能提升性能，而同时引入LGAG和MSCAM则能进一步改善分割效果，最佳组合可实现DICE分数最高，同时只带来较小的计算和参数开销。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Conv. kernels	[1]	[3]	[5]	[1, 3]	[3, 3]	[1, 3, 5]	[3, 3, 3]	[3, 5, 7]	[1, 3, 5, 7]	[1, 3, 5, 7, 9]
Synapse	82.43	82.79	82.74	82.98	82.81	**83.63**	82.92	83.11	83.57	83.34
ClinicDB	94.81	94.90	94.98	95.13	95.06	**95.21**	95.15	95.03	95.18	95.07

分析了MSCAM中采用不同多尺度卷积核组合（例如单独使用1×1、3×3、5×5或它们的组合）对模型性能的影响。结果显示，从单一卷积核到组合使用[1, 3, 5]卷积核能不断提升性能，但如果加入过大的卷积核（如7×7、9×9），反而会导致性能下降，表明多尺度设计需适度平衡。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Encoders	Decoders	#FLOPs(G)	#Params(M)	DICE (%)
PVTv2-B0	CASCADE	0.439	2.32	80.54
PVTv2-B0	EMCAD (**Ours**)	**0.110**	**0.507**	**81.97**
PVTv2-B2	CASCADE	1.93	9.27	82.78
PVTv2-B2	EMCAD (**Ours**)	**0.381**	**1.91**	**83.63**

将提出的EMCAD解码器与基线解码器（CASCADE）进行对比，结果显示EMCAD在大幅降低FLOPs和参数量（分别减少约80%和79%）的同时，还能获得更高的DICE分数，从而证明了其在计算效率和分割精度上的优势。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

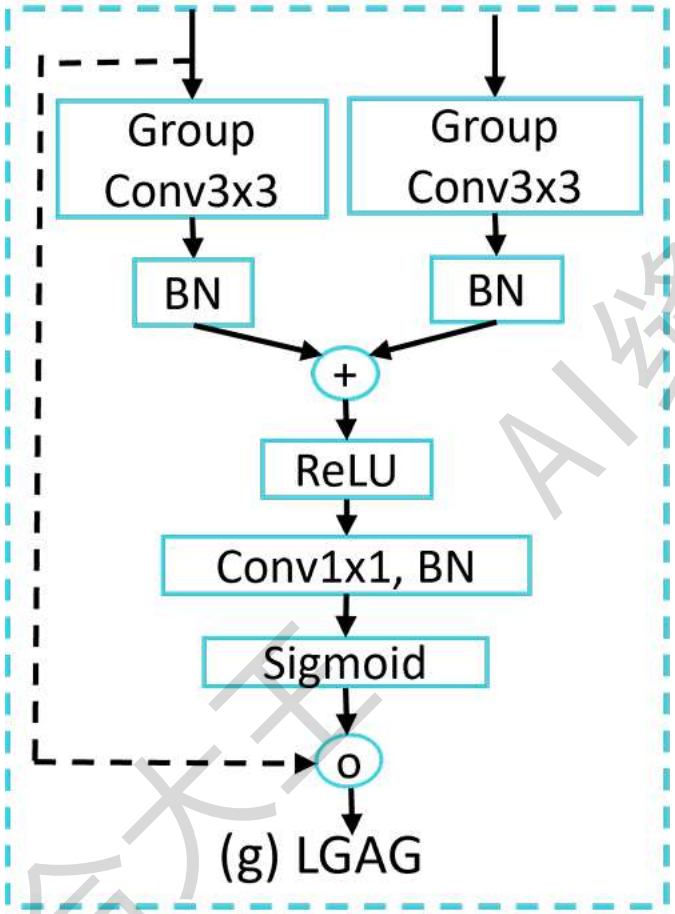

LGAG模块适用于：

1、利用大核（例如3× 3）分组卷积捕获更大局部上下文信息

2、通过注意力门机制对特征进行加权，有效突出关键区域并抑制无关信息

3、提高特征融合效果，从而改善分割或检测任务中的细节识别和整体精度

4、降低计算量和参数量，使网络更加高效且易于集成到现有系统中

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

MogaNet: Multi-order Gated Aggregation Network

Siyuan Li[1,2*] **Zedong Wang**[1*] **Zicheng Liu**[1,2] **Cheng Tan**[1,2] **Haitao Lin**[1,2] **Di Wu**[1,2]
Zhiyuan Chen[1,2] **Jiangbin Zheng**[1,2] **Stan Z. Li**[1†]
[1]AI Lab, Research Center for Industries of the Future, Westlake University, Hangzhou, China
[2]Zhejiang University, College of Computer Science and Technology, Hangzhou, China

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

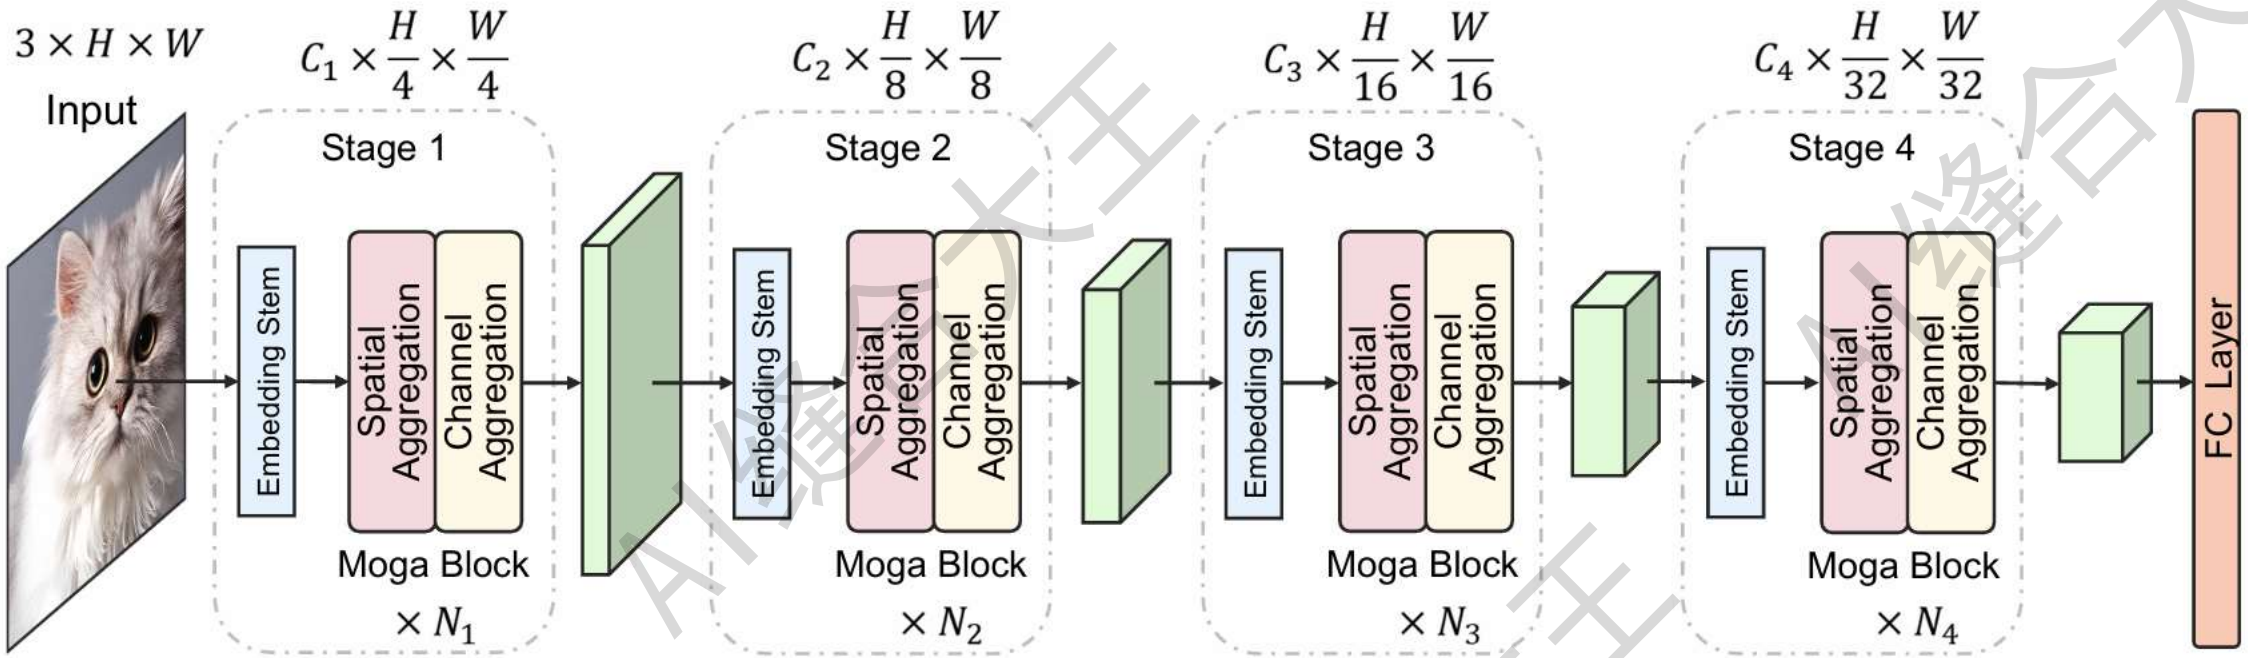

整体结构

MogaNet 采用 四阶段层次化 ConvNet 结构，核心计算单元是 Moga Block，其中包含 空间聚合（SA）模块 和 通道聚合（CA）模块。SA 模块利用 多阶深度卷积（DWConv） 提取局部和全局特征，并通过 门控聚合机制 进行自适应融合，而 CA 模块通过 通道重新分配 降低信息冗余，提高计算效率。整个网络通过 Embedding Stem → 4个阶段（多个 Moga Blocks）→ 全局平均池化（GAP）→ 全连接层（FC）进行特征提取与分类，在计算效率和准确率上优于 Swin Transformer 和 ConvNeXt，可广泛应用于图像分类、目标检测、语义分割等视觉任务。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Modules		Top-1 Acc (%)	Params. (M)	FLOPs (G)
Baseline		76.6	4.75	1.01
SMixer	+Gating branch	77.3	5.09	1.07
	+$DW_{7\times7}$	77.5	5.14	1.09
	+Multi-order DW$(\cdot)$	78.0	5.17	1.10
	+FD$(\cdot)$	78.3	5.18	1.10
CMixer	+SE module	78.6	5.29	1.14
	+CA$(\cdot)$	**79.0**	5.20	1.10

内容：对 MogaNet 设计的不同模块（如 Moga Block、FD 模块、多阶 DWConv 以及 CA 模块）进行消融，观察每个模块对 ImageNet-1K 分类任务 的影响。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Modules	Top-1 Acc (%)
ConvNeXt-T	82.1
Baseline	82.2
Moga Block	**83.4**
−FD(·)	83.2
−Multi-DW(·)	83.1
−Moga(·)	82.7
−CA(·)	82.9

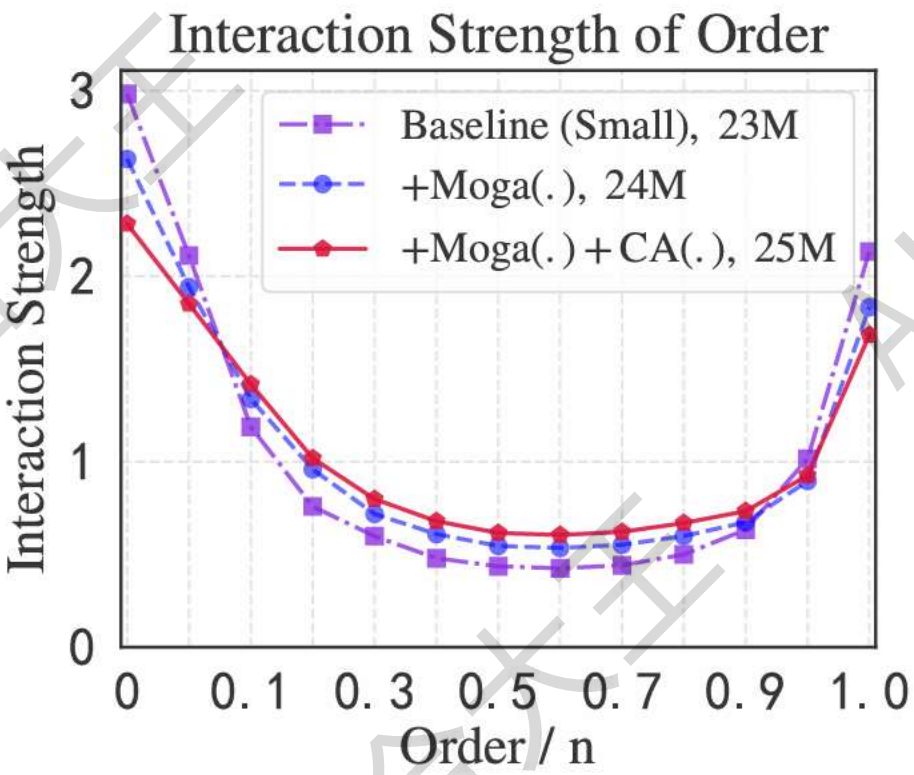

内容：绘制不同消融版本 MogaNet 在不同阶（low-order, middle-order, high-order）特征交互强度上的变化，并对比它们的分类准确率。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

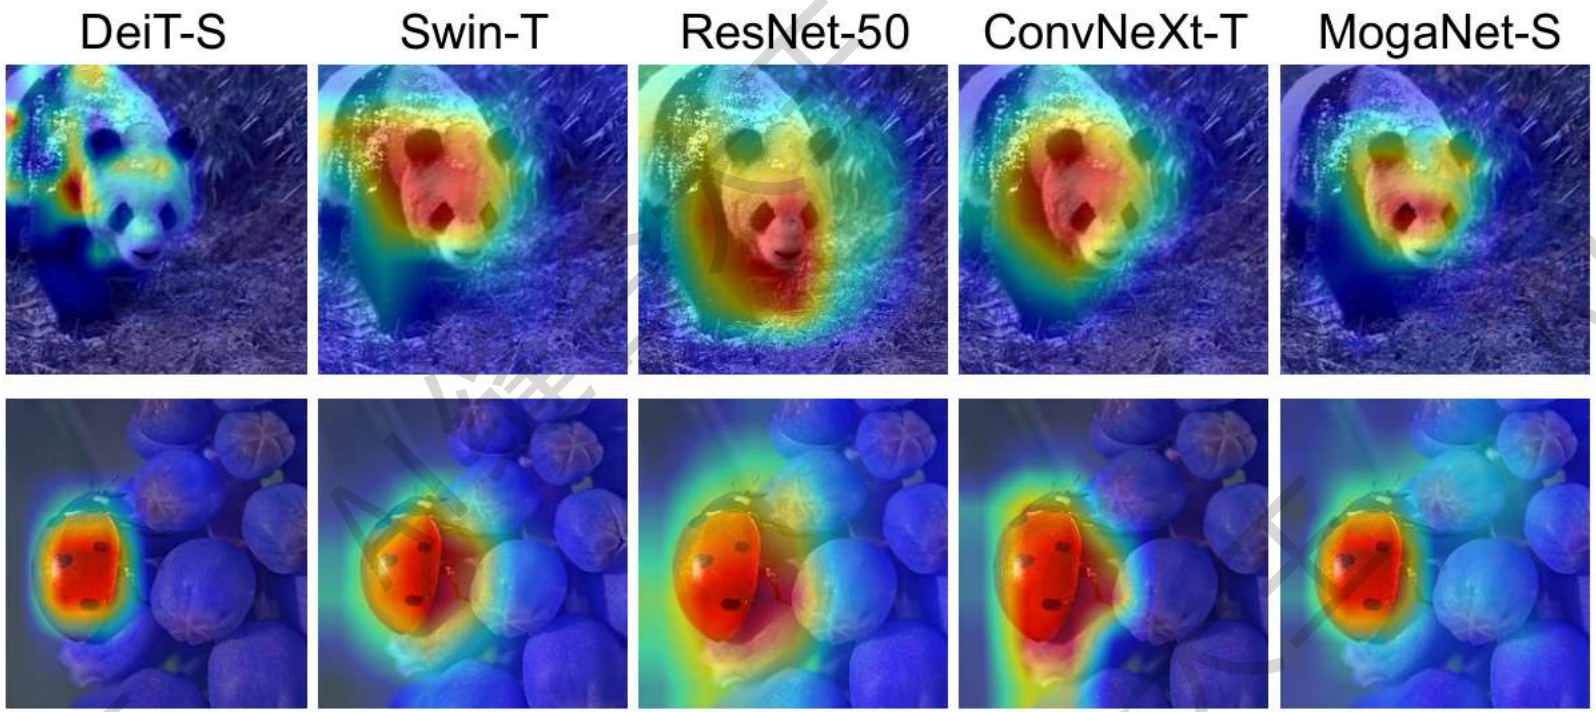

内容：与 Swin Transformer、ConvNeXt 和 ResNet 进行 Grad-CAM 结果对比，分析不同架构对图像分类时的关注区域。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

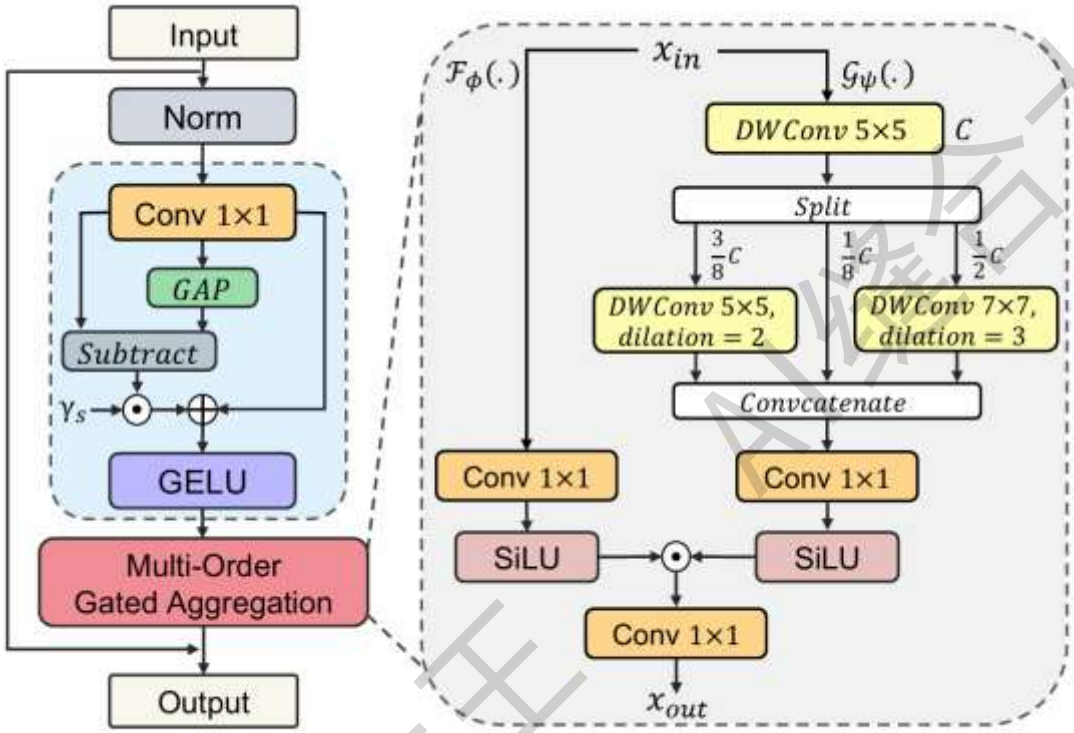

(a) Moga(·) Block

MOGA模块适用于：

1、增强多阶特征交互，提高全局感知能力（适用于分类、检测、分割）。

2、提高小目标检测能力，适应复杂背景干扰（适用于目标检测、人体姿态估计）。

3、降低计算成本，使轻量级模型具备更强特征提取能力（适用于移动端、边缘计算）。

4、提高时空特征建模能力，适用于视频预测等任务。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

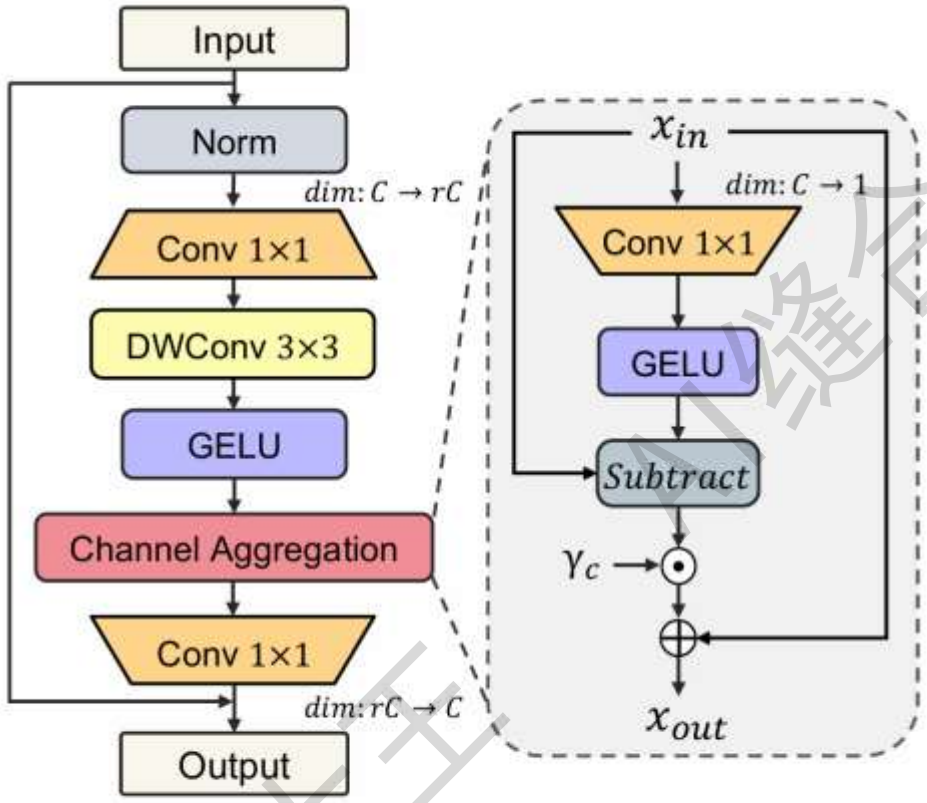

(b) CA(·) Block

CA模块适用于：

1、轻量级 CNN & 边缘计算
降低计算量，提高通道信息利用率

2、目标检测（如自动驾驶、医学影像）
减少通道冗余，提高小目标检测能力

3、语义/实例分割（如自动驾驶、遥感）
强化通道特征分配，提高分割精度

4、人体姿态估计（如运动分析、AR/VR）
提升关键点检测鲁棒性，减少误检

5、视频预测（如智能交通、天气预测）
优化时序信息流，提高推理速度

6、机器人视觉（如无人机、智能机械手）
提升环境感知能力，降低计算开销

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Bracketing Image Restoration and Enhancement with High-Low Frequency Decomposition

Genggeng Chen[1†] Kexin Dai[2†] Kangzhen Yang[2] Tao Hu[1,2] Xiangyu Chen[3]
Yongqing Yang[4] Wei Dong[1] Peng Wu[2] Yanning Zhang[2] Qingsen Yan[2*]
[1]Xi'an University of Architecture and Technology [2]Northwestern Polytechnical University
[3]University of Macau [4]Xi'an Institute of Optics and Precision Mechanics of CAS

https://github.com/chengeng0613/HLNet

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

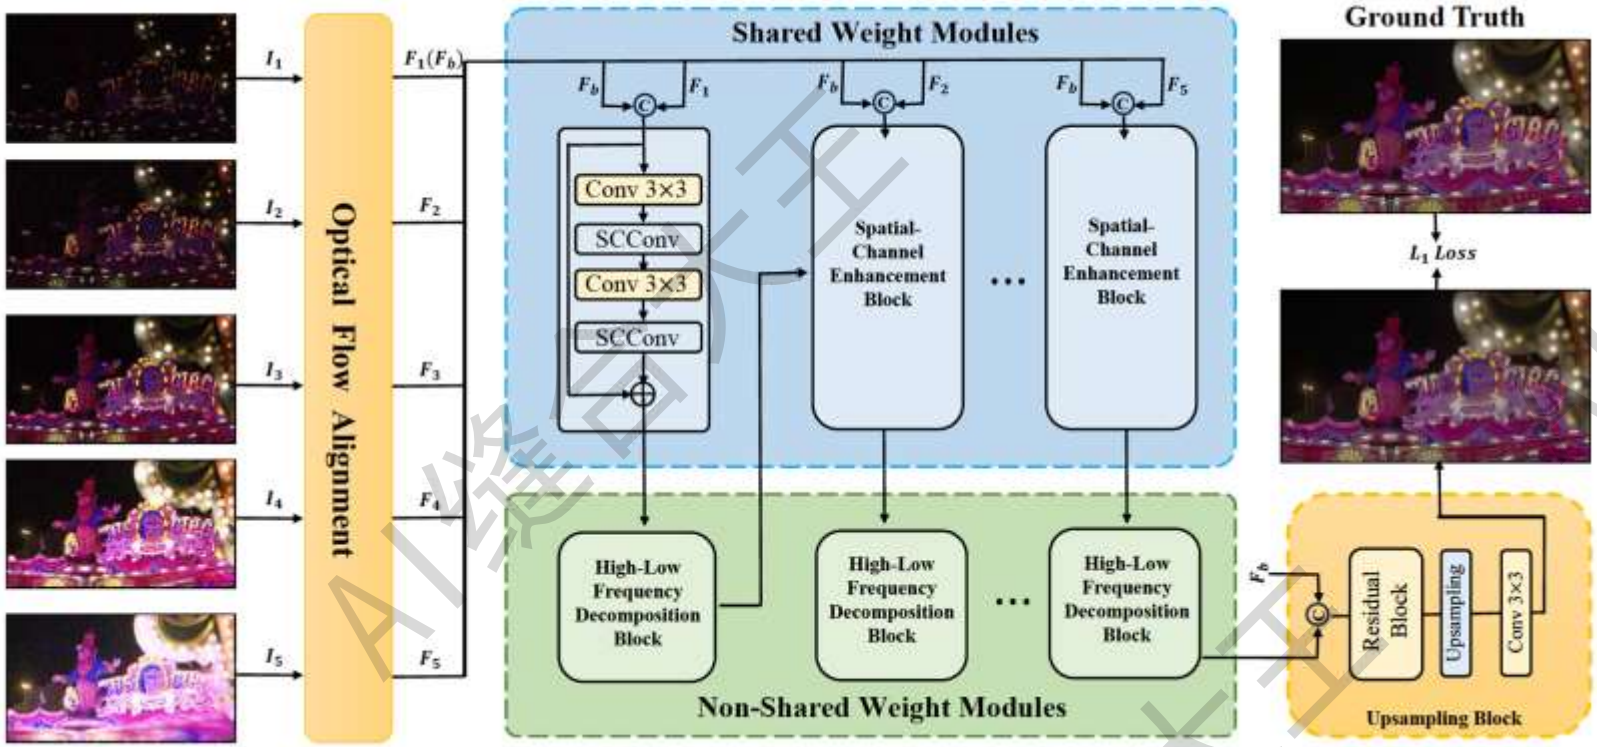

整体结构

HLNet 采用 “对齐 → 特征提取 → 上采样” 的三阶段架构，首先利用 光流 + 可变形卷积（DCN）进行特征对齐，然后通过 共享权重模块（SCEB）提取公共特征，并在 非共享权重模块（HLFDB）通过高低频分解分别处理不同类型的退化：高频信息用于细节恢复（去噪、去模糊），低频信息用于全局建模（超分辨率、HDR重建），其中低频特征结合 Transformer + 小波变换 进行多尺度融合，最后通过 跳跃连接 + 逐步上采样 生成高质量图像。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 2. The Ablation study of HLNet on the Track 2 BracketIRE+ Task dataset.

Models	PSNR-μ	SSIM-μ
HLNet-NoSCEB	29.41	0.8581
HLNet-NoHLFDB	28.97	0.8560
HLNet-LL	28.69	0.8521
HLNet-GG	28.75	0.8547
HLNet-ESRT	29.27	0.8566
HLNet-Wavelet	29.32	0.8577
Ours	**29.66**	**0.8598**

表 2 展示了不同模型变体在 PSNR-μ 和 SSIM-μ 指标上的变化，验证了各个模块对最终性能的贡献。

总结：HLFDB（高低频分解块）对模型影响最大（去掉后 PSNR 下降 0.69dB）。SCEB（空间-通道增强块）能有效提取通用特征（去掉后 PSNR 下降 0.25dB）。高低频信息必须分别用不同方法处理，否则性能下降。平均池化比小波变换更适用于该任务。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

图 6 通过可视化结果展示了 HLFDB（高低频分解块）对图像细节恢复的作用。

总结：去掉 HLFDB 会导致图像细节丢失，边缘模糊，说明高低频分解策略能有效提升恢复质量。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

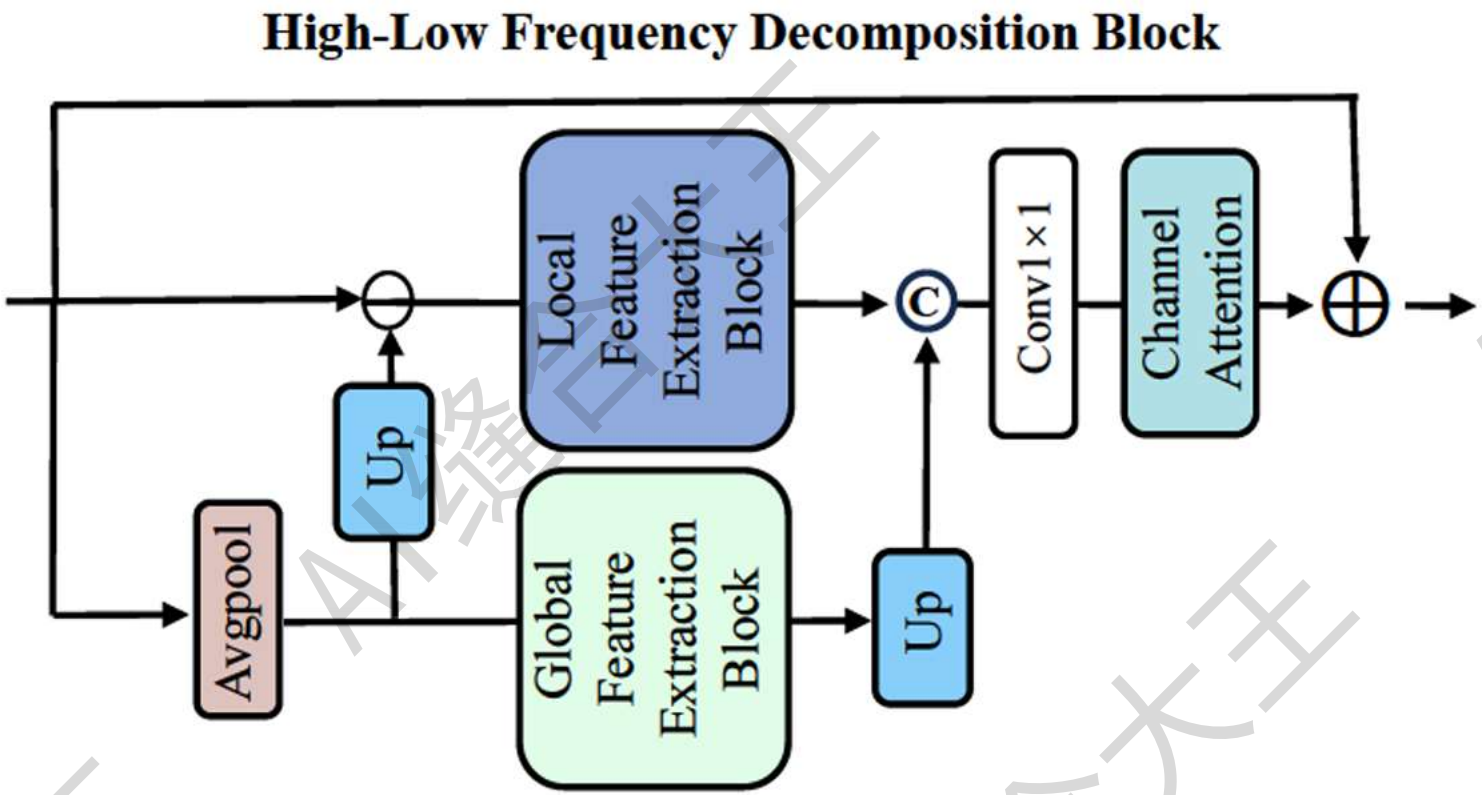

HLFDB 作为一个即插即用的特征增强模块，适用于 超分辨率、去噪、去模糊、HDR、低光增强、医学影像处理等任务。它的核心作用是通过高低频分解，分别优化细节（高频）和全局信息（低频），从而提升图像恢复质量，同时兼具高效性和灵活性，可无缝集成到不同的神经网络结构中。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

Rewrite the Stars ⭐

Xu Ma[1], Xiyang Dai[2], Yue Bai[1], Yizhou Wang[1], Yun Fu[1]
[1]Northeastern University [2]Microsoft

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

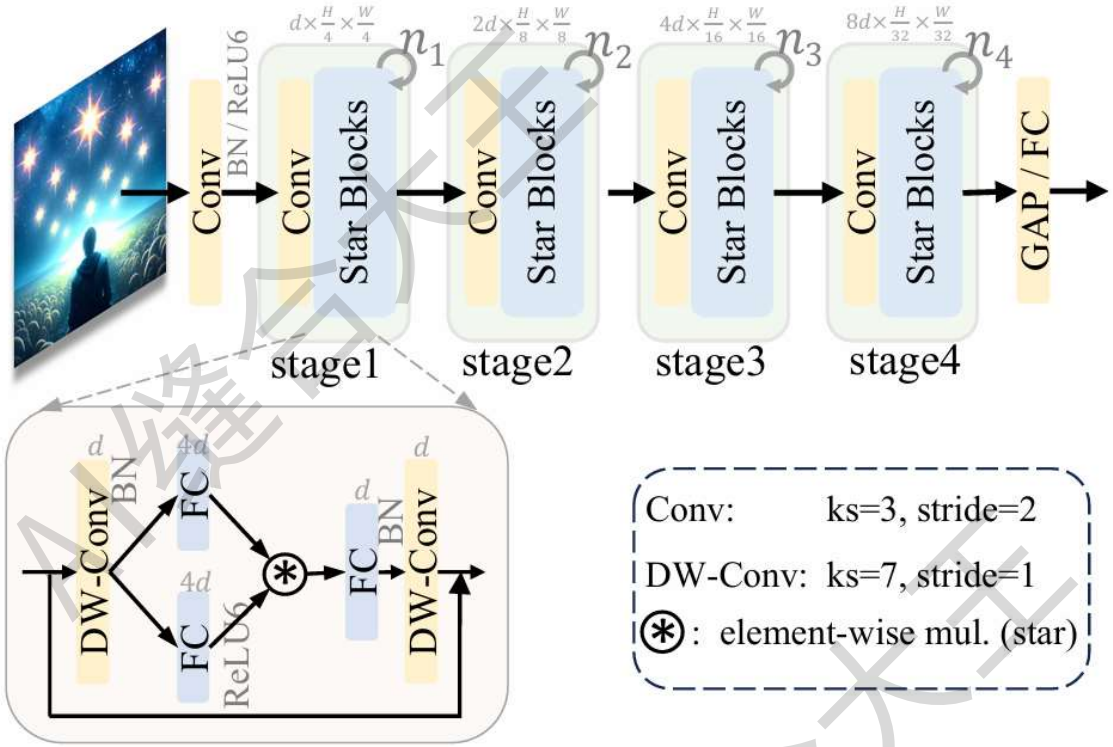

整体结构

StarNet 是一种高效的分层神经网络，采用 四阶段架构（4-stage hierarchical design），通过Star Operation进行特征融合。模型包括 初始卷积层（Stem） 进行下采样，随后通过多个 Star Block（星操作块） 进行特征提取，每个阶段通道数翻倍，最终通过 全局平均池化（GAP） 和 全连接层（FC） 输出分类结果。Star Block 由 两条分支 组成，其中一条使用深度可分离卷积（DW-Conv）和全连接层（FC），另一条通过全连接层（FC）进行变换，最终通过 逐元素乘法（element-wise multiplication） 进行特征融合，类似多项式核方法实现隐式高维映射。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Width	96	128	160	192	224	256	288
sum acc.	51.1	58.5	62.7	66.2	69.6	71.4	72.5
star acc.	57.6	64.0	68.2	71.7	73.9	75.3	76.1
acc. gap	6.5↑	5.5↑	5.5↑	5.5↑	4.3↑	3.9↑	3.6↑

Table 2. **ImageNet-1k classification accuracy of DemoNet using sum operation or star operation with different widths.** We set the depth to 12. We gradually increase the width by a step of 32.

在不同网络宽度（96 到 288）下，对比星操作（Star）和加法操作（Sum）的 ImageNet-1K 分类准确率。

结果：星操作在所有宽度设置下都优于加法操作，随着网络宽度增加，星操作的优势逐渐缩小。

说明：星操作的有效性，尤其是在窄网络中更具优势，能在有限计算资源下提升性能。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Depth	10	12	14	16	18	20	22
sum acc.	63.8	66.3	68.2	68.8	69.9	69.6	70.6
star acc.	70.3	71.8	72.9	72.9	73.9	75.4	75.4
acc. gap	6.5↑	5.5↑	4.7↑	4.1↑	4.0↑	5.8↑	4.8↑

Table 3. **ImageNet-1k classification accuracy of DemoNet using sum operation or star operation with different depths.** We set the width to 192. We gradually increase the depth by a step of 2.

在不同网络深度（10 到 22）下，对比星操作与加法操作的 ImageNet-1K 分类准确率。

结果：星操作在所有深度下都优于加法操作，并且随着深度增加，性能优势仍然保持稳定。

说明：星操作不仅适用于窄网络，在更深的网络中也能有效提升表示能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

operation	w/ act.	w/o act.	Accuracy drop
sum	66.2	32.4	33.8↓
star	71.7	70.5	1.2↓

Table 4. **DemoNet (width=192, depth=12) performance with and without activations**. Removing all activations leads to a significant performance drop in summation, whereas the star operation maintains its efficacy when removing ALL activations.

在 DemoNet（宽度 192，深度 12）上，分别测试带有激活函数和去除激活函数的分类性能。

结果：加法操作 在去掉激活函数后，准确率从 66.2% 降至 32.4%，下降了 33.8%。星操作 在去掉激活函数后，准确率 从 71.7% 仅下降到 70.5%（下降 1.2%），几乎不受影响。

说明：星操作本身具备 非线性特性，即使不使用激活函数，也能保持较好的表现。这说明神经网络可以探索新的非线性设计方式，而不完全依赖 ReLU、GELU 等激活函数。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Stage 1	Stage 2	Stage 3	Stage 4	Top-1
sum	sum	sum	sum	75.3
star	sum	sum	sum	75.1
star	star	sum	sum	75.2
star	star	star	sum	76.8
star	star	star	star	**78.4**
sum	sum	star	sum	76.4
sum	sum	sum	star	76.9
sum	sum	star	star	**78.4**

Table 7. **Gradually replacing star operation '*' with summation '+' in StarNet-S4** (considering its sufficient depth and model size).

在 StarNet-S4 的四个阶段中，逐步将星操作替换为加法操作，观察准确率变化。

完全使用加法（sum）时，准确率 75.3%。
仅第一阶段使用星操作，准确率略微下降 75.1%。
仅前两阶段使用星操作，准确率 75.2%。
仅前三阶段使用星操作，准确率提升至 76.8%。
全部使用星操作时，准确率最高，达到 78.4%。

说明：星操作在网络的后半部分（高通道数阶段）影响更大，而前期影响较小。这表明 星操作主要在更深层次起作用，提高高层特征表达能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

StarNet	Mobile (ms) sum / star	GPU (ms) sum / star	CPU (ms) sum / star
S1	0.7 / 0.7 (—)	2.3 / 2.3 (—)	3.8 / 4.3 (+0.5)
S2	0.8 / 0.7 (− 0.1)	2.0 / 2.0 (—)	4.2 / 4.5 (+0.3)
S3	0.9 / 0.9 (—)	2.7 / 2.7 (—)	5.9 / 6.7 (+0.8)
S4	1.1 / 1.0 (− 0.1)	3.7 / 3.7 (—)	8.4 / 9.4 (+1.0)

Table 8. **Latency comparison of different operations in StarNet.**

对比在 CPU、GPU 和移动设备（iPhone 13）上使用星操作或加法操作的计算时间。

移动设备（iPhone 13）和 GPU：星操作和加法操作的计算延迟几乎相同（<1ms 差异）。
CPU：星操作比加法稍慢，但差距较小（如 StarNet-S4 在 CPU 上的计算时间从 8.4ms 增加到 9.4ms）。

说明：虽然星操作本质上涉及乘法运算，理论上计算量更高，但在实际硬件优化下，其计算延迟与加法操作相当。因此，在 GPU 和移动设备上，星操作并不会带来额外的计算负担。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

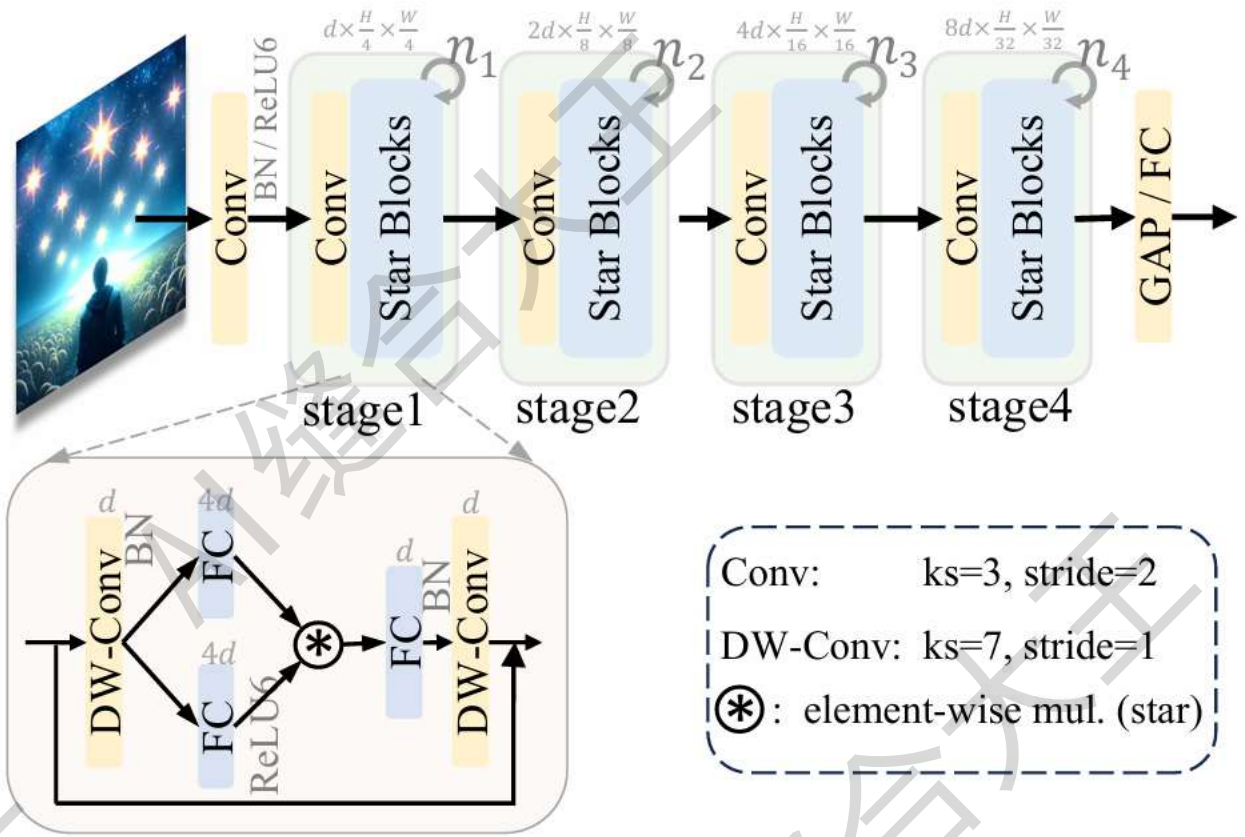

由于 StarConv（星操作） 本质上是一种 高效的特征变换方式，可以 隐式提高特征维度，同时保持计算高效，因此它适用于以下几种主要场景：

轻量级高效网络（Mobile & Edge AI）、计算受限的大规模视觉任务、高效 Transformer/CNN 结合模型、低计算量的医学影像分析、低功耗自动化检测任务、无激活函数（Activation-Free）神经网络

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Submitted to ICLR 2024

CEDNET: A CASCADE ENCODER-DECODER NETWORK FOR DENSE PREDICTION

Gang Zhang[1], **Ziyi Li**[4], **Chufeng Tang**[1], **Jianmin Li**[1], **Xiaolin Hu**[1,2,3*]
[1]Department of Computer Science and Technology, Institute for AI,
BNRist, THU-Bosch JCML Center, Tsinghua University, Beijing 100084, China
[2]Tsinghua Laboratory of Brain and Intelligence (THBI),
IDG/McGovern Institute for Brain Research, Tsinghua University, Beijing 100084, China
[3]Chinese Institute for Brain Research (CIBR), Beijing 100010, China
[4]Huazhong University of Science and Technology, Wuhan 430074, China
{zhang-g19,tcf18}@mails.tsinghua.edu.cn, liziyi@hust.edu.cn,
{lijianmin,xlhu}@mail.tsinghua.edu.cn
Code: https://github.com/zhanggang001/CEDNet

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

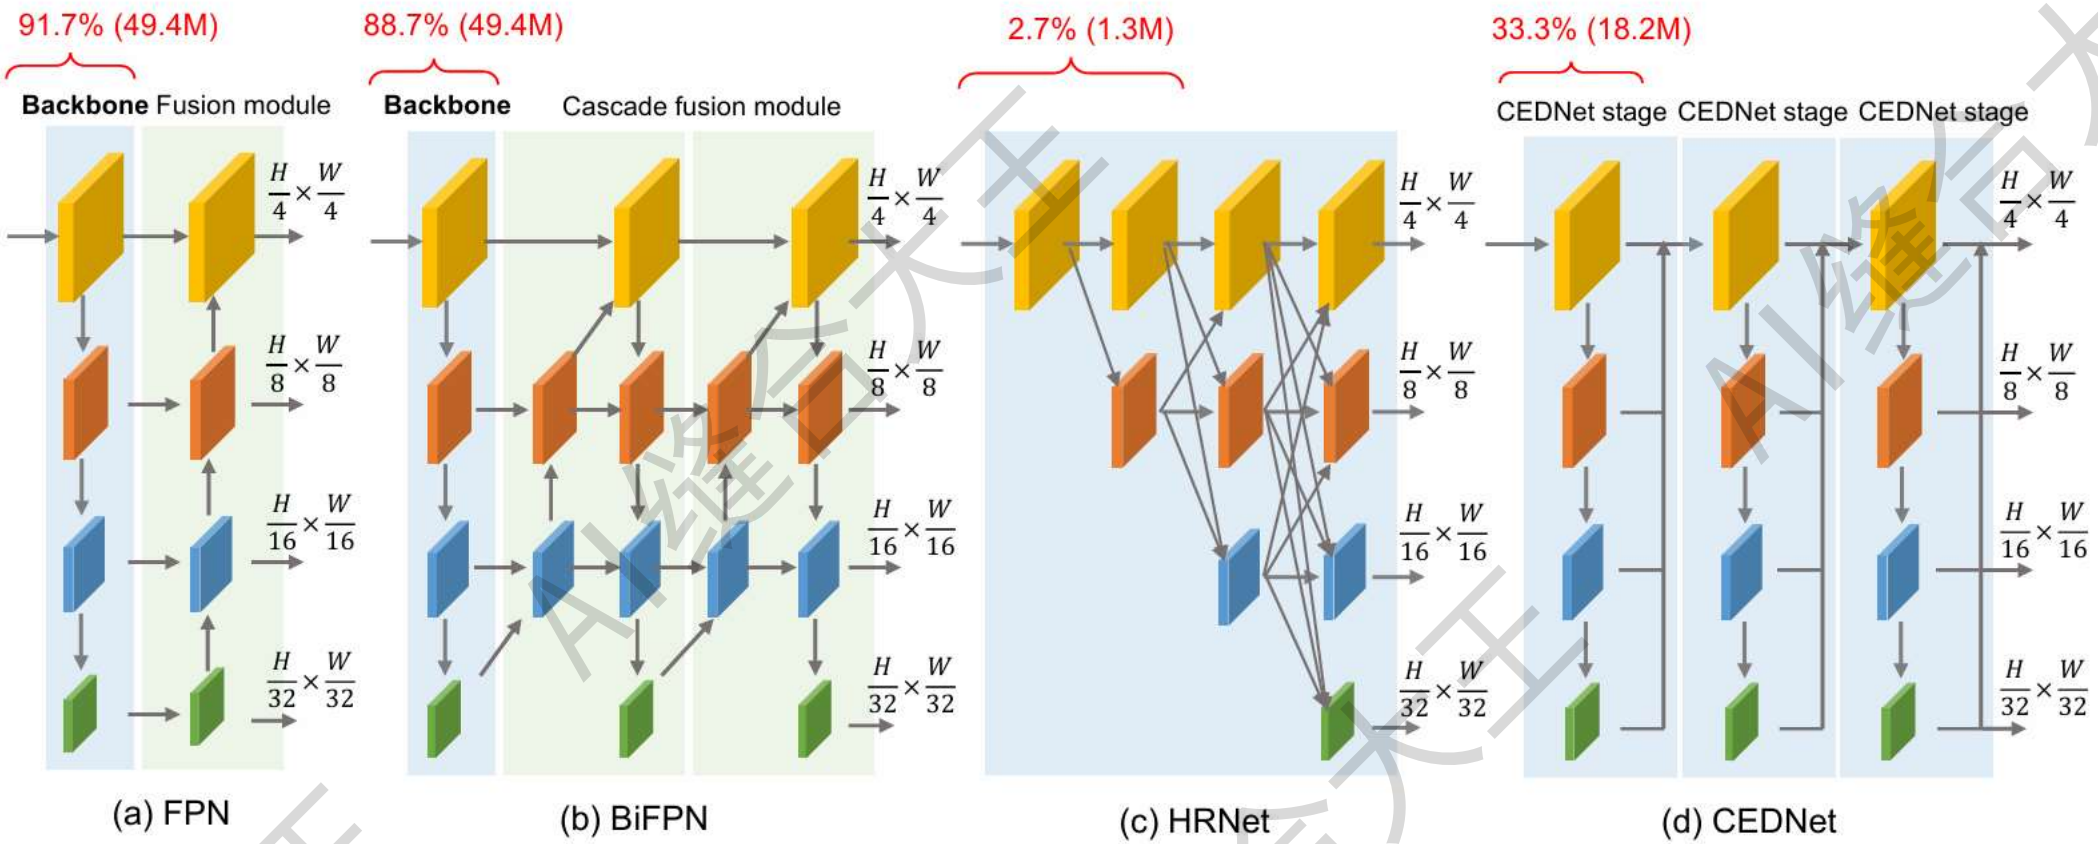

整体结构

CEDNet（Cascade Encoder-Decoder Network）是一种级联编码-解码网络，专为密集预测任务（如目标检测、实例分割和语义分割）设计。它采用多个级联的编码-解码阶段，在每个阶段内部进行多尺度特征提取和融合，使高层特征能够更早地指导低层特征学习，从而提升特征表达能力。相比传统的 FPN 和 BiFPN 仅在网络后期进行特征融合，CEDNet 通过均匀分配计算资源，在早期阶段就实现高效的多尺度特征整合，提升检测和分割任务的性能。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 4: Early feature fusion. n_1^i, n_2^i, n_3^i are the number of blocks in the i-th stage.

Time	#Stage	n_1^1, n_2^1, n_3^1	n_1^2, n_2^2, n_3^2	Param	AP^b
6/6	2	6, 9, 3	-	38M	40.6
5/6	2	5, 10,5	1, 2, 1	38M	42.2
4/6	2	4, 8, 4	2, 4, 2	38M	42.4
3/6	2	3, 6, 3	3, 6, 3	38M	42.9
2/6	2	2, 4, 2	4, 8, 4	38M	**43.3**
1/6	2	1, 2, 1	5,10, 5	38M	**43.3**
2/6	3	2, 4, 2	2, 4, 2	39M	**43.3**

研究了不同的特征融合时间对目标检测性能（APb）的影响。通过调整两个级联阶段（stages）之间的计算资源分配比例，实验验证了越早进行多尺度特征融合，检测性能越好。

结果：当模型在更早的阶段进行特征融合时，APb（目标检测精度）逐步提高，最终在 3 级联阶段时达到最优。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 5: Different token mixers. WA and DW are short for window attention and depth-wise.

Backbone	Token mixer	Param	AP^b
ResNet-50	Vanilla conv 3×3	38M	41.7
CEDNet-R50-T		39M	**45.3**
Swin-T	Local WA	39M	44.9
CEDNet-Swin-T		37M	**47.4**
ConvNeXt-T	DW conv 7×7	39M	45.4
CEDNet-NeXt-T		39M	**48.3**
CSwin-T	Cross WA	32M	48.0
CEDNet-CSwin-T		33M	**49.5**

研究了不同 Token Mixer（空间特征交互方式）对 CEDNet 性能的影响。

研究了三种主流的 Token Mixer：卷积（Conv）（ResNet, ConvNeXt）、窗口注意力（Window Attention, WA）（Swin Transformer）、交叉窗口注意力（Cross Window Attention, CSwin）

结果：CEDNet 在不同 Token Mixer 上均优于对应的主干网络，说明其架构的泛化能力强。其中，CSwin 提供最佳性能，但 ConvNeXt 作为默认选择，能在性能和计算成本之间取得平衡。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 6: Number of stages.

m	n_1, n_2, n_3	Param	AP^b
1	6, 9, 3	38M	40.6
2	3, 6, 3	38M	42.9
3	2, 4, 2	39M	**43.3**
4	1, 4, 1	39M	43.1

研究了不同级联阶段数（m）对模型性能的影响。

结果：当 m=1（即没有级联结构，仅使用一个编码-解码模块）时，APb = 40.6。
当 m=3 时，检测精度达到最优（APb = 43.3）。
继续增加阶段数到 m=4 时，性能略有下降（APb = 43.1），可能是由于网络过深导致优化困难。
最终选择 m=3 作为默认设置，保证早期特征融合的有效性，同时避免过深带来的优化问题。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 7: Data augmentation.

Backbone	Aug.	AP^b
ConvNeXt-T	Existing	45.2
ConvNeXt-T	Ours	45.4
CEDNet-NeXt-T	Existing	47.0
CEDNet-NeXt-T	Ours	**48.3**

对比了数据增强策略对 CEDNet 性能的影响。

实验设置：“Existing”：使用 ConvNeXt 原始的数据增强策略。“Ours”：采用更强的数据增强，包括大尺度抖动（Large Scale Jittering）和 Copy-Paste 数据增强。

结果：CEDNet 在使用增强版数据增强策略后，APb 提高了 1.3%（从 47.0 → 48.3）。ConvNeXt 仅提升 0.2%（45.2 → 45.4），说明 CEDNet 由于更强的特征学习能力，能从更强的数据增强中获益更多。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 8: LR CED block.

LR block	Param	AP^b
	38.5M	47.9
✓	38.6M	**48.3**

研究了是否加入 LR CED Block 对 CEDNet 性能的影响。

结果：在 CEDNet-NeXt-T 中加入 LR CED Block 后，APb 从 47.9 提升至 48.3。说明在最低分辨率特征层增加长程空洞卷积（Dilated Depth-wise Convolution）能够有效提升目标检测性能，同时参数量增加极小（38.5M → 38.6M）。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

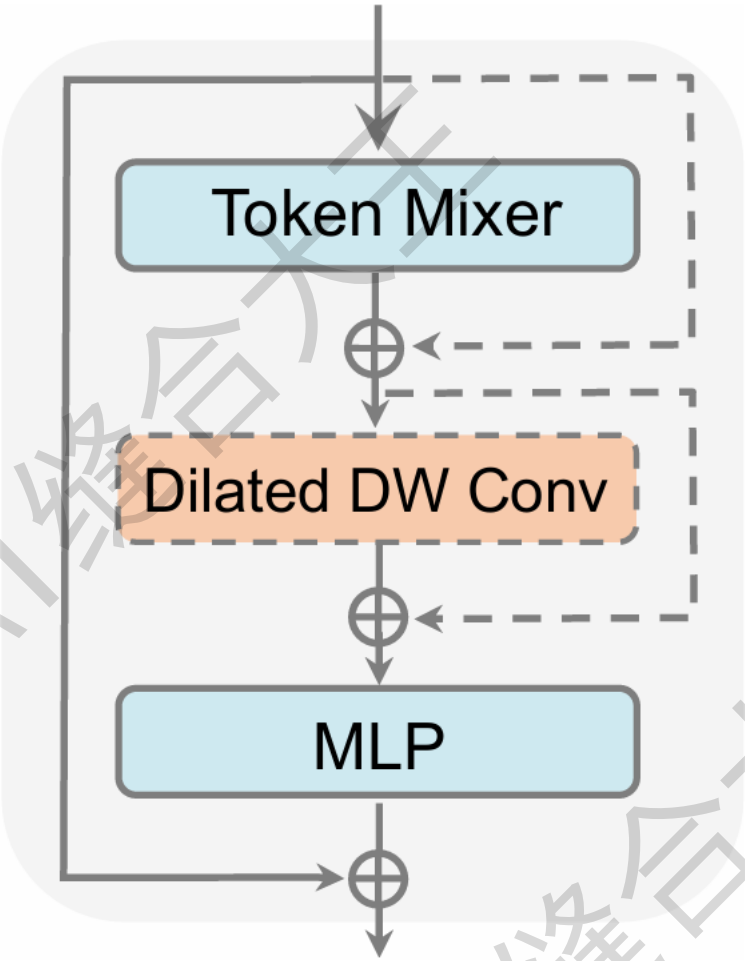

CED 模块作为即插即用的特征提取模块，适用于目标检测、实例分割、语义分割、医学影像分析、遥感图像处理和视频理解等任务。它的主要作用是实现早期多尺度特征融合、增强特征提取能力，并作为轻量化的 FPN/HRNet 替代方案，以提高不同主干网络在密集预测任务中的性能。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Hybrid Convolutional and Attention Network for Hyperspectral Image Denoising

Shuai Hu, Feng Gao, *Member, IEEE*, Xiaowei Zhou, Junyu Dong, *Member, IEEE*, and Qian Du, *Fellow, IEEE*

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

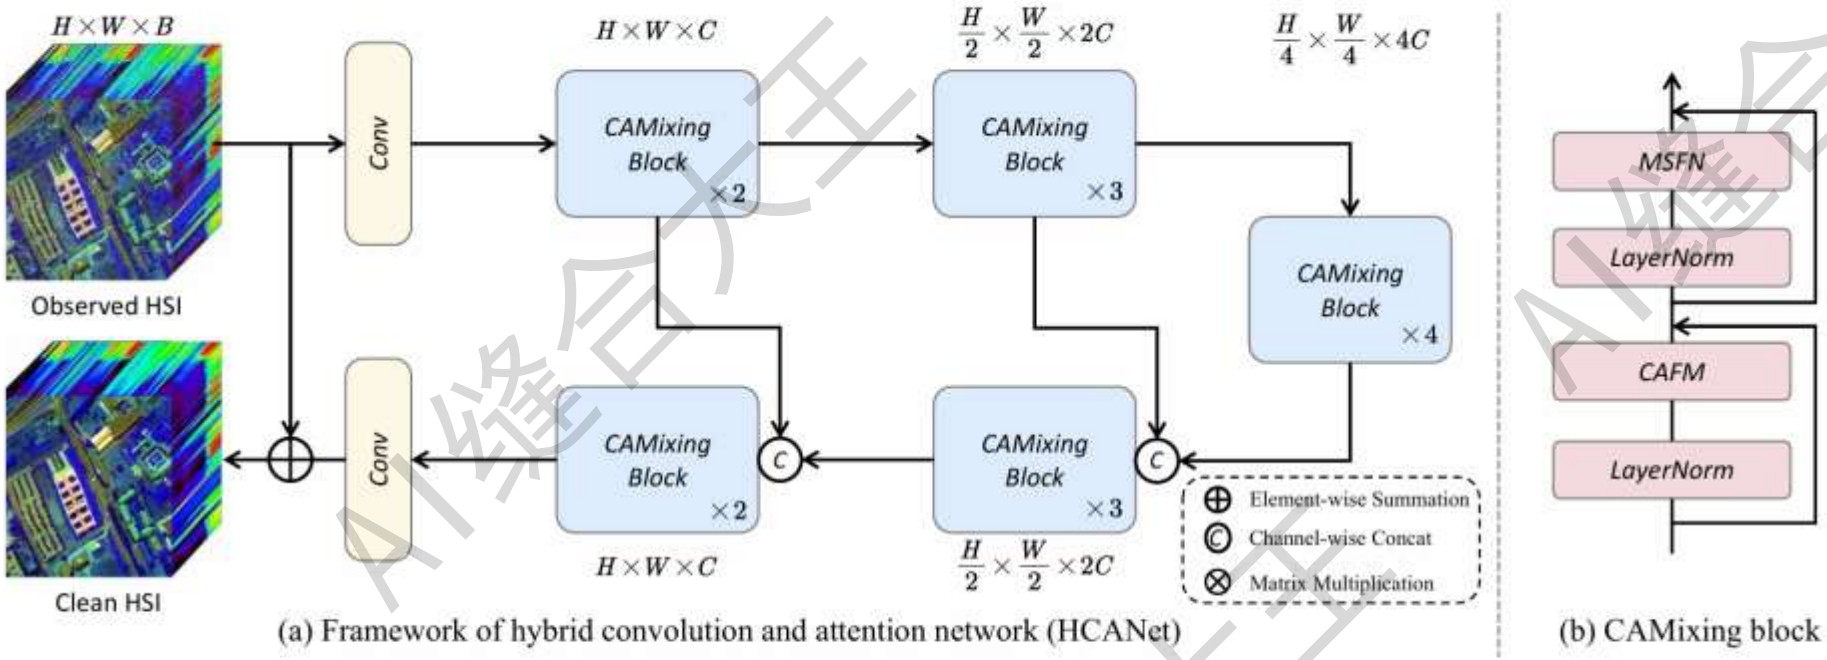

Fig. 1. Illustration of our proposed hybrid convolution and attention network (HCANet) for HSI denoising. (a) Framework of HCANet. (b) Inner structure of CAMixing block.

整体结构

HCANet 采用 U-Net 结构，结合 卷积（CNN）和 Transformer 注意力机制，通过 卷积与注意力融合模块（CAFM）提取局部和全局特征，并利用 多尺度前馈网络（MSFN） 进行多尺度特征聚合，有效增强去噪能力。模型使用 跳跃连接 维持信息流动，并通过 L1 误差损失 + 全局梯度正则化 进行优化，确保去噪效果的同时保留图像细节。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

TABLE III
ABLATION STUDIES ON ICVL DATASETS UNDER NOISE LEVEL $\sigma = 30$, EPOCH = 50

Base model	Local branch	3D Conv	MSFN	PSNR ↑	SSIM ↑	SAM ↓
✓				39.94	0.965	0.045
✓	✓			40.58	0.967	0.039
✓	✓	✓		42.23	0.975	0.037
✓	✓	✓	✓	**42.68**	**0.976**	**0.035**

1、基础模型（仅使用 Transformer）：PSNR = 39.94，SSIM = 0.965，SAM = 0.045说明单独使用 Transformer 进行去噪，去噪效果有限。
2、加入局部分支（Local Branch）：PSNR 提升至 40.58，SSIM 提升至 0.967，SAM 下降至 0.039说明局部特征提取（卷积操作）有助于提升去噪性能。
3、引入 3D 卷积：PSNR 提升至 42.23，SSIM 提升至 0.975，SAM 进一步下降至 0.037说明 3D 卷积在高光谱去噪中有利于捕捉空间-光谱特征，提高恢复质量。
4、完整模型（加入 MSFN）：PSNR 达到 42.68，SSIM 达到 0.976，SAM 降低至 0.035说明 多尺度特征提取（MSFN）能够有效抑制多种噪声，进一步提高去噪性能。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

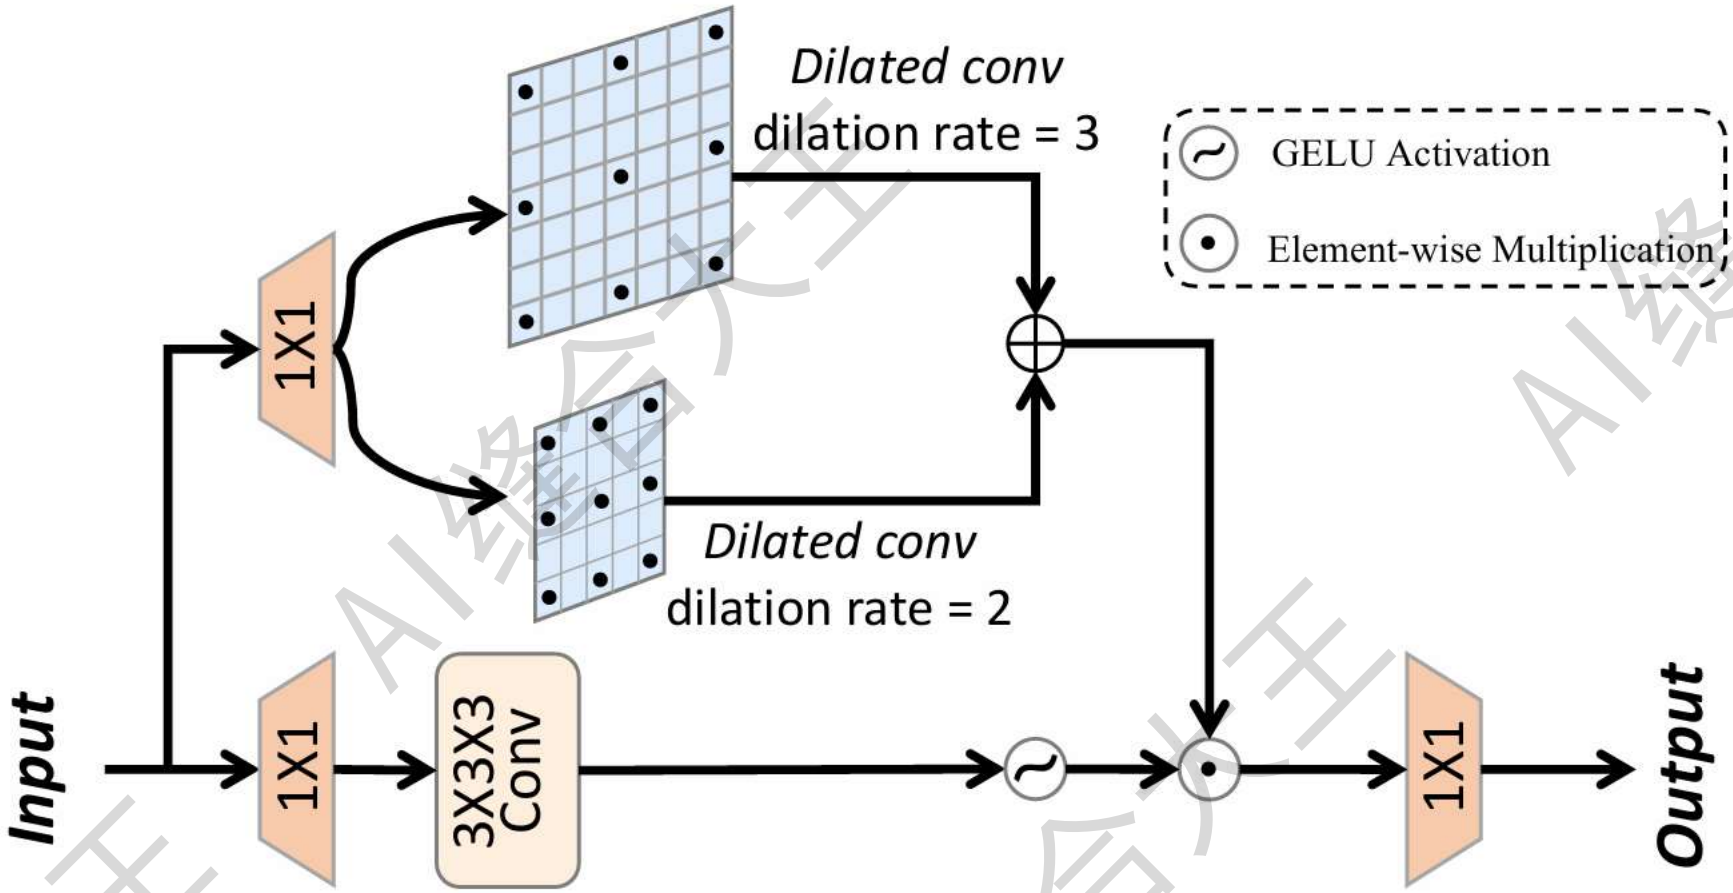

MSFN 作为即插即用模块，适用于图像去噪、超分辨率、去模糊、去伪影等任务，能够增强多尺度特征表达能力，提高模型对不同尺度噪声和细节的适应性，同时减少计算开销，提升恢复质量。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

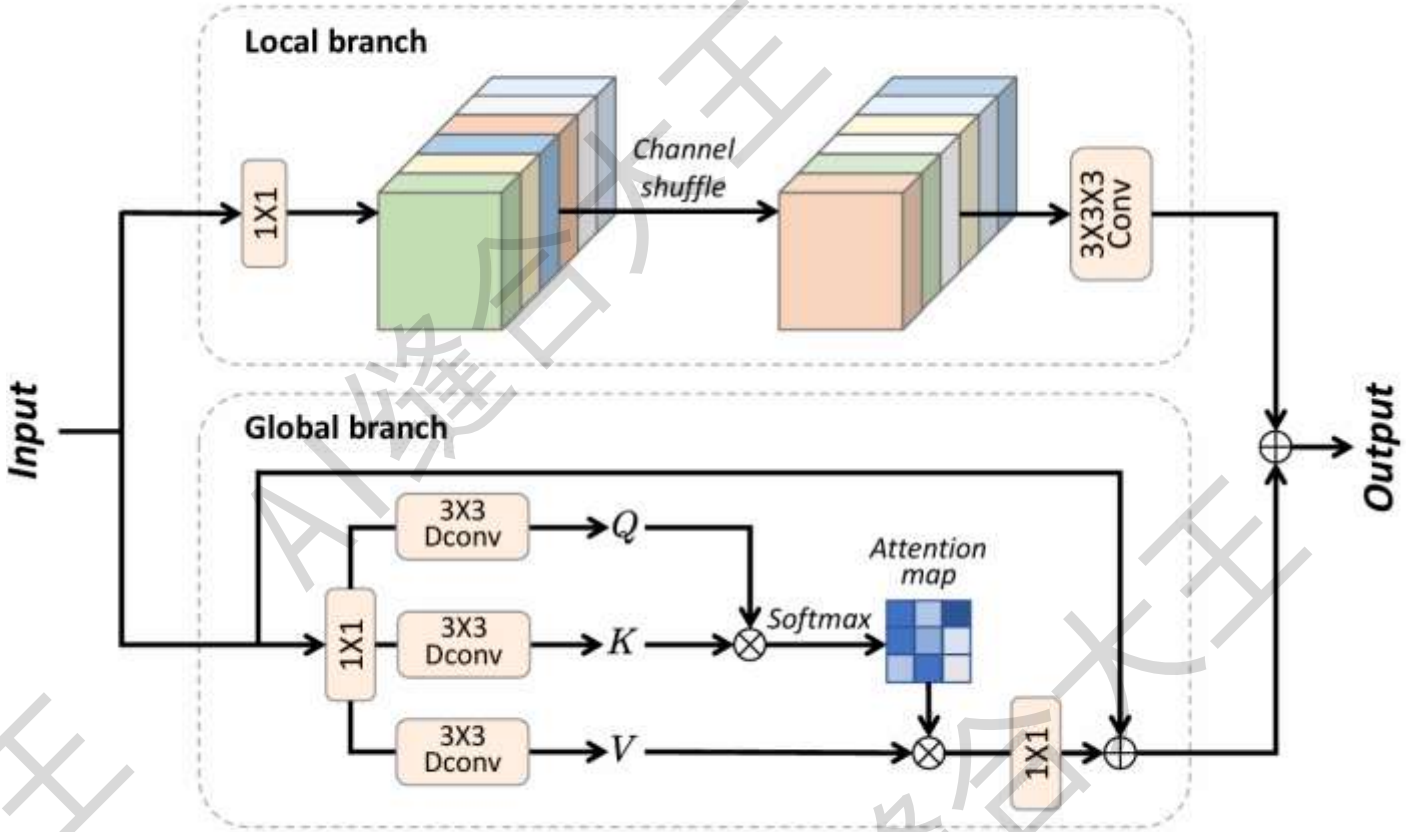

CAFM 作为即插即用模块，适用于图像去噪、超分辨率、去模糊、目标检测、分割等任务，能够有效融合局部特征（CNN）和全局特征（Transformer），增强边缘保留、减少伪影，提高模型的泛化能力和计算效率。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Restoring Images in Adverse Weather Conditions via Histogram Transformer

Shangquan Sun[1,2], Wenqi Ren[3,4†], Xinwei Gao[5], Rui Wang[1,2], and Xiaochun Cao[3]

[1] Institute of Information Engineering, Chinese Academy of Sciences, Beijing 100085, China
[2] School of Cyber Security, University of Chinese Academy of Sciences, Beijing 100049, China
[3] School of Cyber Science and Technology, Shenzhen Campus of Sun Yat-sen University, Shenzhen 518107, China
[4] Guangdong Provincial Key Laboratory of Information Security Technology, Guangzhou 510006, China
[5] Wechat Business Group, Tencent, Shenzhen, Guangdong, China, 518057
shangquansun@gmail.com, renwq3@mail.sysu.edu.cn,

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

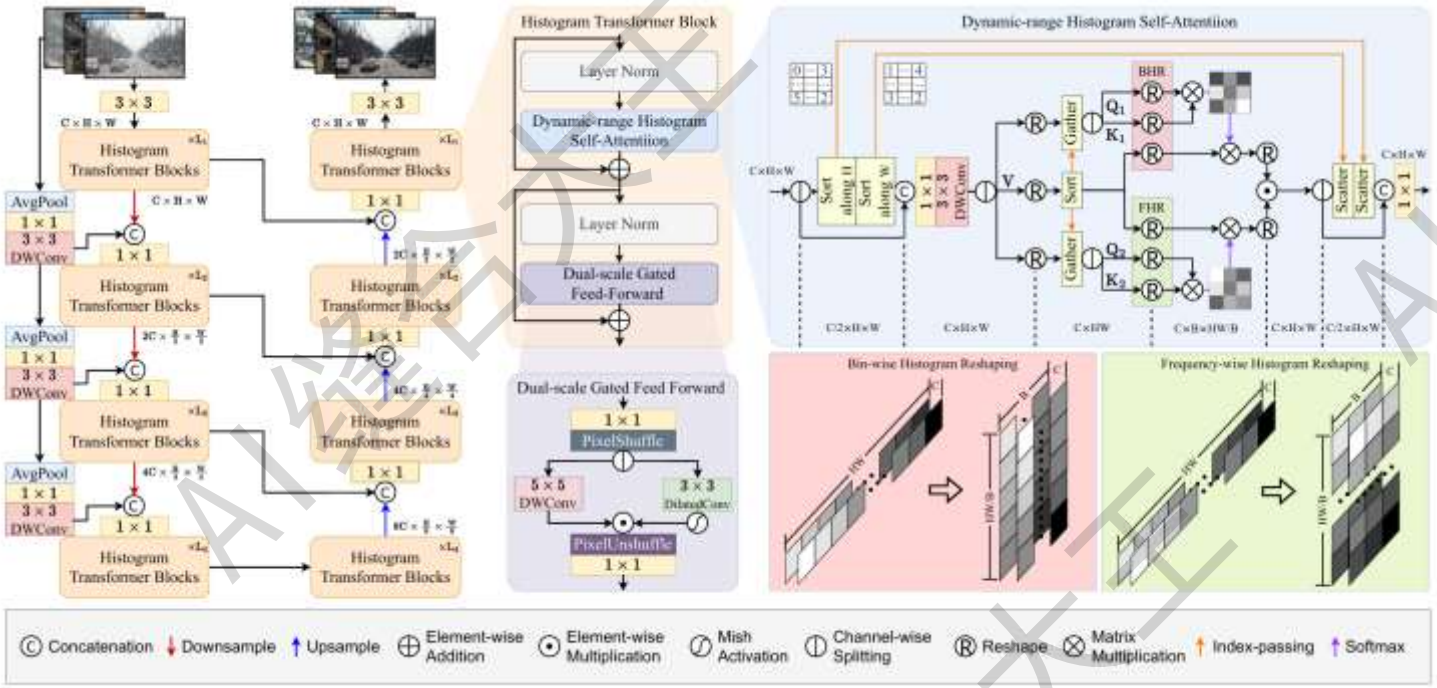

Histoformer 模型整体结构采用 编码-解码架构，其中主干网络由多个 直方图Transformer块（HTB）组成，每个HTB包含两个关键模块：动态范围直方图自注意力（DHSA）和 双尺度门控前馈网络（DGFF）。模型首先通过 3×3卷积 进行图像特征提取，然后在多个编码和解码阶段应用HTB以提取天气降解的特征，并通过跳跃连接 保持低级特征信息。

在下采样和上采样阶段，分别采用 像素重排来调整特征分辨率。最终，通过一个 1×1卷积 重建高质量图像，并结合 皮尔逊相关损失和 L1损失 进行优化，以确保恢复图像在局部细节和整体结构上的一致性。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 2: Ablation studies on the dynamic-range convolution.

	Vanilla Conv	Verti.+Horiz.	Horiz.+Verti.
PSNR	31.94	32.03	**32.08**
SSIM	0.9377	0.9385	**0.9389**

实验内容：对比传统卷积（Vanilla Conv）和不同排序方式（水平+垂直 vs. 垂直+水平）的动态范围卷积对PSNR和SSIM的影响。

结论：动态范围卷积能够提升图像恢复质量，并且排序方式对结果影响较小。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 3: Ablation studies on the design of self-attention

SA type	PSNR	SSIM
MDTA [86]	30.94	0.9278
TKSA [11]	31.12	0.9295
w/o BHR	31.05	0.9301
w/o FHR	31.79	0.9364
DHSA	**32.08**	**0.9389**

证明 直方图自注意力（Histogram Self-Attention）通过结合 BHR+FHR 取得最佳效果。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 4: Ablation studies on the number of $C \times B$

$C \times B$	PSNR	SSIM
12	30.43	0.9283
20	31.56	0.9312
28	31.94	0.9379
36	**32.08**	**0.9389**
44	Out of memory	

调整 C × B（通道数 × 直方图分区数），观察对PSNR和SSIM的影响。

适当增加通道数和分区数可以提升恢复质量，但过多会导致显存消耗过大，最佳设置为 C × B = 36。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 5: Ablation studies on the choice of feed-forward module

Feed-Forward	PSNR	SSIM
FFN [38]	31.32	0.9313
GDFN [86]	31.42	0.9347
DANB [96]	31.56	0.9351
MSFN [11]	31.78	0.9367
DGFF	**32.08**	**0.9389**

对比不同的前馈网络：FFN、GDFN、DANB、MSFN、DGFF（Dual-Scale Gated Feed-Forward，本研究提出）

DGFF 模块 提供了最佳性能，说明 同时结合不同尺度和动态范围的信息 能够提升恢复质量。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 6: Ablation studies on the setting of correlation loss

	α	PSNR	SSIM
w/o $\mathcal{L}_{cor}$	0	31.77	0.9358
w/ $\mathcal{L}_{cor}$	0.1	32.01	0.9369
	1	**32.08**	**0.9389**
	5	32.03	0.9392
	10	31.96	0.9375

对比不同的损失权重 α 对恢复质量的影响：不使用相关性损失（w/o Lcor）不同 α 权重（0.1, 1, 5, 10）

引入皮尔逊相关损失（Lcor）可提升图像恢复效果，表明在像素层面之外，维护全局亮度和纹理结构的一致性是重要的。但 α 过大会导致性能下降，最佳设置为 α = 1.0。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

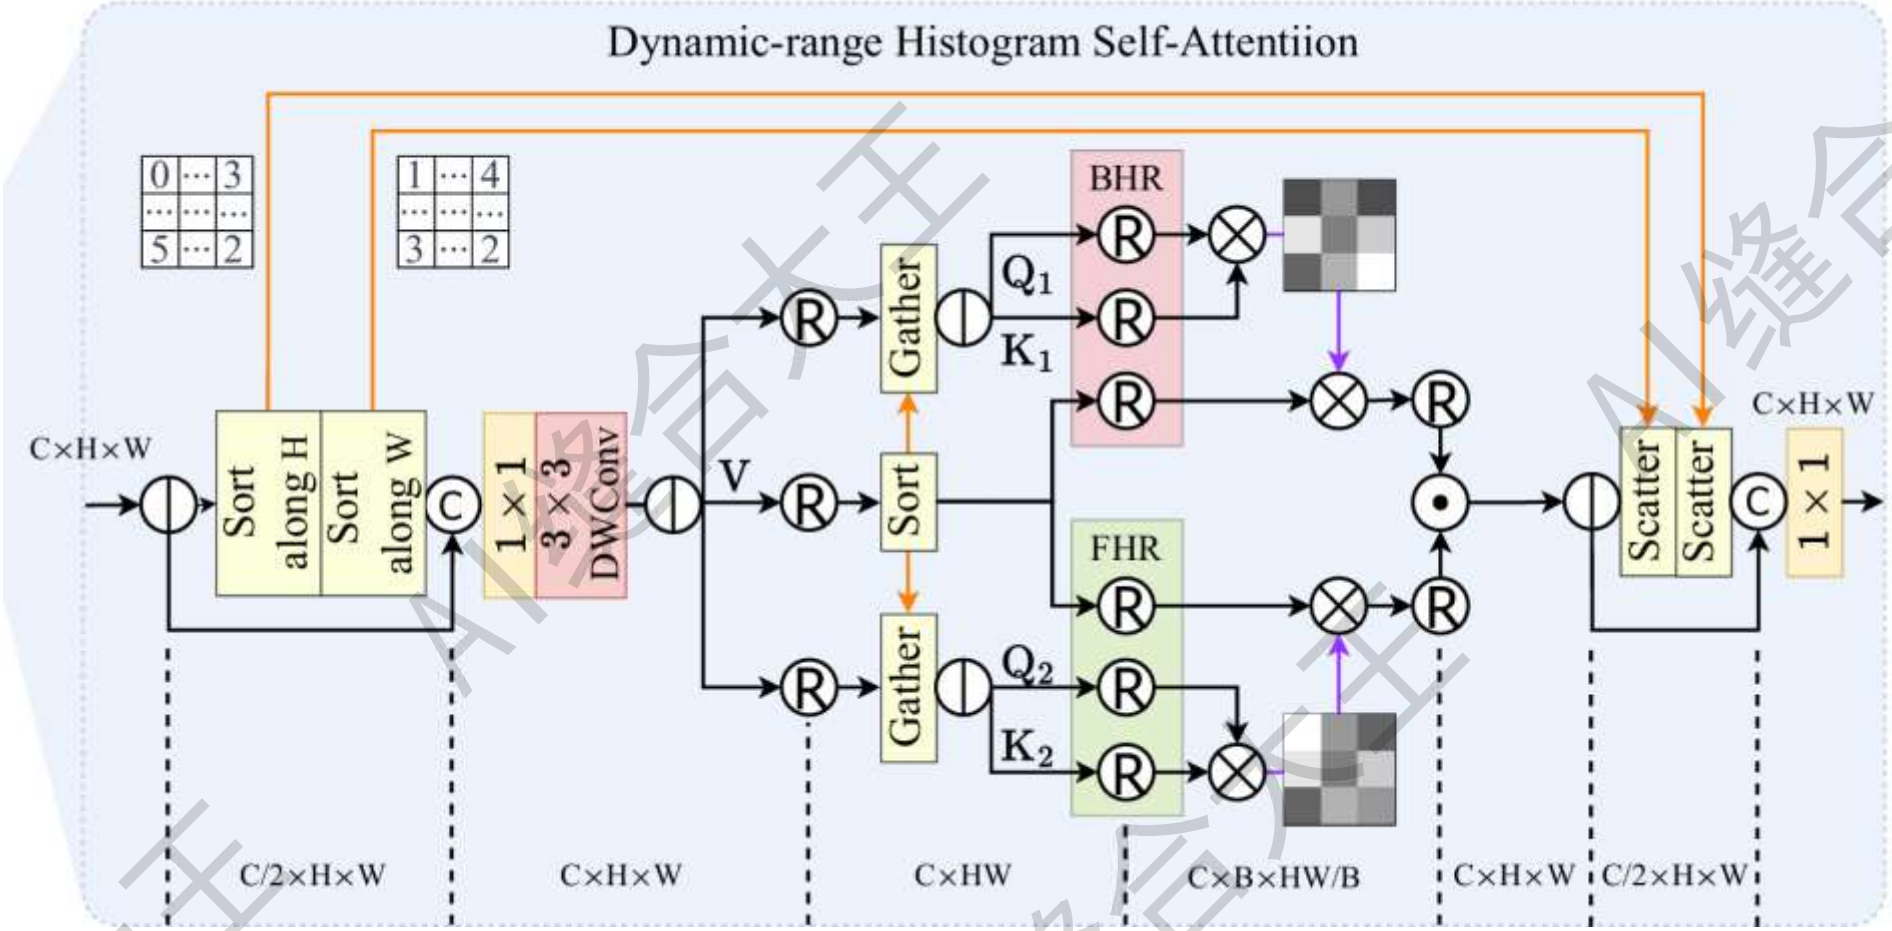

DHSA 是一个 通用且高效的自注意力模块，适用于图像恢复、增强、去噪、医学影像分析、目标检测等多个任务。其核心优势在于 动态建模相似降解区域，提高恢复质量，同时降低计算成本。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

InceptionNeXt: When Inception Meets ConvNeXt

Weihao Yu[1] Pan Zhou[2,3] Shuicheng Yan[4] Xinchao Wang[1*]
[1]National University of Singapore [2]Singapore Management University [3]Sea AI Lab [4]Skywork AI
weihaoyu@u.nus.edu panzhou@smu.edu.sg shuicheng.yan@kunlun-inc.com xinchao@nus.edu.sg

Code: https://github.com/sail-sg/inceptionnext

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

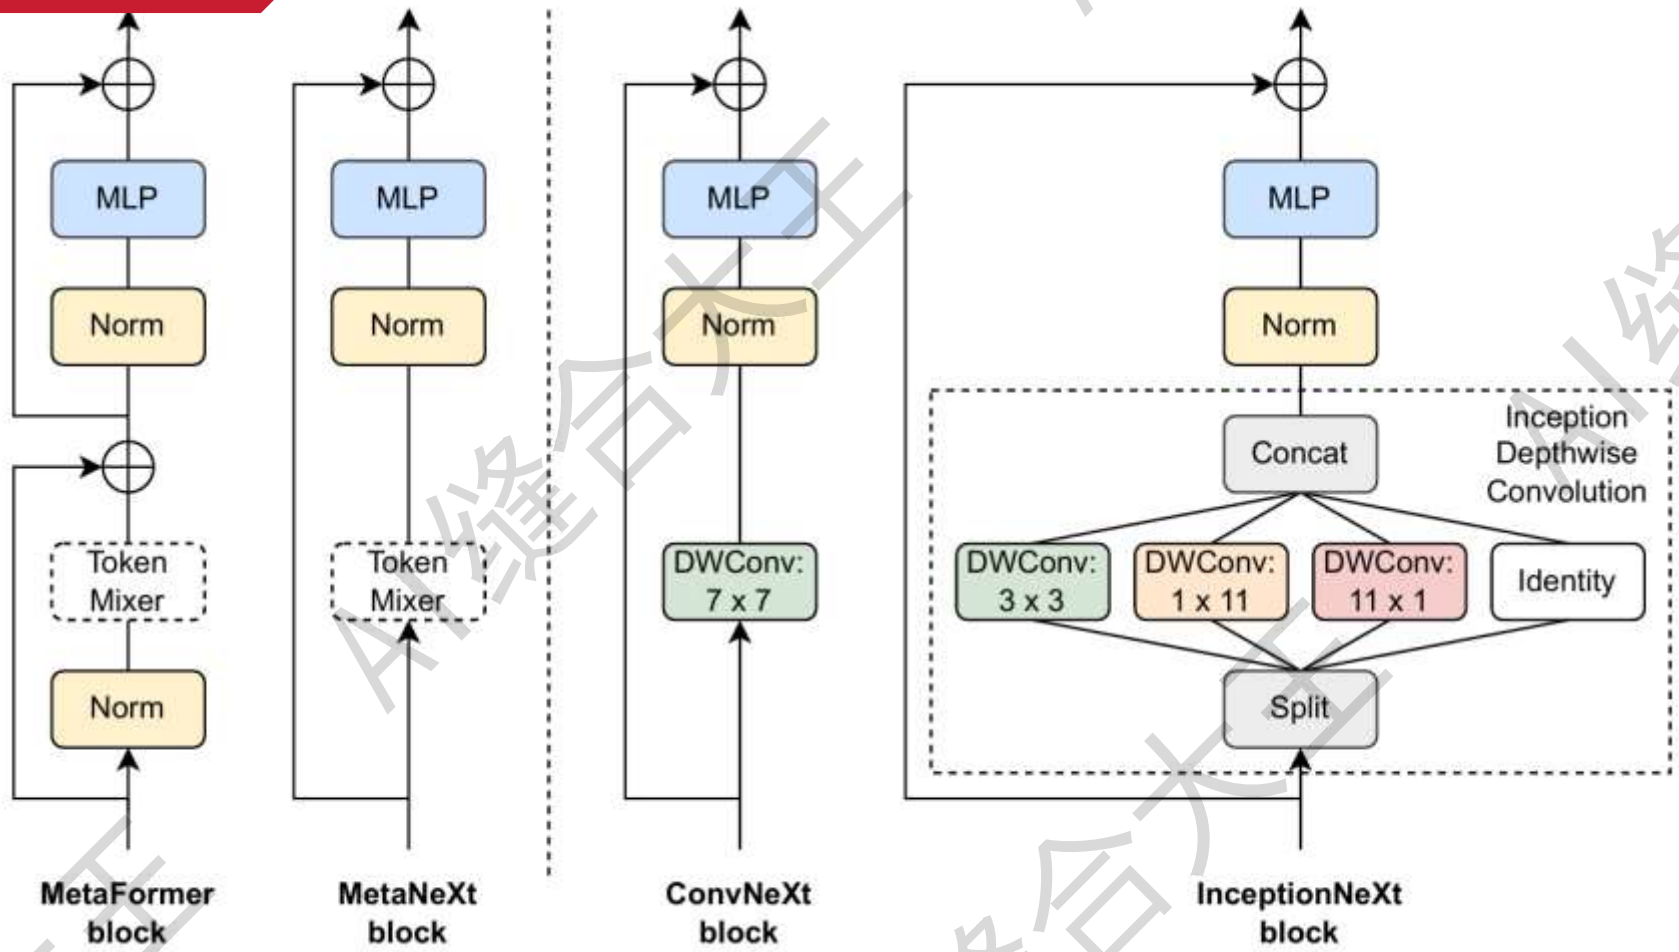

整体结构

AFPN模型通过逐步融合不同尺度的特征，首先从相邻的低层特征开始，逐步加入高层特征，形成渐进式特征融合结构。模型同时采用自适应空间融合模块（ASF），为每个尺度特征分配权重，以解决不同尺度间的矛盾信息，从而实现更高效、精确的多尺度特征融合，用于目标检测任务。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Ablation	Variant	Params (M)	MACs (G)	Throughput Train	Throughput Inference	Top-1 (%)
Baseline	None (InceptionNeXt-T)	28.1	4.2	901	2900	82.3
Branch	Remove horizontal band kernel	28.0	4.2	947	3093	81.9
	Remove vertical band kernel	28.0	4.2	954	3173	81.9
	Remove small band kernel	28.0	4.2	940	3004	82.0
	horizontal and vertical band kernel in parallel → in sequence	28.1	4.2	903	2971	82.1
Band kernel size	Band kernel size 11 → 7	28.0	4.2	905	2946	82.1
	Band kernel size 11 → 9	28.1	4.2	904	2916	82.1
	Band kernel size 11 → 13	28.1	4.2	896	2895	82.0
Convolution branch ratio	Conv. branch ratio 1/8 → 1/4	28.1	4.2	834	2499	82.2
	Conv. branch ratio 1/8 → 1/16	28.0	4.2	936	3097	81.8
Normalization	Batch Norm [29] → Layer Norm [1]	28.1	4.2	721	2646	82.4

消融实验表明：

带状核（band kernel）对模型准确率至关重要，删除任何一个都会导致性能下降。

带状核的最佳大小为 11，过小或过大会影响准确率或计算开销。

计算通道比率 1/8 是最优选择，能在计算效率和准确率之间取得平衡。

Batch Normalization 更适合该架构，Layer Normalization 尽管准确率略高，但计算效率下降。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

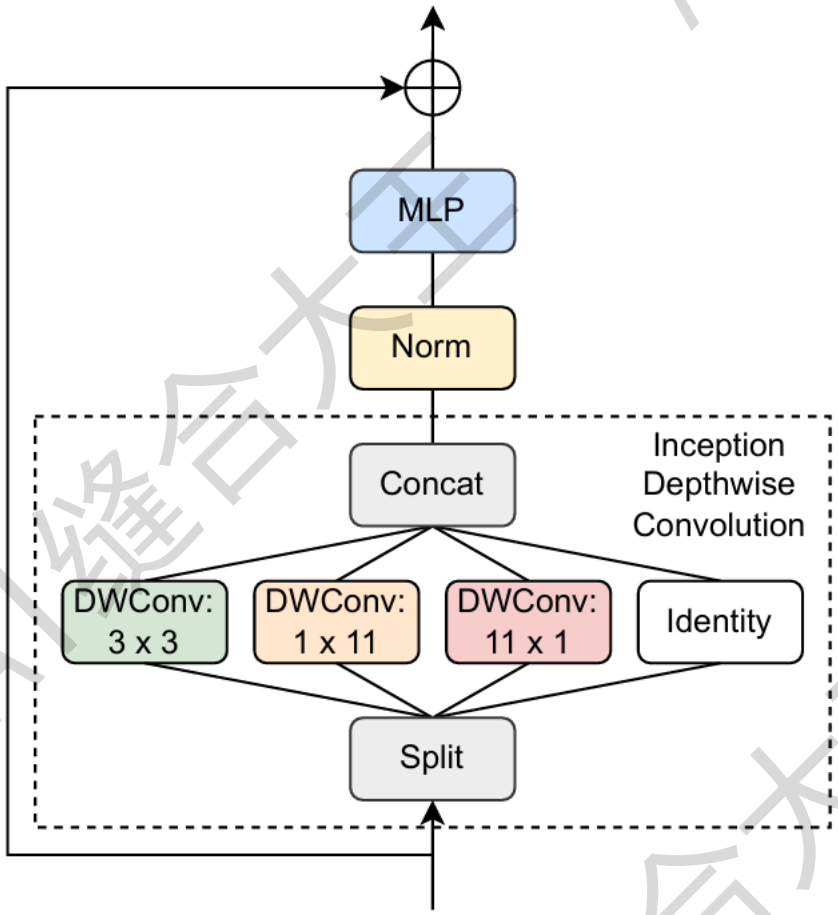

InceptionNeXt block

InceptionNeXt 作为即插即用模块，最适合用于 计算受限的 CNN 任务、混合 Transformer 任务、目标检测/分割等视觉任务。它的高计算效率 + 低计算开销 + 大感受野，使其能广泛应用于边缘计算、自动驾驶、医学影像分析等领域，作为ConvNeXt 的更优替代方案。

B站、小红书、微信公众号同步更新 @ai缝合大王