ai缝合交流Q群：994264161

CAS-ViT: Convolutional Additive Self-attention Vision Transformers for Efficient Mobile Applications

Tianfang Zhang, Lei Li, Yang Zhou, Wentao Liu, Chen Qian, Jenq-Neng Hwang, Xiangyang Ji, *Member, IEEE*

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

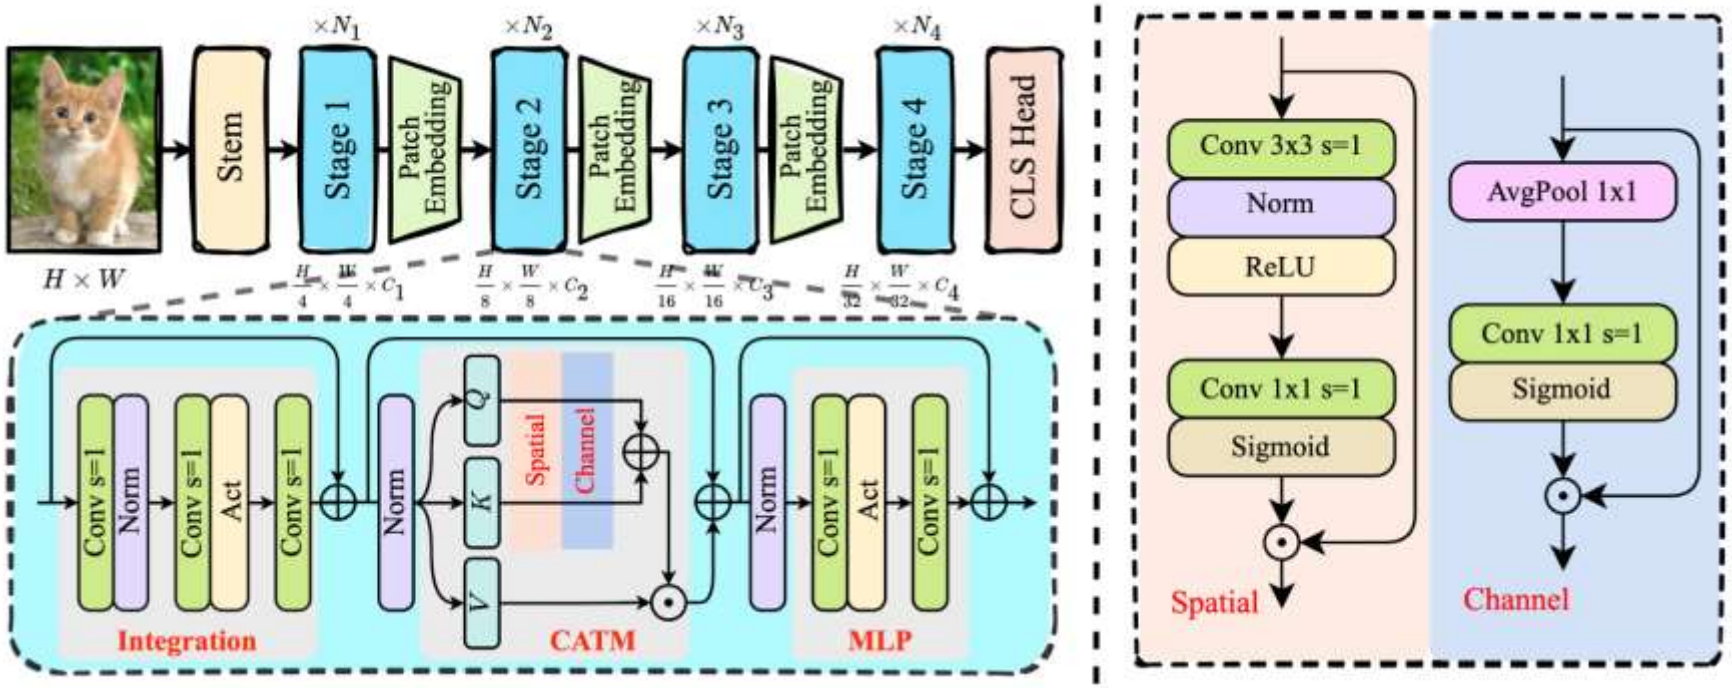

CAS-ViT 模型采用 四阶段（Four-stage） 设计架构，每个阶段包含多个 CAS块（Convolutional Additive Self-attention Block），用于特征提取和全局建模。网络首先通过 Stem模块（由两个3× 3卷积组成）进行初步特征提取和降采样，然后通过四个阶段的 CAS块 进行深度特征提取，并在每个阶段之间使用 Patch Embedding 进行特征下采样（2倍）。CAS块 内部包含 信息融合子网络（Integration Subnet）、卷积加性Token Mixer（CATM） 和 MLP模块，通过 卷积替代传统自注意力机制，减少计算开销，同时保持强大的全局感知能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

TABLE VII

ABLATION STUDY. WE REPLACE CATM WITH OTHER MODULES AND REPLACE SIMILARITY FUNCTION $\Phi(\cdot)$ WITH OTHER INTERACTIONS.

#	Similarity Function	Param.(M)	Flops(G)	Top-1(%)
1	**Base**	**12.4**	**1.88**	**80.43**
	$Sim(\mathbf{Q},\mathbf{K}) = \Phi(\mathbf{Q}) + \Phi(\mathbf{K})$			
2	$\Phi(\cdot) \rightarrow$ w/o spatial	12.4	1.86	79.98
3	$\Phi(\cdot) \rightarrow$ w/o channel	11.0	1.88	80.22
	$Sim(\mathbf{Q},\mathbf{K}) = \Phi(\mathbf{Q}) + \Psi(\mathbf{K})$			
4	$\Phi(\cdot) = \mathcal{S}(\cdot),\ \Psi(\cdot) = \mathcal{C}(\cdot)$	11.7	1.87	80.04
5	$\Phi(\cdot) = \mathcal{S}(\mathcal{C}(\cdot))\ \Psi(\cdot) = \mathcal{C}(\mathcal{S}(\cdot))$	12.4	1.88	80.40

说明信息交互的必要性：同时利用空间和通道信息能显著提升性能，并且加性计算方式能够避免高计算复杂度的矩阵运算，提升计算效率。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

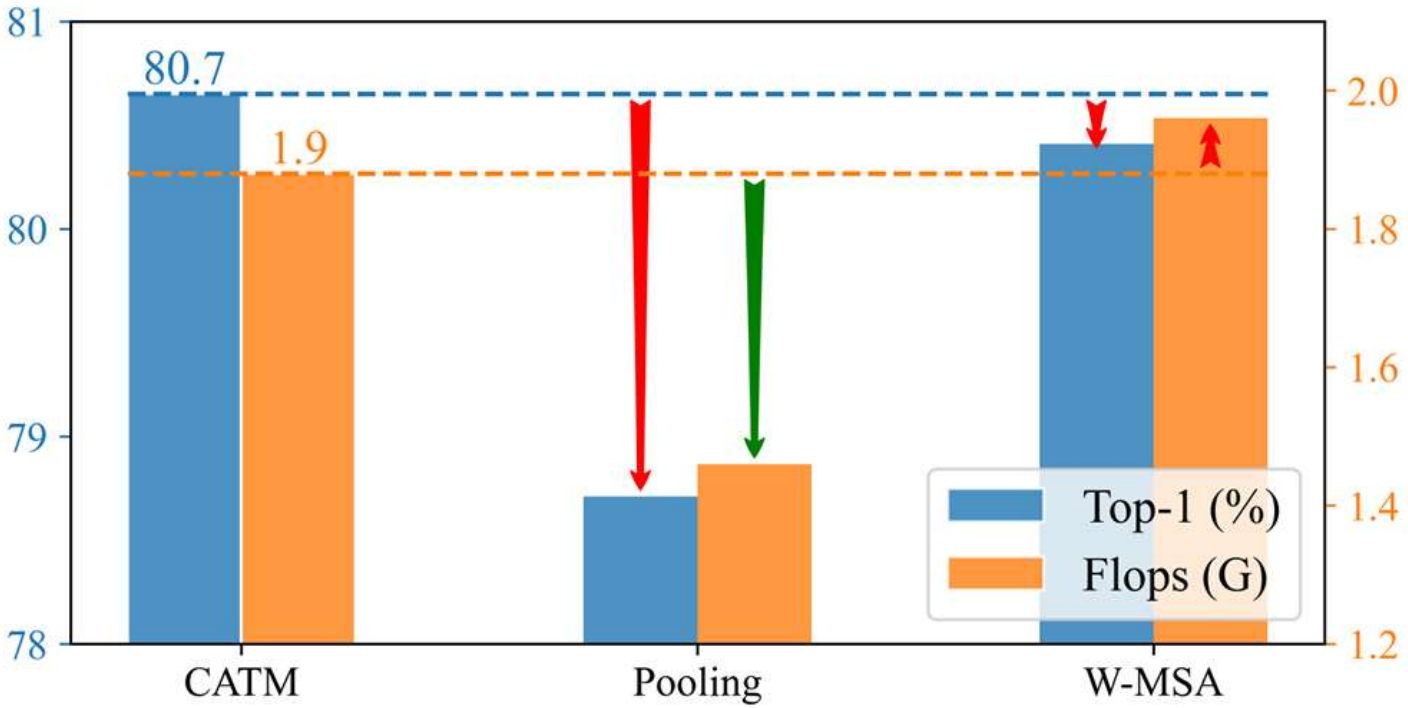

证明 CATM 的有效性：相比传统 Token Mixer（如 Pooling 和 Window-MSA），CAS-ViT 能在计算效率和准确率之间取得更好平衡。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

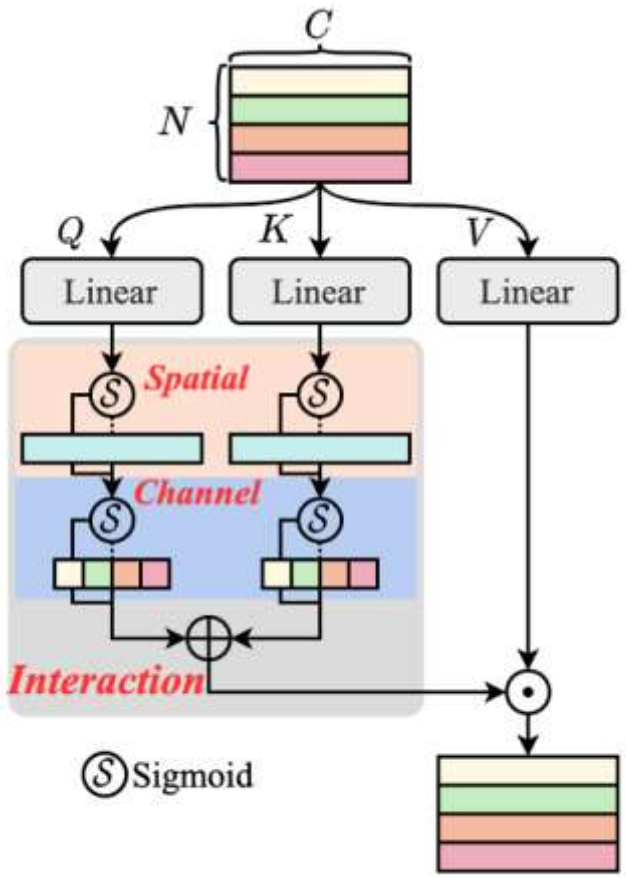

(d) Conv Additive Self-Attention

CAS 模块作为即插即用模块，主要适用于：移动端和边缘计算，减少计算开销，提高推理速度。实时应用，适用于自动驾驶、视频监控等需要高效推理的任务。多种计算机视觉任务（分类、检测、分割），提升模型的全局建模能力和鲁棒性。混合模型架构（CNN+Transformer），增强局部特征提取能力，同时保留全局信息建模能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

EfficientViM: Efficient Vision Mamba with Hidden State Mixer based State Space Duality

Sanghyeok Lee **Joonmyung Choi** **Hyunwoo J. Kim***

Department of Computer Science and Engineering, Korea University

{cat0626, pizard, hyunwoojkim}@korea.ac.kr

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

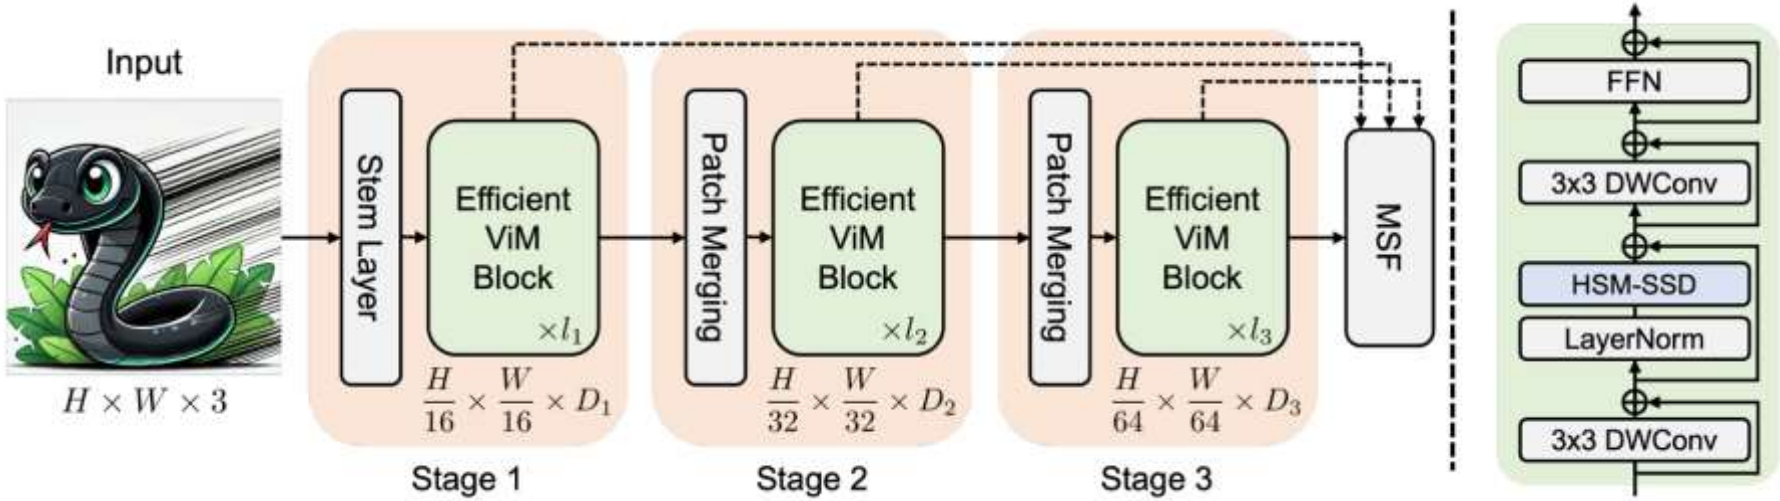

EfficientViM 是一种高效的视觉 Mamba 变体，采用 HSM-SSD（Hidden State Mixer-based SSD）进行全局 token 交互，并结合 多阶段隐藏状态融合（MSF） 提高表示能力。其整体架构包括 四层 3×3 卷积的 Stem 层、三个下采样阶段的主干网络（每阶段包含多个 EfficientViM 块），以及全局平均池化的分类头。每个 EfficientViM 块由 HSM-SSD 层和前馈网络（FFN） 组成，HSM-SSD 通过隐藏状态混合降低计算复杂度，而 FFN 结合 3×3 深度卷积增强局部特征提取。

B站、小红书、微信公众号同步更新　　@ai缝合大王

ai缝合交流Q群：994264161

Method	Thr.	Top-1	Params	FLOPs
(A) **EfficientViM-M2** (Base)	17,005	75.4	13.9M	355M
(B) **EfficientViM-M3**	11,952	77.5	16.6M	656M
a. Token Mixers (Base: HSM-SSD)				
(C) (→) NC-SSD [56]	9,786	76.2	13.0M	382M
(D) (→) Self-Attention [68]	13,038	76.1	13.6M	416M
b. Head designs (Base: Single-head with $\mathbf{A} \in \mathbb{R}^{L \times N}$*)*				
(E) (→) Multi-head	15,703	75.4	13.9M	352M
c. Multi-stage fusion				
(F) (→) None	17,317	75.1	13.0M	354M

这一表格展示了 EfficientViM 关键设计的影响，包括：

(A) EfficientViM-M2（基线模型）(B) EfficientViM-M3（更大模型）

(C) Token Mixer 选择：替换 HSM-SSD 为 NC-SSD（导致吞吐量下降）。替换 HSM-SSD 为 Self-Attention（计算量增加，吞吐量下降）。

(E) Head 设计：采用多头（Multi-head）设计会降低吞吐量，表明单头设计更高效。

(F) 多阶段融合：移除隐藏状态融合（MSF）会降低准确率，证明其有效性。

结论：HSM-SSD 优于 NC-SSD 和 Self-Attention，在吞吐量和精度上更有优势。单头 HSM-SSD 比多头更高效，减少了内存访问开销。多阶段融合（MSF）显著提高了模型准确率，但计算量几乎不变。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Method	Thr.	Top-1	Params	FLOPs
(A) **EfficientViM-M2** (Base)	17,005	75.4	13.9M	355M
(B) **EfficientViM-M3**	11,952	77.5	16.6M	656M
a. Token Mixers (Base: HSM-SSD)				
(C) (→) NC-SSD [56]	9,786	76.2	13.0M	382M
(D) (→) Self-Attention [68]	13,038	76.1	13.6M	416M
b. Head designs (Base: Single-head (SH) with $\mathbf{A} \in \mathbb{R}^{L \times N}$*)*				
(E) (→) Multi-head	15,703	75.5	13.9M	352M
(F) (→) SH w. $\mathbf{a} \in \mathbb{R}^{L}$	17,081	75.2	13.9M	352M
c. Multi-stage fusion (Base: $\mathbf{h}^{(s)}$*)*				
(G) (→) Fusion with $\mathbf{x}^{(s)}$	17,041	75.3	13.4M	355M
(H) (→) None	17,317	75.1	13.0M	354M
d. # states (N) of each stage (Base: $[49, 25, 9]$*)*				
(I) (→)$[9, 25, 49]$	16,476	75.4	14.0M	407M
(J) (→)$[25, 25, 25]$	16,991	75.2	13.9M	373M
e. Normalization (Base: Partial LN)				
(L) (→) Full BN	17,432	*NaN*	13.9M	355M

进一步分析不同组件对 EfficientViM 的影响：

结论：HSM-SSD 显著提升吞吐量，特别是在大模型上表现优越。单头比多头更高效，减少了额外计算。隐藏状态融合是提升准确率的关键。逐级减少隐藏状态数（N）更有效，比固定 N 方案表现更好。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

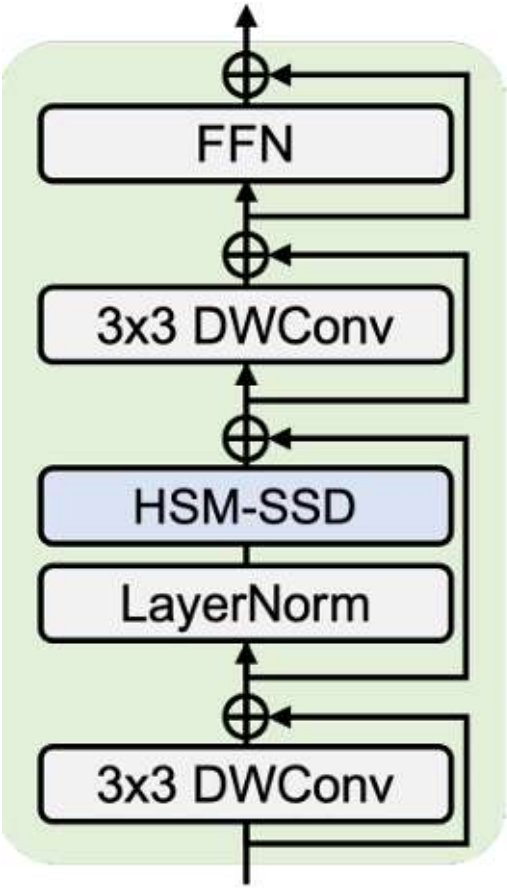

EfficientViM 作为即插即用模块，适用于 轻量级计算、目标检测、高分辨率图像处理、视频分析、多任务学习等场景，其主要作用包括：替换自注意力（Self-Attention）或 CNN 计算层，提供更高效的全局特征交互。增强多尺度特征融合，提升检测、分割等任务的效果。用于知识蒸馏 / 迁移学习，提高轻量级模型的泛化能力。提高高分辨率任务的计算效率，适用于医疗影像、遥感等领域。

B站、小红书、微信公众号同步更新 @ai缝合大王