ai缝合交流Q群：994264161

The Thirty-Eighth AAAI Conference on Artificial Intelligence (AAAI-24)

FFT-Based Dynamic Token Mixer for Vision

Yuki Tatsunami[1,2], **Masato Taki**[1]

[1]Rikkyo University
[2]AnyTech Co., Ltd.
y.tatsunami@rikkyo.ac.jp, taki_m@rikkyo.ac.jp

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

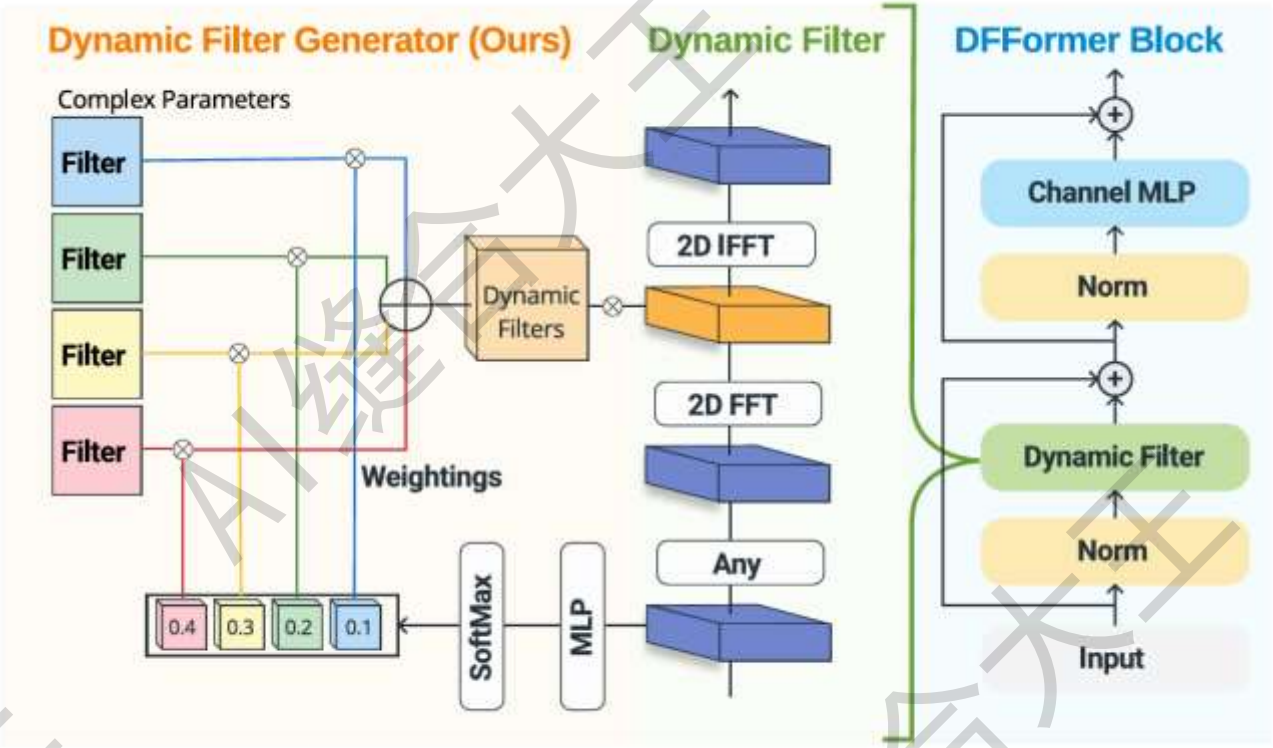

DFFormer 和 CDFFormer 模型基于 MetaFormer 框架，采用四阶段（four-stage）架构，每个阶段包含多个 DFFormer 或 CDFFormer Block，其中 DFFormer Block 采用动态滤波器（Dynamic Filter）作为 Token Mixer，而 CDFFormer Block 则结合了卷积（Conv）和动态滤波器（DF）。整个模型结构包括一个初始卷积层用于特征提取，随后通过四个阶段逐步增加通道数和特征尺度，最终通过全局平均池化（GAP）和MLP 分类头完成分类任务。CDFFormer 通过混合卷积和 FFT 进一步提升计算效率，使其在高分辨率图像任务上更具优势。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Ablation	Variant	Parameters (M)	FLOPs (G)	Throughput (img/sec)	Top-1 Acc. (%)
Baseline	DFFormer-S18	30	3.8	535	83.2
Filter	$N = 4 \rightarrow 2$	29	3.8	534	83.0
	$\rho = 0.25 \rightarrow 0.125$	28	3.8	532	83.1
	GFFormer-S18	30	3.8	575	82.9
	DF $\rightarrow$ AFNO	30	3.8	389	82.6
Activation	StarReLU $\rightarrow$ GELU	30	3.8	672	82.7
	StarReLU $\rightarrow$ ReLU	30	3.8	640	82.5
	StarReLU, DF$\rightarrow$ ReLU, AFNO	30	3.8	444	82.0

Table 4: Ablation for DFFormer-S18 on ImageNet-1K. Remind N is the dimension of the dynamic filter basis, and ρ is a ratio of MLP intermediate dimension to input dimension.

验证了 动态滤波器（Dynamic Filter）比静态滤波器和 AFNO 更有效，并且 StarReLU 是最佳激活函数。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

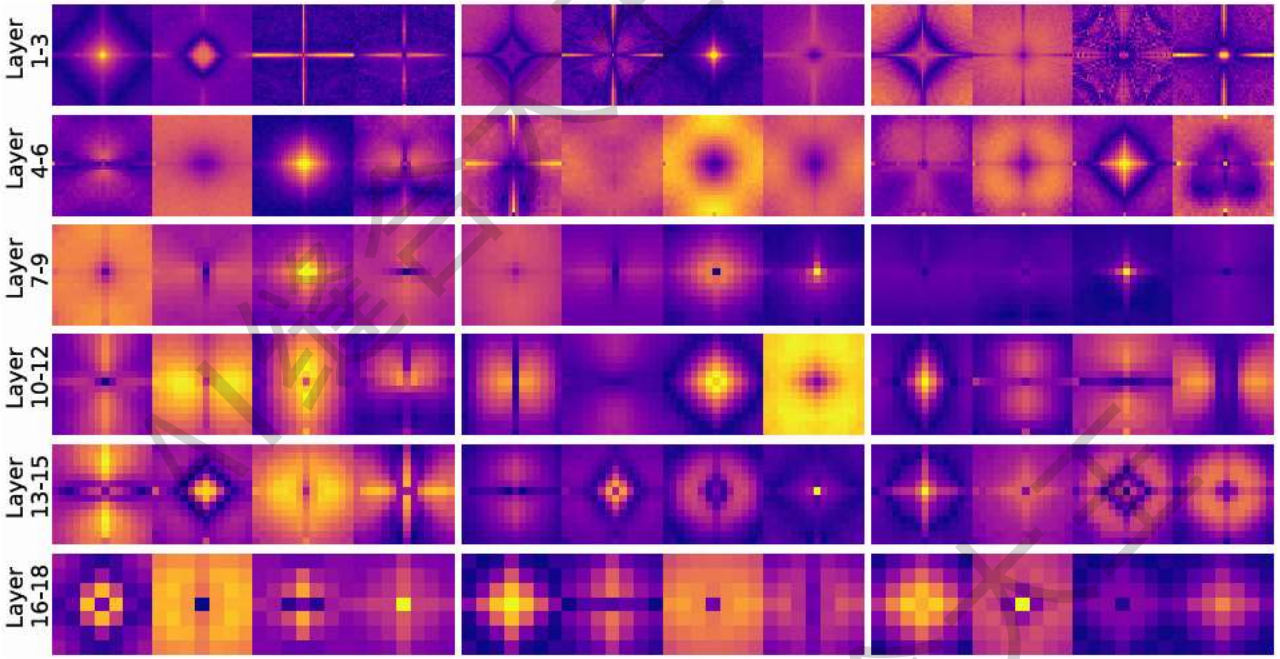

Figure 9: Filters in the frequency domain on DFFormer-S18

不同层的动态滤波器可以学习不同的频率特征，如高通、低通和带通滤波器，说明动态滤波器能够根据数据自适应调整滤波特性，而不像传统 MHSA 只能基于固定的注意力机制。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

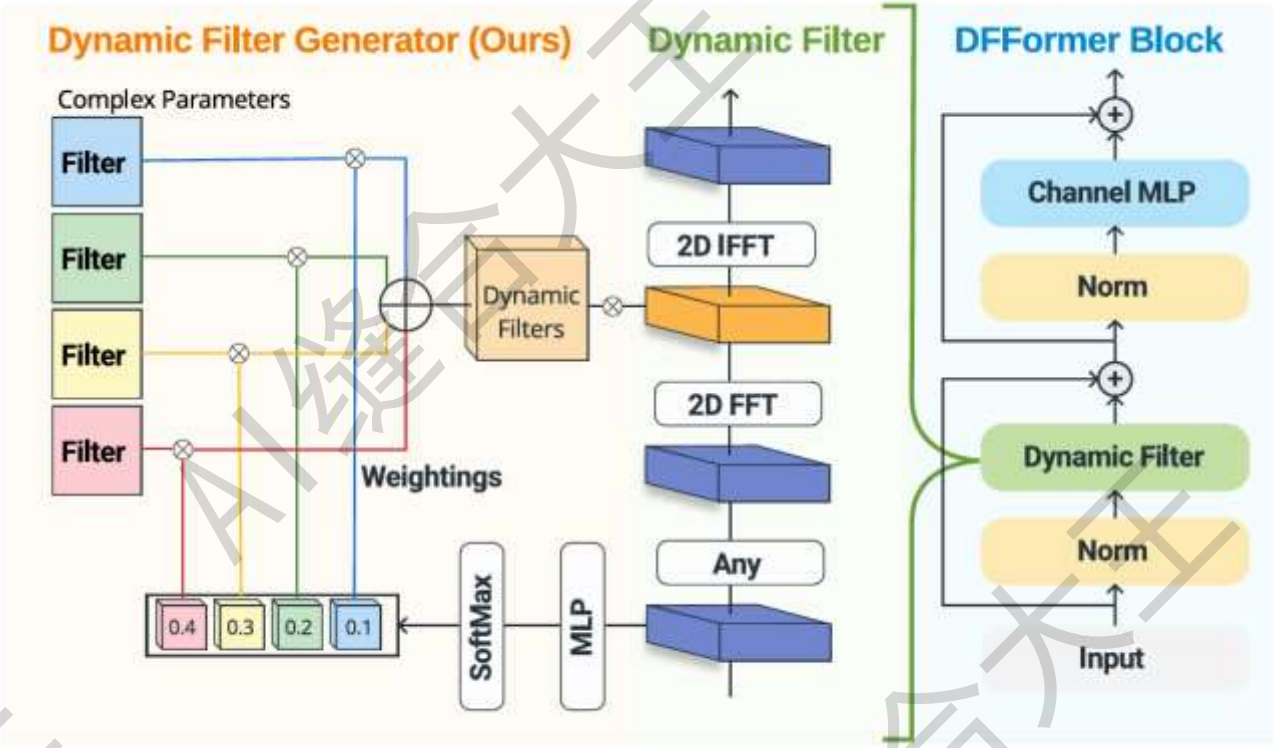

Dynamic Filter 作为可即插即用的模块，主要适用于：高分辨率计算机视觉任务（医学影像、遥感、语义分割）、计算受限设备（边缘 AI、移动设备、自动驾驶）、作为 Transformer Token Mixer 替代 MHSA、与 CNN 结合，增强全局信息建模、应用于 3D 视觉和时序任务

它的主要作用是：降低计算复杂度，相比 MHSA 更高效保持全局信息交互能力，适用于高分辨率任务减少显存占用，适合嵌入式和移动 AI结合 CNN 提供更优的局部+全局特征融合

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Mesoscopic Insights: Orchestrating Multi-scale & Hybrid Architecture for Image Manipulation Localization

Xuekang Zhu[1,2*], Xiaochen Ma[3*], Lei Su[1,2], Zhuohang Jiang[4], Bo Du[1,2], Xiwen Wang[1,2], Zeyu Lei[1,2], Wentao Feng[1,2], Chi-Man Pun[5], Jizhe Zhou[1,2†]

[1]College of Computer Science, Sichuan University
[2]Engineering Research Center of Machine Learning and Industry Intelligence, Ministry of Education of China
[3]Mohamed Bin Zayed University of Artificial Intelligence
[4]The Hong Kong Polytechnic University
[5]Computer and Information Science, Faculty of Science and Technology, University of Macau

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

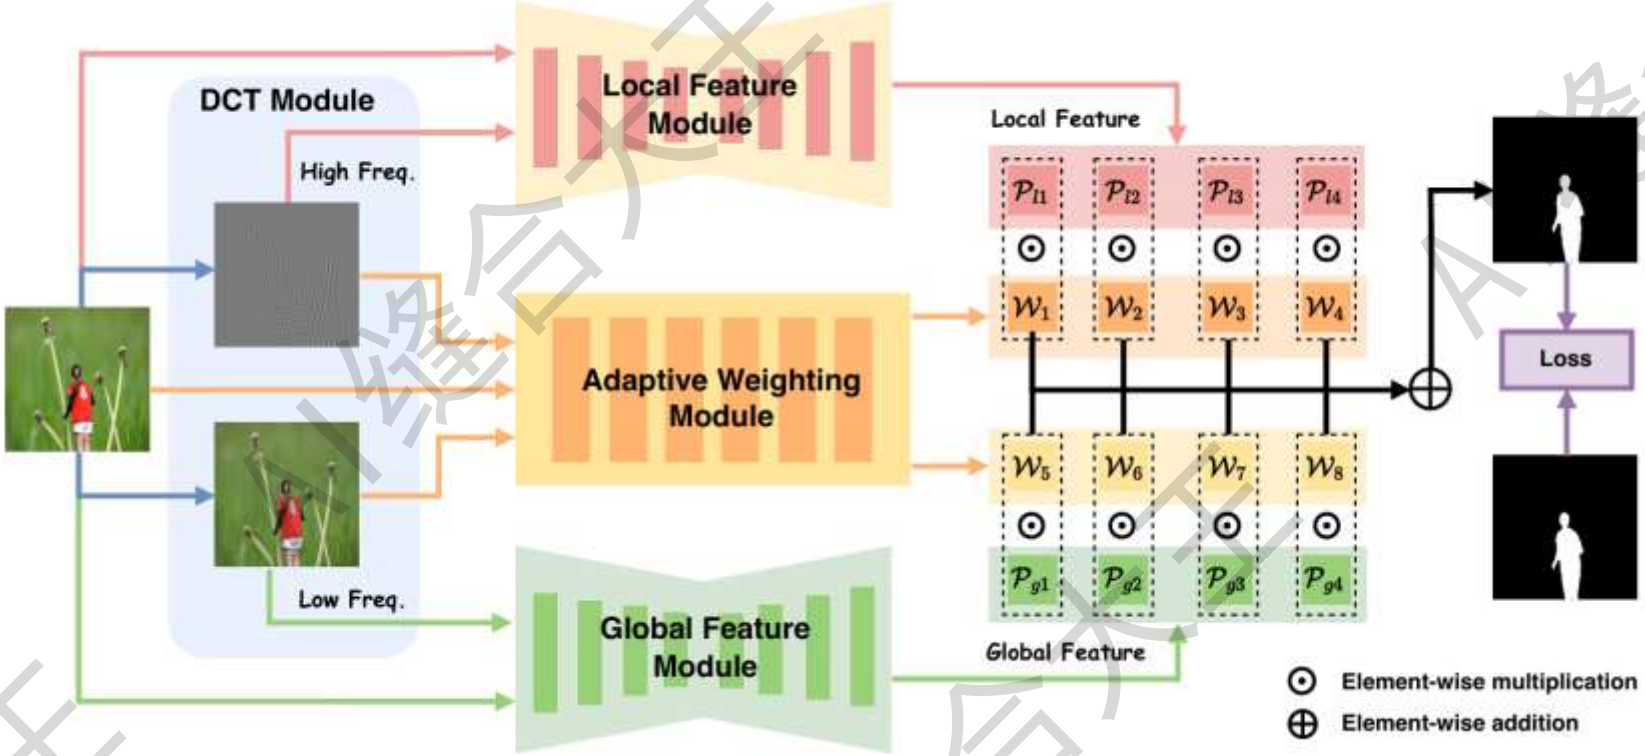

该Mesorch（Mesoscopic-Orchestration）架构 采用 并行混合 方式结合 CNN 和 Transformer， 以有效融合微观（低级特征）和宏观（高级语义）信息，从而更精准地定位图像篡改区域。模型首先通过 DCT（离散余弦变换） 分解输入图像的高频和低频信息，并分别输入到 局部特征编码器（CNN 处理高频特征） 和 全局特征编码器（Transformer 处理低频特征）。在解码阶段，模型采用 多尺度解码 生成篡改区域预测，同时通过 自适应加权模块 赋予不同尺度特征不同权重，优化篡改区域的检测精度。最终，经过尺度加权融合和剪枝优化，模型在保持高精度的同时显著降低计算复杂度，实现了对图像篡改区域的高效检测和定位。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 4: Independent Evaluation. "Avg.F1" represents the average F1 score across four datasets.

Model	Multi.	Weighting	Extractor	Prune	Avg.F1
CNN	×	×	×	×	0.5610
	✓	×	×	×	0.6031
Transformer	×	×	×	×	0.5723
	✓	×	×	×	0.6096
CNN+Trans.	×	×	×	×	0.6422
	✓	×	×	×	0.6501
	✓	×	✓	×	0.6612
	✓	✓	×	×	0.6653
	✓	✓	✓	×	0.6771
	✓	–	✓	✓	0.6762

主要分析不同模块的作用，逐步添加关键组件，观察其对 F1 分数的影响。
主要结论：仅使用 CNN 或 Transformer 的基线模型（0.5610/0.5723）性能较低。添加多尺度处理（Multi）后，F1 得分提升，说明多尺度特征有助于提升篡改检测能力。DCT 特征提取进一步提高 F1 分数（0.6771），表明高频和低频特征能增强篡改区域的辨别能力。自适应权重（Weighting）有助于优化多尺度特征利用，使 F1 分数提升到 0.6653。剪枝（Prune）显著降低计算量，且性能仅小幅下降（0.6771 → 0.6762），表明剪枝对性能影响有限，但能大幅提升效率。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 5: The performance of the same module uses different backbones. "Avg.F1" stands for "Average F1," representing the mean value of the standard F1 score across four datasets.

CNN	Transformer	Avg.F1
ConvNeXt	MAE	0.6215
	PVT	0.6704
	Segformer	0.6771
	Swin	0.6089
Resnet	MAE	0.6327
	PVT	0.6496
	Segformer	0.6615
	Swin	0.6022

主要分析不同 CNN 和 Transformer 组合对 F1 分数的影响，验证最佳的主干网络组合。

主要结论：采用 ConvNeXt + Segformer 组合的 F1 得分最高（0.6771），说明这种结构能更好地捕获微观与宏观信息。Swin Transformer 组合效果最差，可能是由于 Swin 偏向全局特征提取，导致对篡改细节的检测能力下降。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 9: Ablation Study on CNN and Transformer Architectures with High-Frequency and Low-Frequency DCT Features

CNN	Trans.	Columbia	NIST16	Coverage	CASIAv1	Avg.F1
High	Low	0.8903	0.3921	0.5862	0.8398	**0.6771**
High	High	0.9191	0.3417	0.5245	0.8493	0.6587
Low	High	0.9049	0.3812	0.5544	0.8356	0.6690
Low	Low	0.8889	0.3448	0.4867	0.8305	0.6377

主要分析 CNN 和 Transformer 处理高频/低频特征的影响。

主要结论：CNN 处理高频 + Transformer 处理低频的组合效果最好（0.6771），说明 CNN 在高频特征（篡改痕迹）检测方面更擅长，而 Transformer 适合处理低频特征（全局语义）。高频+高频组合 F1 下降，可能是由于缺乏全局信息导致误检增加。低频+低频组合效果最差（0.6377），说明低频特征不足以单独检测篡改区域。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

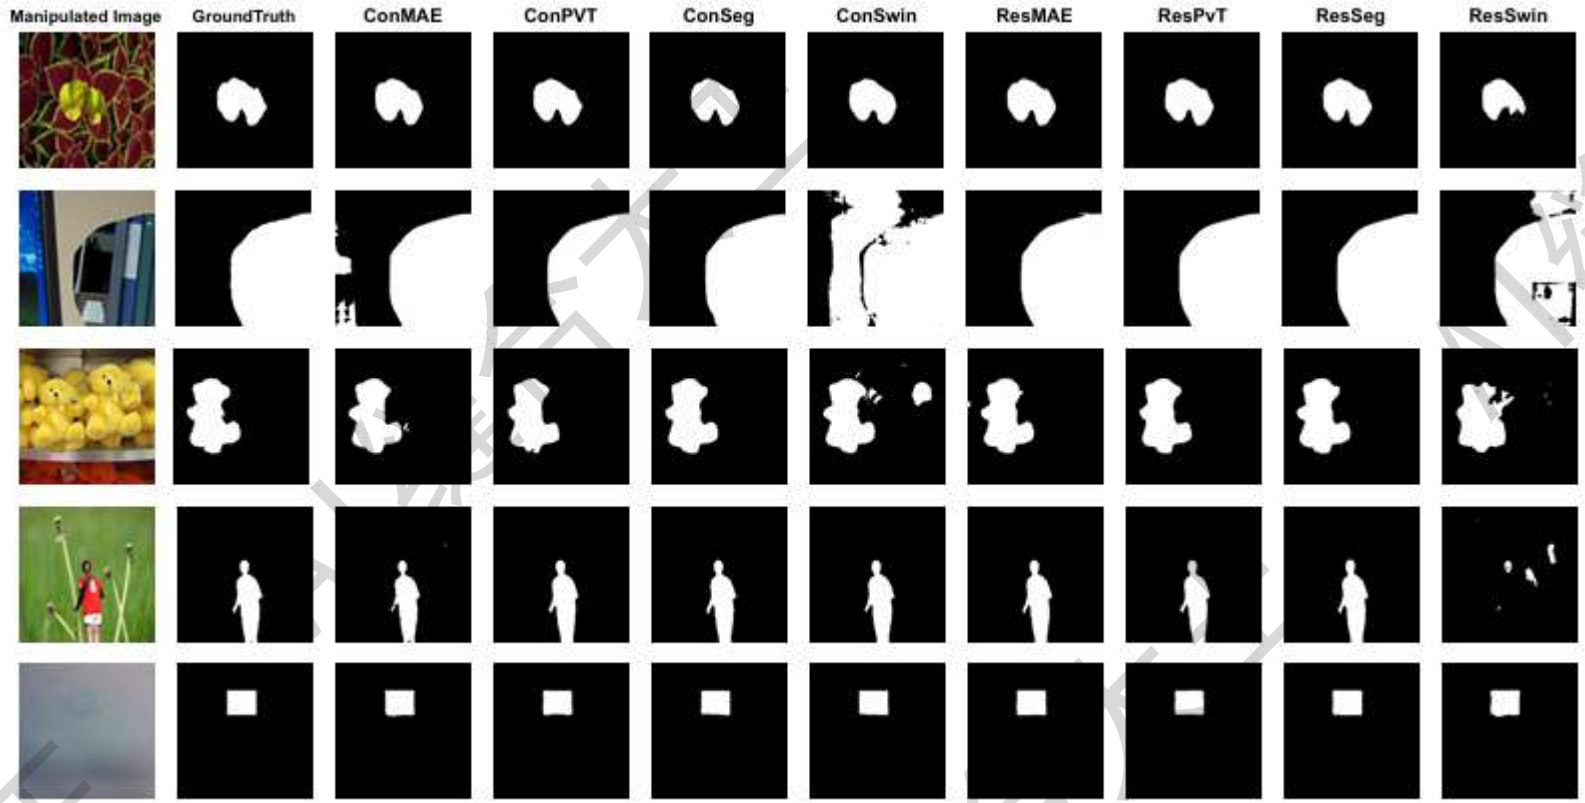

展示了不同 CNN 和 Transformer 组合在篡改区域检测任务上的可视化结果。

主要结论：ConvNeXt + Segformer 组合（Mesorch）在检测细节和整体边界上表现最佳。其他组合（如 ResNet + Swin）在某些情况下会漏检或边界模糊，说明它们在中观特征提取方面不如最佳组合。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

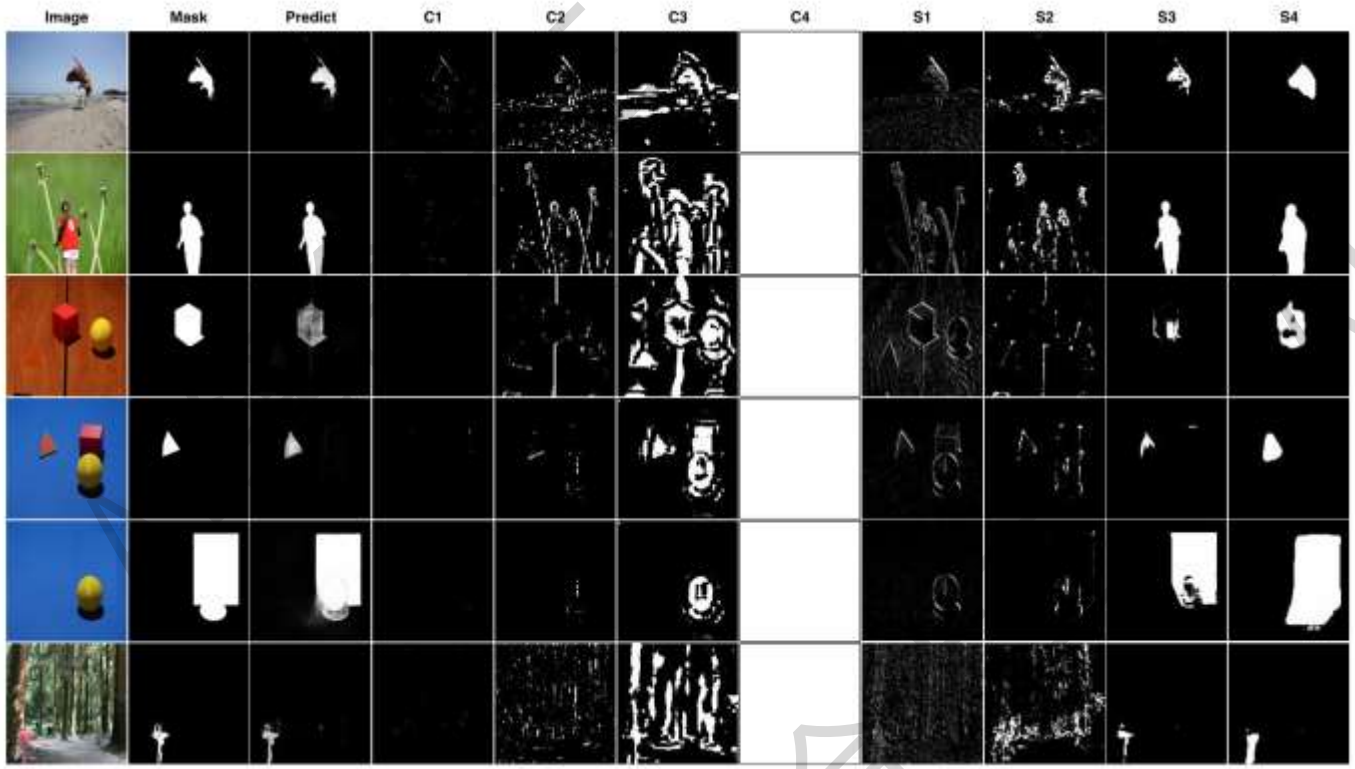

对比了 CNN 和 Transformer 在不同尺度上的特征表示方式，展示它们的互补性。
主要结论：CNN 在浅层（C1、C2）能提取更多 局部细节（微观特征），但在深层（C3、C4）会丢失全局结构。Transformer 在所有层（S1-S4）都能保持 宏观结构完整性，但缺乏细节特征。这解释了为什么 Mesorch 采用 CNN 处理高频（微观）、Transformer 处理低频（宏观）能获得最佳结果。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

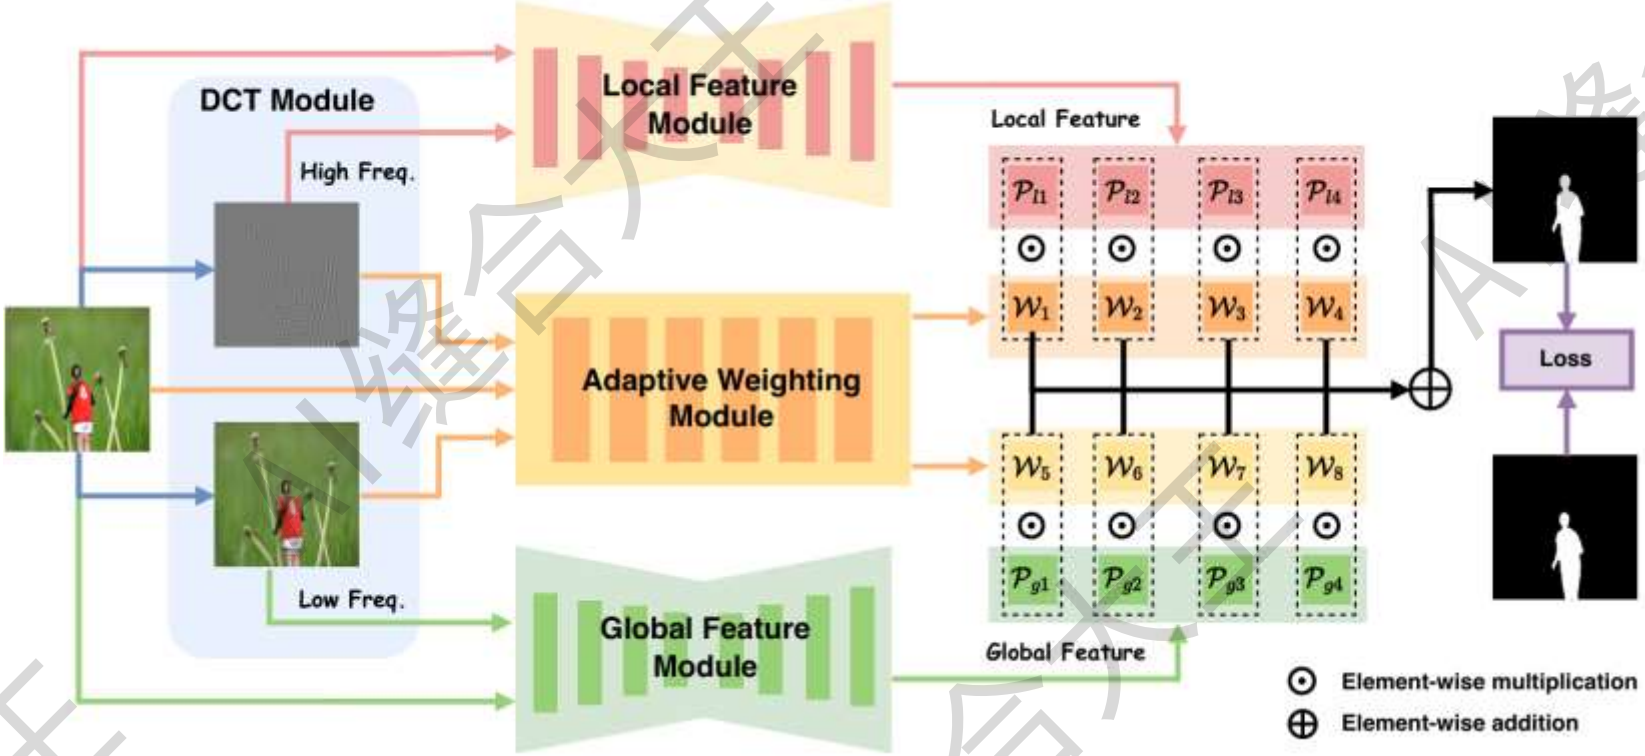

LowDctFrequencyExtractor 作为一个 即插即用模块，适用于 深度伪造检测、对象级篡改检测、高压缩图像篡改分析，以及对抗攻击鲁棒性增强 的场景。它的核心作用是 提供低频全局特征，提高模型在不同质量图像下的检测能力，同时增强 CNN 和 Transformer 结合的效率和稳定性。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

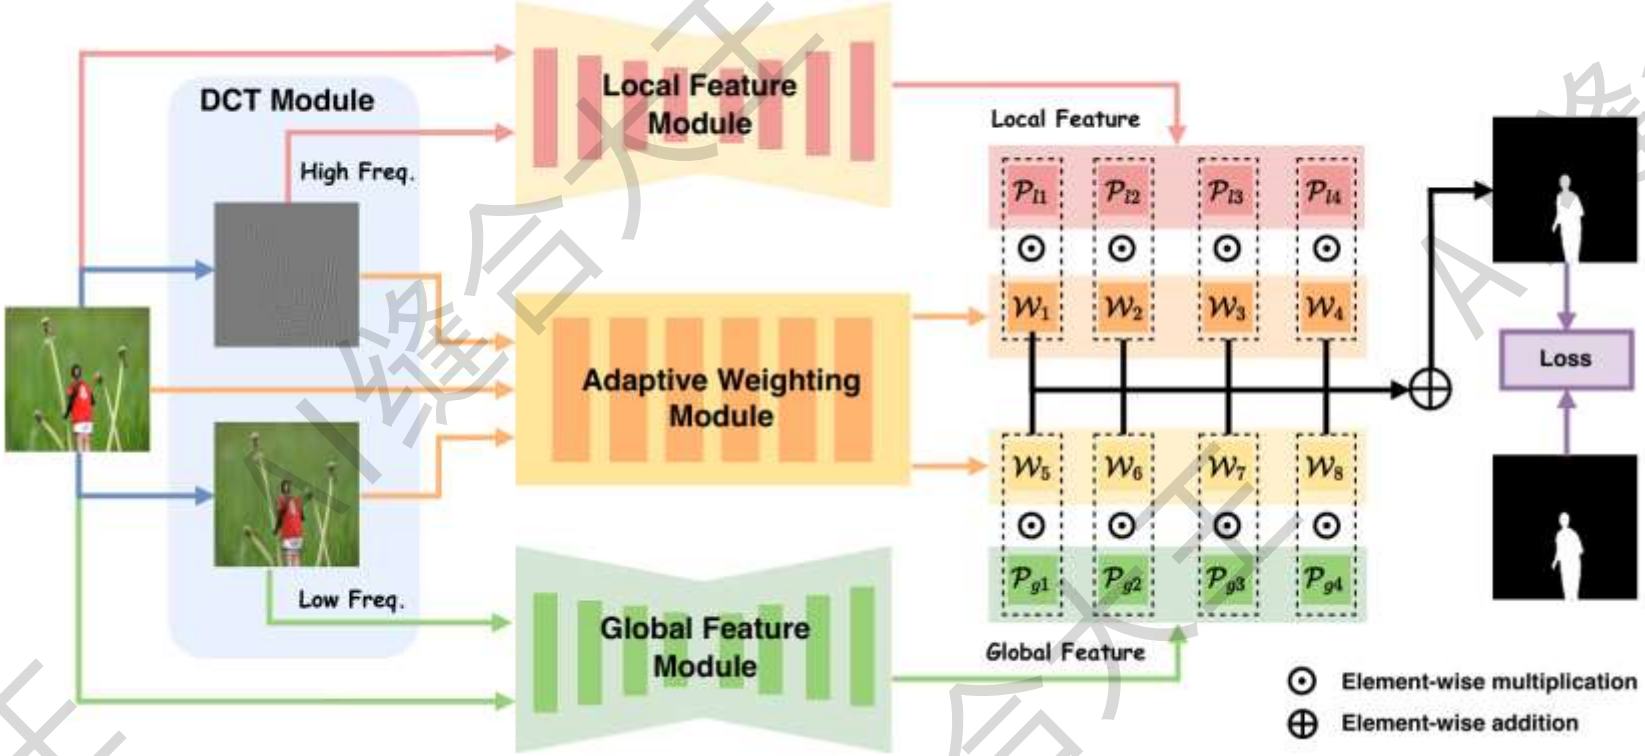

HighDctFrequencyExtractor 适用于微观级篡改检测任务，包括篡改痕迹检测、JPEG 伪造、AI 生成图像分析和对抗攻击检测。它的核心作用是：提供高频特征，增强 CNN 处理篡改伪影和边缘异常的能力；提高对微小篡改区域的识别精度，提高模型的细节检测能力；增强模型在 JPEG 压缩、噪声干扰等复杂环境下的鲁棒性。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

QUANTIZED SPIKE-DRIVEN TRANSFORMER

Xuerui Qiu[1,2,3], **Malu Zhang**[1,*], **Jieyuan Zhang**[1], **Wenjie Wei**[1], **Honglin Cao**[1], **Junsheng Guo**[4], **Rui-Jie Zhu**[5], **Yimeng Shan**[6], **Yang Yang**[1], **Haizhou Li**[7]

[1]University of Electronic Science and Technology of China,
[2]Institute of Automation, Chinese Academy of Sciences,
[3]School of Future Technology, University of Chinese Academy of Sciences,
[4]China Agricultural University, [5]University of California, Santa Cruz,
[6]Liaoning Technical University, [7]Chinese University of Hong Kong (Shenzhen)

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

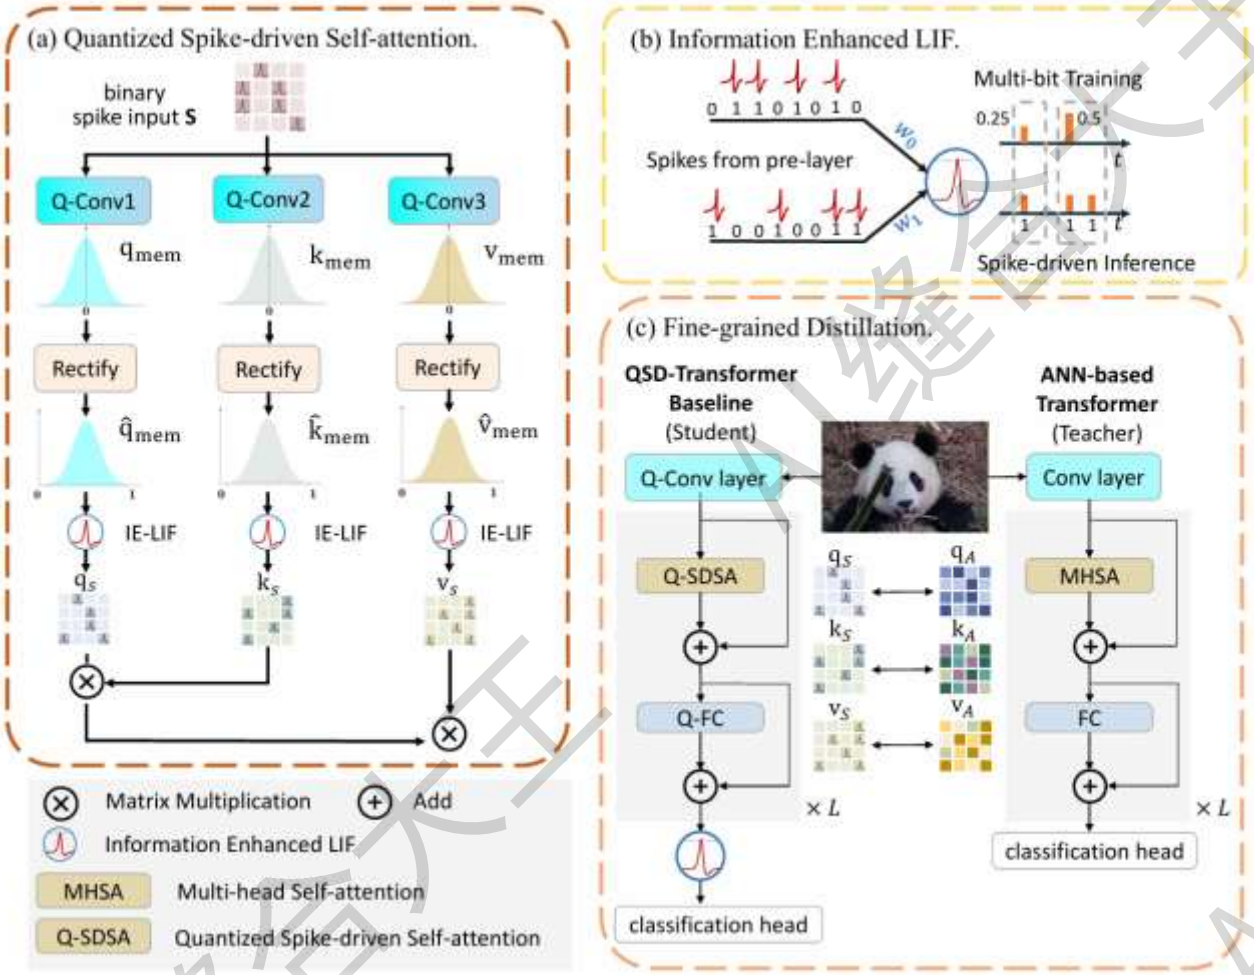

这篇论文提出的 QSD-Transformer 是一种轻量级、能效优化的 量化脉冲驱动Transformer，其整体结构由以下关键模块组成：

1、量化脉冲驱动自注意力（Q-SDSA）：该模块基于Transformer的自注意力机制，但采用脉冲神经网络（SNN）实现，并对权重和激活值进行低比特量化，以减少计算开销和功耗。

2、信息增强LIF（IE-LIF）神经元：在训练过程中，该神经元使用多位（multi-bit）脉冲进行信息增强，而在推理时保持二值化脉冲，以提高信息表达能力并减少量化损失。

3、精细蒸馏（FGD）机制：通过蒸馏学习，使Q-SDSA中的信息分布与标准ANN Transformer的自注意力机制对齐，以减少因量化带来的信息扭曲（SID）问题，提高模型性能。

整个模型在推理时仍然遵循 脉冲驱动计算 方式，仅使用 低比特量化权重和二值化脉冲活动 进行高效计算，从而实现了高精度、低功耗、轻量级的Transformer架构，适用于资源受限的硬件环境，如边缘计算和神经形态芯片。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 5: Ablation study of the IE-LIF, FGD, and different bits.

Architecture	IE-LIF	FGD	Weight Bits	Acc.(%)
SD-Transformer v2 (Yao et al., 2023a)	-	-	4	70.0
	✓	-	4	75.8
	✓	✓	4	**77.5**
	✓	✓	3	76.9
	✓	✓	2	75.0
Spikformer (Zhou et al., 2023b)	-	-	4	64.1
	✓	-	4	70.1
	✓	✓	4	**75.5**
	✓	✓	3	74.1
	✓	✓	2	73.1

研究内容：分析信息增强LIF（IE-LIF）神经元、精细蒸馏（FGD）策略以及不同权重量化比特数对模型性能的影响。

结论：证明了 IE-LIF 神经元和 FGD 策略都可以提升性能，且两者结合效果更好。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 6: Ablation study of the activity bits and training time step on the QSD-Transformer.

Bits (b)	Timestep (T)	Acc.(%)
1	1	67.6
1	2	68.5
1	4	70.0
2	1	71.6
2	2	77.4
4	1	**77.5**

研究内容：探讨不同活动位数（b）和训练时间步长（T）对模型准确率的影响。

结论：量化SNN模型的性能更依赖于活动位数b，而不是时间步长T，这意味着即使使用较少的时间步长，也能通过适当的量化策略提高性能。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

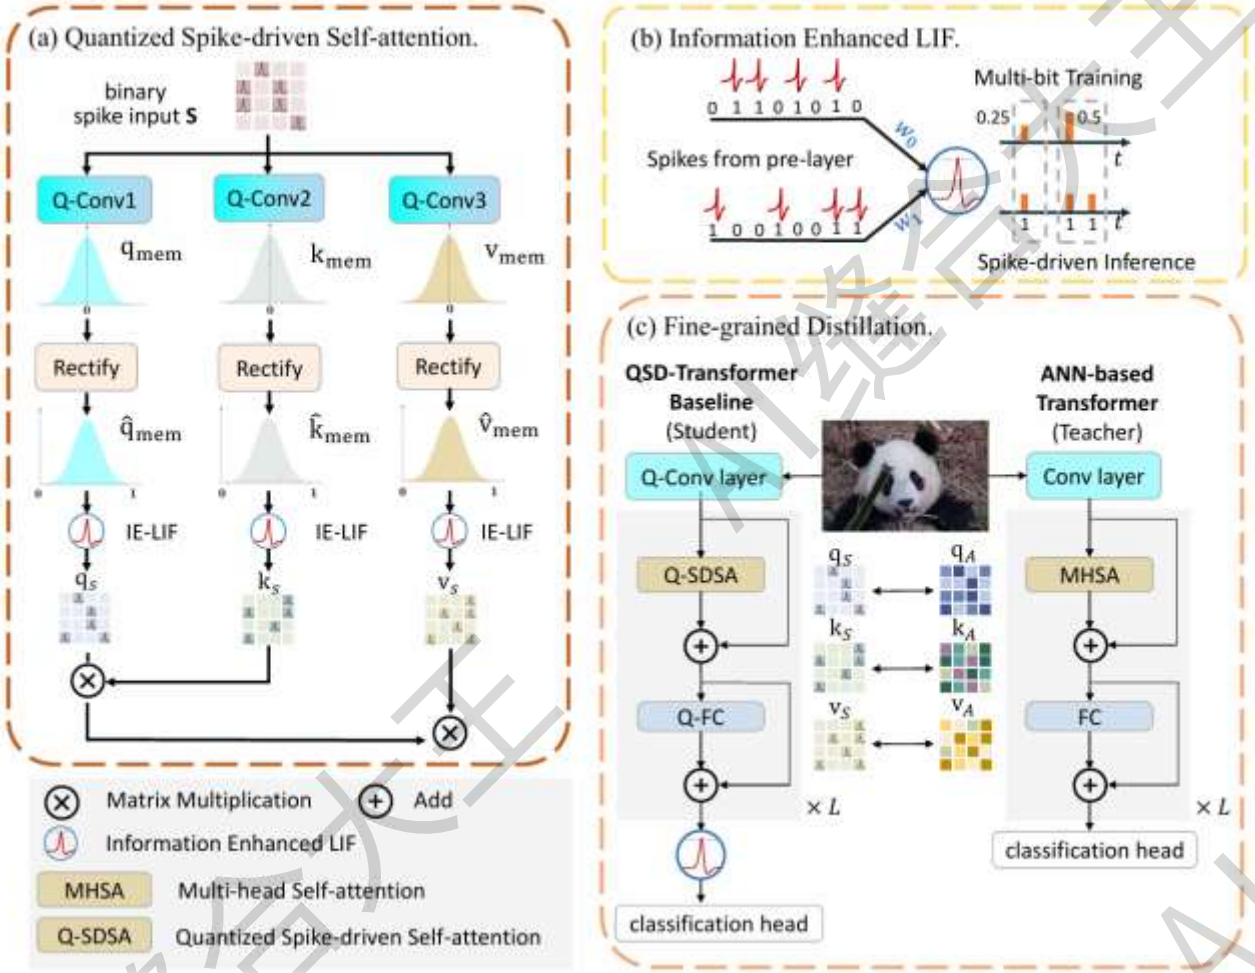

QSD-Transformer 作为即插即用的低功耗 Transformer模块，最适合 边缘计算、神经形态计算、可穿戴设备、自动驾驶、工业检测等应用，可显著减少计算资源消耗、降低功耗，同时保持高性能，推动 Transformer 在资源受限设备中的实际应用。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

Modality-agnostic Domain Generalizable Medical Image Segmentation by Multi-Frequency in Multi-Scale Attention

Ju-Hyeon Nam[1] Nur Suriza Syazwany[1] Su Jung Kim[1] Sang-Chul Lee[1,2]
Department of Electrical and Computer Engineering, Inha University[1], DeepCardio[2]
{jhnam0514, surizasyazwany, sk2266}@inha.edu sclee@{inha.ac.kr, deepcardio.com}

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

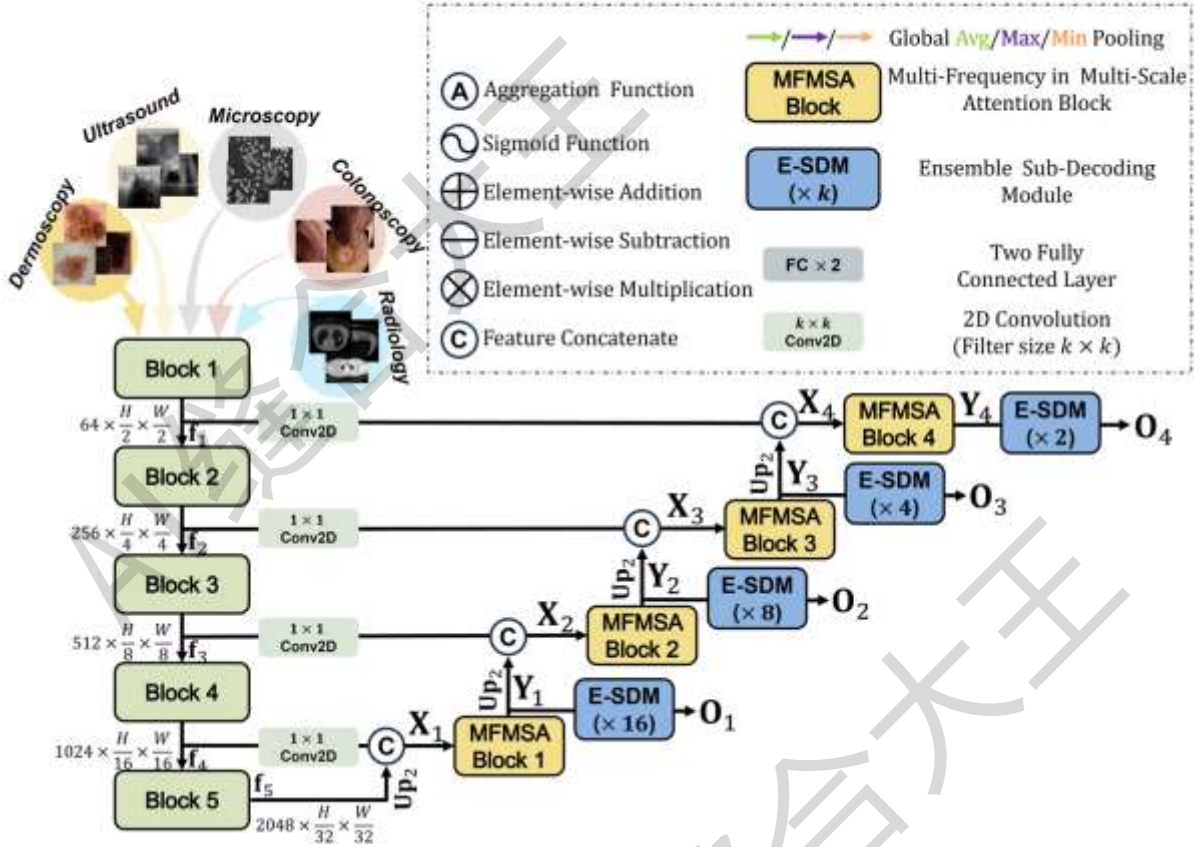

MADGNet 主要由 多频率与多尺度注意力（MFMSA）模块 和 Ensemble Sub-Decoding Module（E-SDM） 组成。模型采用 ResNeSt 作为编码器 提取特征， 随后通过 MFMSA 模块 在不同尺度和频率上提取判别性特征， 提高对边界信息和解剖结构的敏感度。在解码过程中， 采用 E-SDM 以级联方式整合子任务预测（区域、边界、距离映射）， 防止信息丢失并增强深度监督的效果。整个架构旨在提高医学图像分割的模态无关性（Modality-agnostic） 和 领域泛化能力（Domain Generalizability）， 使其在不同影像模态和临床环境下都能实现高精度分割。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Method	Dermoscopy		Radiology		Ultrasound		Microscopy		Colonoscopy				*P*-value
	ISIC2018 [23]		COVID19-1 [33]		BUSI [3]		DSB2018 [6]		CVC-ClinicDB [5]		Kvasir [31]		
	DSC	mIoU	DSC	mIoU	DSC	mIoU	DSC	mIoU	DSC	mIoU	DSC	mIoU	
UNet [52]	87.3 (0.8)	80.2 (0.7)	47.7 (0.6)	38.6 (0.6)	69.5 (0.3)	60.2 (0.2)	91.1 (0.2)	84.3 (0.3)	76.5 (0.8)	69.1 (0.9)	80.5 (0.3)	72.6 (0.4)	5.2E-06
AttUNet [45]	87.8 (0.1)	80.5 (0.1)	57.5 (0.2)	48.4 (0.2)	71.3 (0.4)	62.3 (0.6)	91.6 (0.1)	85.0 (0.1)	80.1 (0.6)	74.2 (0.5)	83.9 (0.1)	77.1 (0.1)	4.1E-06
UNet++ [74]	87.3 (0.2)	80.2 (0.1)	65.6 (0.7)	57.1 (0.8)	72.4 (0.1)	62.5 (0.2)	91.6 (0.1)	85.0 (0.1)	79.7 (0.2)	73.6 (0.4)	84.3 (0.3)	77.4 (0.2)	7.5E-07
CENet [22]	89.1 (0.2)	82.1 (0.1)	76.3 (0.4)	69.2 (0.5)	79.7 (0.6)	71.5 (0.5)	91.3 (0.1)	84.6 (0.1)	89.3 (0.3)	83.4 (0.2)	89.5 (0.7)	83.9 (0.7)	1.0E-05
TransUNet [7]	87.3 (0.2)	81.2 (0.8)	75.6 (0.4)	68.8 (0.2)	75.5 (0.5)	68.4 (0.1)	91.8 (0.3)	85.2 (0.2)	87.4 (0.2)	82.9 (0.1)	86.4 (0.4)	81.3 (0.4)	9.9E-08
FRCUNet [4]	88.9 (0.1)	83.1 (0.2)	77.3 (0.3)	70.4 (0.2)	***81.2*** (0.2)	***73.3*** (0.3)	90.8 (0.3)	83.8 (0.4)	91.8 (0.2)	87.0 (0.2)	88.8 (0.4)	83.5 (0.6)	6.6E-02
MSRFNet [57]	88.2 (0.2)	81.3 (0.2)	75.2 (0.4)	68.0 (0.4)	76.6 (0.7)	68.1 (0.7)	***91.9*** (0.1)	***85.3*** (0.1)	83.2 (0.9)	76.5 (1.1)	86.1 (0.5)	79.3 (0.4)	8.8E-07
HiFormer [26]	88.7 (0.5)	81.9 (0.5)	72.9 (1.4)	63.3 (1.5)	79.3 (0.2)	70.8 (0.1)	90.7 (0.2)	83.8 (0.4)	89.1 (0.6)	83.7 (0.6)	88.1 (1.0)	82.3 (1.2)	1.8E-05
DCSAUNet [67]	89.0 (0.3)	82.0 (0.3)	75.3 (0.4)	68.2 (0.4)	73.7 (0.5)	65.0 (0.5)	91.1 (0.2)	84.4 (0.2)	80.5 (1.2)	73.7 (1.1)	82.6 (0.5)	75.2 (0.5)	6.2E-07
M2SNet [73]	***89.2*** (0.2)	***83.4*** (0.2)	***81.7*** (0.4)	***74.7*** (0.5)	80.4 (0.8)	72.5 (0.7)	91.6 (0.2)	85.1 (0.3)	***92.8*** (0.8)	***88.2*** (0.8)	***90.2*** (0.5)	***85.1*** (0.6)	2.0E-05
SFSSNet	88.8 (0.3)	81.9 (0.2)	80.3 (0.8)	73.0 (0.7)	66.1 (0.6)	59.3 (0.8)	91.5 (0.2)	84.0 (0.2)	90.7 (0.4)	83.0 (0.7)	88.1 (0.6)	82.2 (0.7)	2.2E-06
MFSSNet	88.5 (0.2)	81.8 (0.2)	80.4 (0.7)	73.1 (0.4)	81.0 (0.1)	73.2 (0.2)	91.6 (0.1)	85.1 (0.2)	92.3 (0.5)	87.7 (0.5)	89.9 (0.6)	84.7 (0.7)	5.1E-07
SFMSNet	89.2 (0.3)	82.5 (0.3)	81.4 (0.3)	74.5 (0.3)	80.8 (0.4)	73.0 (0.3)	91.5 (0.2)	84.9 (0.4)	92.3 (0.3)	88.0 (0.3)	89.0 (0.6)	84.1 (0.5)	1.4E-04
MADGNet	**90.2** (0.1)	**83.7** (0.2)	**83.7** (0.2)	**76.8** (0.2)	**81.3** (0.4)	**73.4** (0.5)	**92.0** (0.0)	**85.5** (0.1)	**93.9** (0.6)	**89.5** (0.5)	**90.7** (0.8)	**85.3** (0.8)	-

Table 1. Segmentation results on five different modalities with *seen* clinical settings. We also provide one tailed *t*-Test results (*P*-value) compared to our method and other methods. (·) denotes the standard deviations of multiple experiment results.

Method	Dermoscopy		Radiology		Ultrasound		Microscopy		Colonoscopy						*P*-value
	PH2 [42]		COVID19-2 [1]		STU [75]		MonuSeg2018 [12]		CVC-300 [62]		CVC-ColonDB [58]		ETIS [55]		
	DSC	mIoU	DSC	mIoU	DSC	mIoU	DSC	mIoU	DSC	mIoU	DSC	mIoU	DSC	mIoU	
UNet [52]	90.3 (0.1)	***83.5*** (0.1)	47.1 (0.7)	37.7 (0.6)	71.6 (1.0)	61.6 (0.7)	29.2 (5.1)	18.9 (3.5)	66.1 (2.3)	58.5 (2.1)	56.8 (1.3)	49.0 (1.2)	41.6 (1.1)	35.4 (1.0)	1.1E-09
AttUNet [45]	89.9 (0.2)	82.6 (0.3)	43.7 (0.8)	35.2 (0.8)	77.0 (1.6)	68.0 (1.7)	***39.0*** (3.1)	***26.5*** (2.4)	63.0 (0.3)	57.2 (0.4)	56.8 (1.6)	50.0 (1.5)	38.4 (0.3)	33.5 (0.1)	6.7E-09
UNet++ [74]	88.0 (0.3)	80.1 (0.3)	50.5 (3.8)	40.9 (3.7)	77.3 (0.4)	67.8 (0.3)	25.4 (0.8)	15.3 (0.5)	64.3 (2.2)	58.4 (2.0)	57.5 (0.4)	50.2 (0.4)	39.1 (2.4)	34.0 (2.1)	1.0E-05
CENet [22]	90.5 (0.1)	83.3 (0.1)	60.1 (0.3)	49.9 (0.3)	86.0 (0.7)	***77.2*** (0.9)	27.7 (1.5)	16.9 (1.0)	85.4 (1.6)	78.2 (1.4)	65.9 (1.6)	59.2 (0.1)	57.0 (3.4)	51.4 (0.5)	4.5E-06
TransUNet [7]	89.5 (0.3)	82.1 (0.4)	56.9 (1.0)	48.0 (0.7)	41.4 (9.5)	32.1 (4.2)	15.9 (8.5)	9.6 (5.5)	85.0 (0.6)	77.3 (0.3)	63.7 (0.1)	58.4 (0.3)	50.1 (0.5)	44.0 (2.3)	1.6E-06
FRCUNet [4]	90.6 (0.1)	83.4 (0.2)	62.9 (1.1)	52.7 (0.9)	***86.5*** (2.3)	***77.2*** (2.7)	26.1 (5.6)	16.8 (4.3)	86.7 (0.7)	79.4 (0.3)	69.1 (1.0)	62.6 (0.9)	65.1 (1.0)	58.4 (0.5)	2.3E-05
MSRFNet [57]	90.5 (0.3)	***83.5*** (0.3)	58.3 (0.8)	48.4 (0.6)	84.0 (5.5)	75.2 (8.2)	9.1 (1.0)	5.3 (0.7)	72.3 (2.2)	65.4 (2.2)	61.5 (1.0)	54.8 (0.8)	38.3 (0.6)	33.7 (0.7)	1.0E-07
HiFormer [26]	86.9 (1.6)	79.1 (1.8)	54.1 (1.0)	44.5 (0.8)	80.7 (2.9)	71.3 (3.2)	21.9 (8.9)	13.2 (5.7)	84.7 (1.1)	77.5 (1.1)	67.6 (1.4)	60.5 (1.3)	56.7 (3.2)	50.1 (3.3)	2.5E-07
DCSAUNet [67]	89.0 (0.4)	81.5 (0.3)	52.4 (1.2)	44.0 (0.7)	86.1 (0.5)	76.5 (0.8)	4.3 (0.3)	2.4 (0.9)	68.9 (4.0)	59.8 (3.9)	57.8 (0.4)	49.3 (0.4)	42.9 (3.0)	36.1 (2.9)	1.3E-07
M2SNet [73]	***90.7*** (0.3)	***83.5*** (0.5)	***68.6*** (0.1)	***58.9*** (0.2)	79.4 (0.7)	69.3 (0.6)	36.3 (0.9)	23.1 (0.8)	**89.9** (0.2)	**83.2** (0.3)	***75.8*** (0.7)	***68.5*** (0.5)	***74.9*** (1.3)	***67.8*** (1.4)	4.9E-02
SFSSNet	89.8 (0.2)	82.2 (0.4)	65.1 (1.6)	55.5 (1.3)	59.1 (0.3)	49.3 (0.7)	21.5 (7.2)	14.3 (5.0)	81.7 (0.3)	74.7 (0.4)	65.6 (0.4)	58.4 (0.5)	56.4 (0.7)	49.4 (0.4)	2.0E-07
MFSSNet	90.2 (0.8)	83.3 (0.9)	67.6 (0.5)	57.9 (0.3)	66.1 (0.8)	59.3 (0.2)	30.1 (7.5)	20.5 (5.5)	83.3 (1.4)	76.1 (1.2)	66.0 (0.7)	59.1 (0.8)	59.3 (0.2)	52.6 (0.6)	3.9E-04
SFMSNet	90.8 (0.3)	83.9 (0.5)	67.7 (1.1)	58.0 (1.3)	84.5 (0.2)	74.3 (0.1)	28.1 (9.9)	18.2 (7.1)	84.2 (1.2)	78.1 (1.0)	75.9 (0.8)	68.3 (0.8)	68.9 (0.3)	62.7 (0.4)	7.9E-03
MADGNet	**91.3** (0.1)	**84.6** (0.1)	**72.2** (0.3)	**62.6** (0.3)	**88.4** (1.0)	**79.9** (1.5)	**46.7** (4.3)	**32.0** (2.9)	***87.4*** (0.4)	***79.9*** (0.4)	**77.5** (1.1)	**69.7** (1.2)	**77.0** (0.3)	**69.7** (0.5)	-

Table 2. Segmentation results on five different modalities with *unseen* clinical settings. We also provide one tailed *t*-Test results (*P*-value) compared to our method and other methods. (·) denotes the standard deviations of multiple experiment results.

相比于仅使用多尺度（SFMSNet）或仅使用多频率（MFSSNet），同时结合多频率+多尺度（MADGNet）表现最佳。在 seen 和 unseen 数据集上，MADGNet 都优于所有基线模型（如 M2SNet、TransUNet）。说明 同时使用多频率信息和多尺度信息，可以有效提升模型的泛化能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

DS	Flow	Task	*Seen*		*Unseen*	
			DSC	mIoU	DSC	mIoU
✗	-	R	90.8	85.7	75.2	68.2
	Parallel	$R\&D\&B$	91.5	86.6	76.2	69.9
✓	Parallel	$R\&D\&B$	90.8	85.9	73.7	66.8
	Ensemble	$R \rightarrow D \rightarrow B$	91.4	86.5	77.5	70.0
	Ensemble	$R \leftrightarrow D \leftrightarrow B$	92.0	87.3	80.9	73.3

内容：对比不同的多任务学习策略（无深度监督、并行深度监督、E-SDM 级联方式）在 Colonoscopy（结肠镜）数据集 上的效果。主要分析 深度监督（DS）和不同的子任务流向 对模型性能的影响。

结论：使用 深度监督（DS） 可以提高模型表现，但若直接采用并行方式训练多个任务（区域、边界、距离映射），会造成信息丢失，影响分割效果。采用 E-SDM（级联方式）进行任务解码，能够有效防止上采样过程中的信息丢失，进一步提升分割精度。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

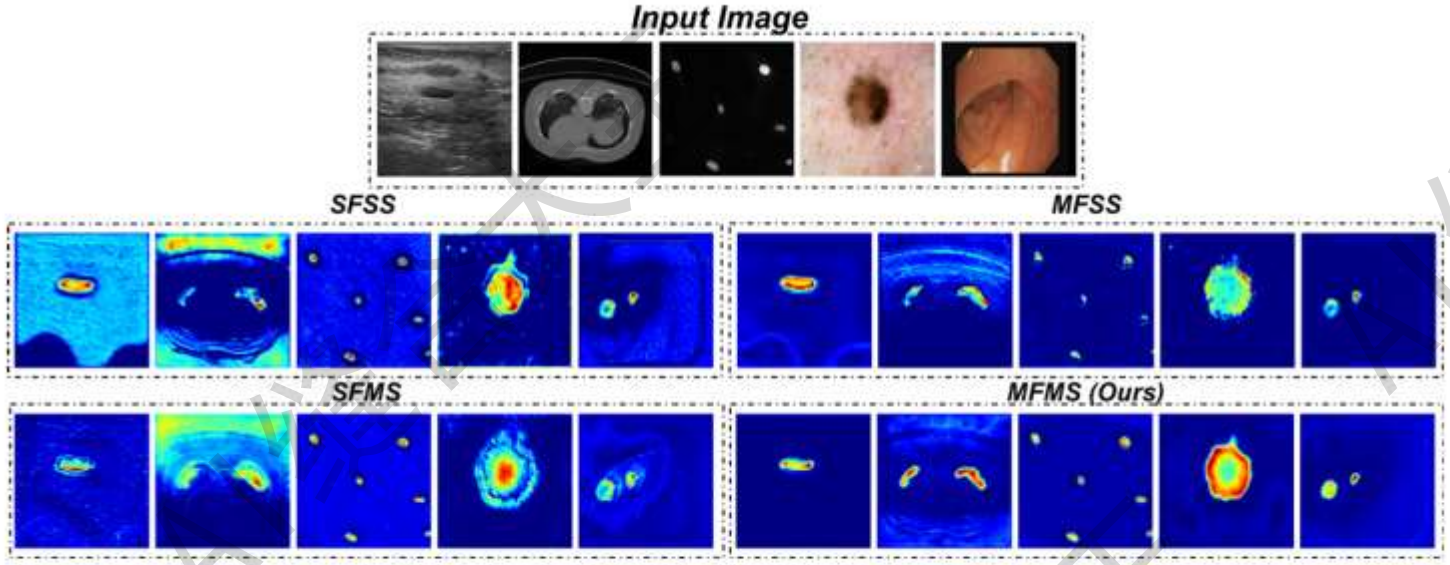

Figure 6. Feature visualization of SFSS, MFSS, SFMS, **MFMS**.

内容：可视化不同变体（仅使用单频率/单尺度 vs. 结合多频率和多尺度）的特征提取效果。直观展示 MADGNet（MFMS）的特征表达更加清晰，边界更加精准。

结论：单频率（SFSS）模型无法清晰捕捉边界信息。单尺度（MFSS）虽然有频率信息，但仍然难以处理不同大小的目标。单频率 + 多尺度（SFMS）比单频率更好，但仍然存在局限。多频率 + 多尺度（MADGNet，MFMS）能更精准地提取特征，边界更清晰，细节保留更完整。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

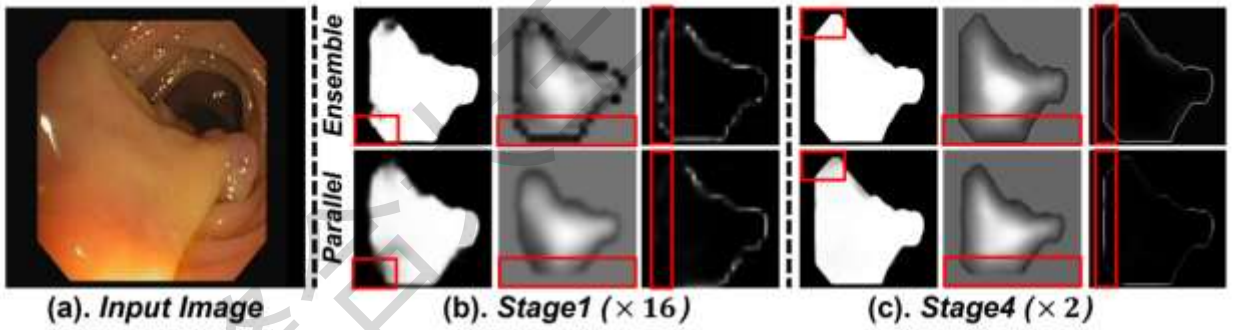

Figure 7. Qualitative results between ensemble and parallel manners. (a) Input Image, (b) and (c) Predictions from Stage1 (×16 **Up**) and Stage4 (×2 **Up**). First and second rows in (b) and (c) are predictions with **ensemble (Ours)** and parallel manners.

内容：对比了两种不同的深度监督解码方式（E-SDM 级联 vs. 并行）在不同上采样阶段的分割效果。第一行是 E-SDM 级联方式，第二行是 并行方式。

结论：E-SDM（级联方式）在高上采样率（× 16）情况下，预测边界更清晰，噪声更少。并行方式在高上采样率情况下，细节丢失严重，边界模糊。证明级联子任务解码（E-SDM）能够有效防止信息丢失，提高最终分割效果。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

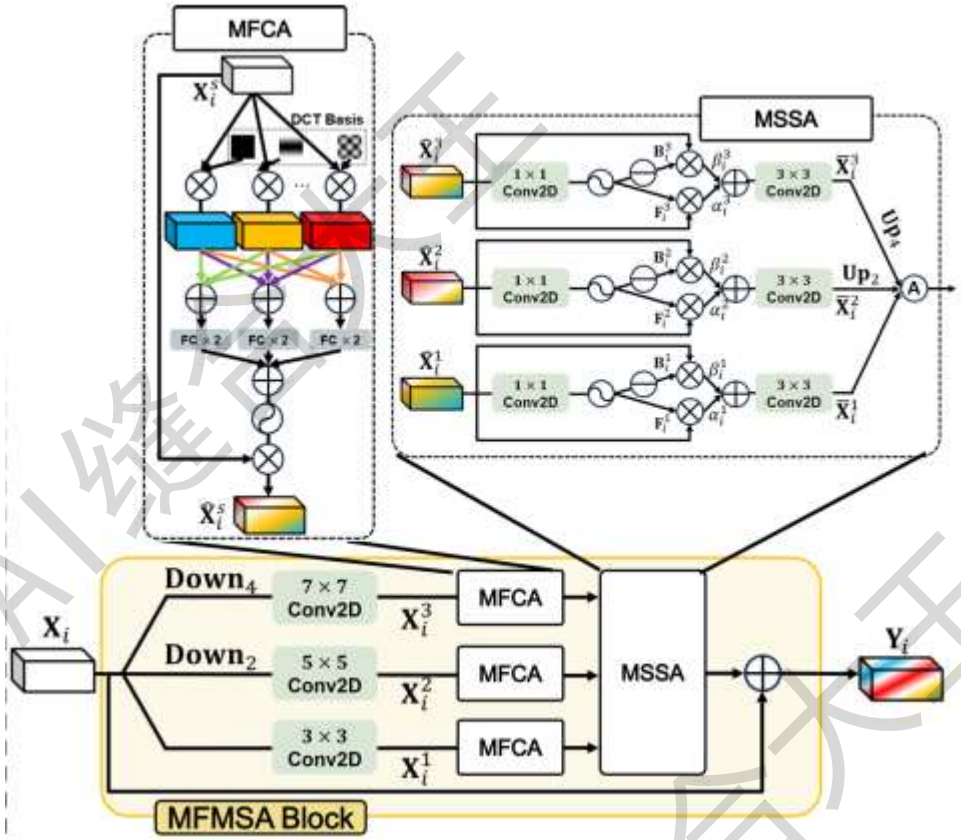

Multi-Frequency Channel Attention（MFCA）作为即插即用模块，特别适用于医学图像分析、低对比度图像增强、高噪声环境以及多模态学习。其核心作用是增强边界检测能力、提高对噪声的鲁棒性，并优化计算效率，使深度学习模型在复杂场景下具有更强的泛化能力和鲁棒性。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

MixDehazeNet : Mix Structure Block For Image Dehazing Network

LiPing Lu*
WuHan University Of Technology
luliping@whut.edu.cn

Qian Xiong*
WuHan University Of Technology
xiongqian2021@whut.edu.cn

DuanFeng Chu
WuHan University Of Technology
chudf@whut.edu.cn

BingRong Xu†
WuHan University Of Technology
bingrongxu@whut.edu.cn

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

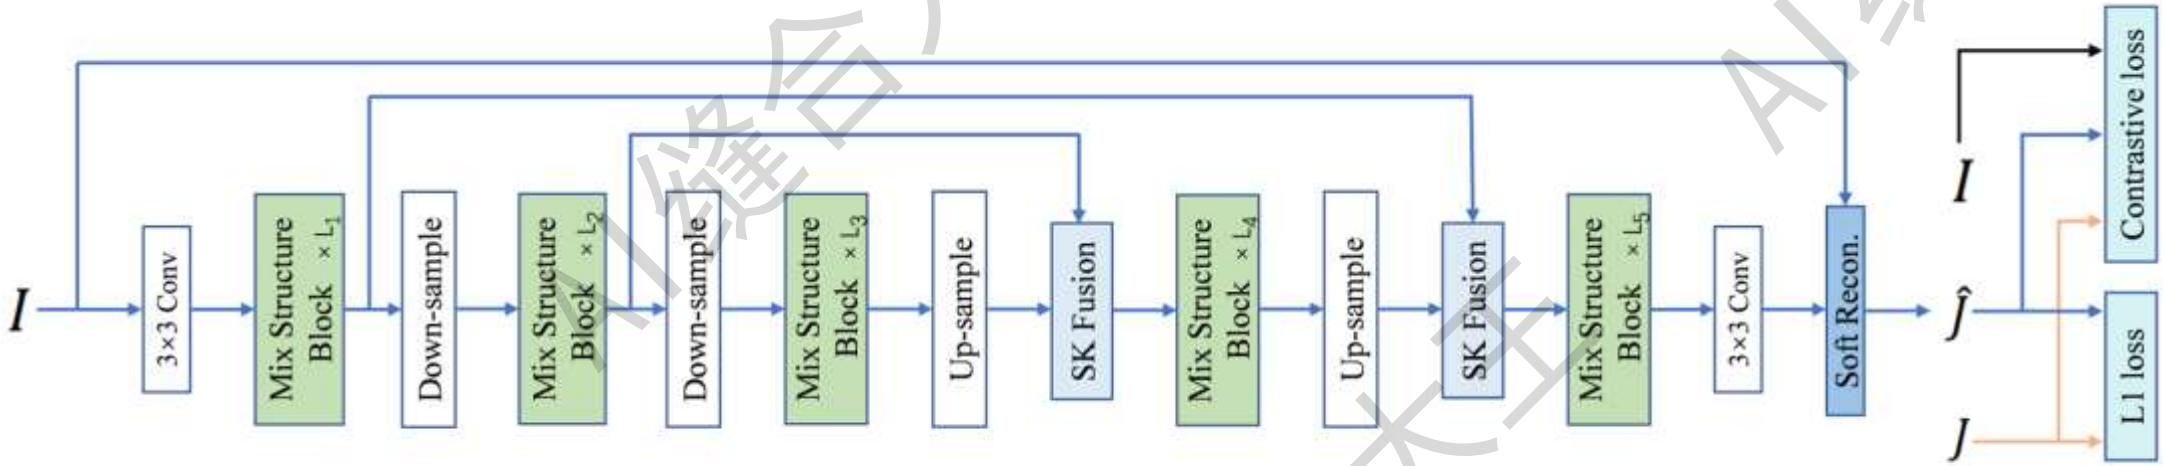

MixDehazeNet 采用 U-Net 作为主干网络，并在其中嵌入了创新的 Mix Structure Block，该块由 多尺度并行大卷积核模块（MSPLCK） 和 增强型并行注意力模块（EPA） 组成。MSPLCK 通过并行的大卷积核（7×7、13×13、19×19）提取多尺度特征，提高去雾能力，同时保留纹理细节；EPA 结合 像素注意力、通道注意力和简单像素注意力，增强对全局与局部信息的建模能力，优化去雾效果。此外，网络采用 跳跃连接（Skip Connection） 来融合不同层级的特征，并引入 对比学习（Contrastive Learning） 进一步优化去雾质量。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 3. Ablation Study on the RESIDE-IN dataset.

Method	PSNR	SSIM
MixDehazeNet-S-Base	34.39	0.987
+MSPLCK	36.15	0.990
+EPA	36.28	0.991
+MSPLCK+EPA	38.35	0.992
+MSPLCK+EPA+CR	39.47	0.995

作用：验证 多尺度并行大卷积核模块（MSPLCK）、增强型并行注意力模块（EPA） 和 对比学习（Contrastive Learning, CR） 对模型性能的影响。

结论：每个模块都有贡献， MSPLCK 和 EPA 是提升去雾性能的关键， 对比学习进一步优化去雾效果。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 5. Multi-Scale Parallel Large Convolution kernel ablation study on the RESIDE-IN dataset.

Method	PSNR	SSIM
Three Parallel DWDConv7	35.23	0.989
Three Parallel DWDConv13	35.67	0.990
Three Parallel DWDConv19	35.71	0.990
MSPLCK	35.94	0.990

作用：验证 多尺度并行大卷积核设计 是否优于单一尺度的大卷积核。

结论：多尺度组合（MSPLCK）比单一尺度更有效，提高去雾能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 6. Enhanced Parallel Attention ablation study on the RESIDE-IN dataset.

Method	PSNR	SSIM
CA PA in Serial	34.95	0.988
SPA CA PA in Serial	34.25	0.987
EPA	35.94	0.990

作用：比较 串行注意力（Sequential Attention）和 并行注意力（Parallel Attention, EPA）的去雾效果。

结论：EPA（并行注意力）比串行注意力更适用于去雾任务，能更有效地提取全局和局部信息，提高去雾质量。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

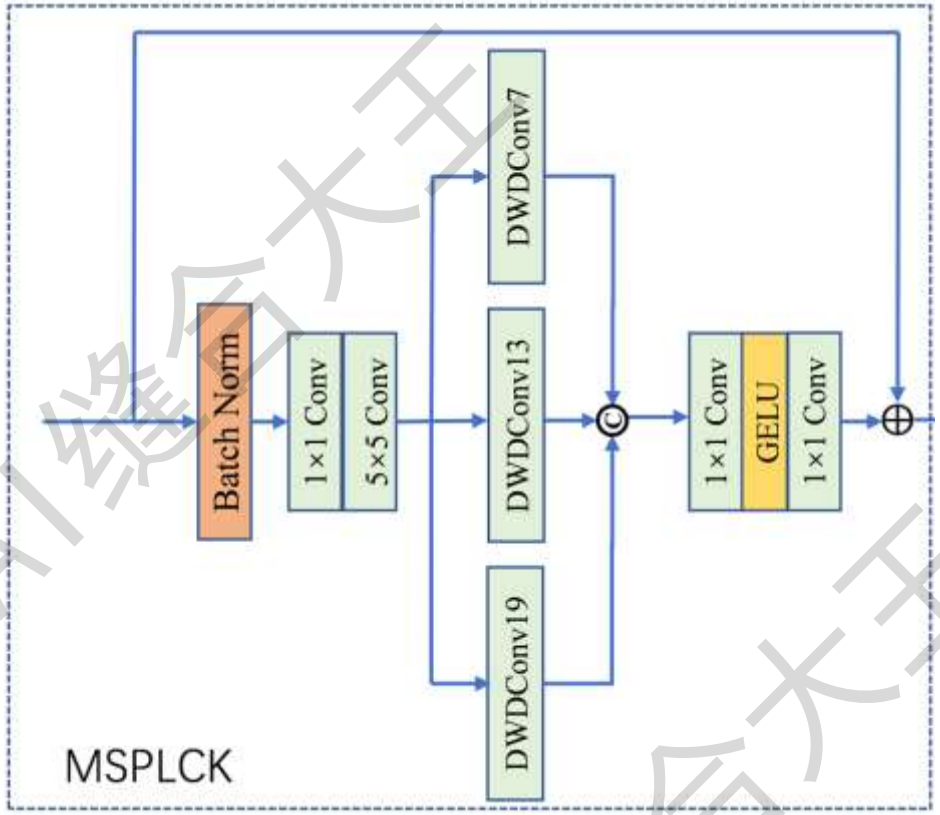

MSPLCK 作为即插即用模块，特别适用于需要去雾、去雨、低光增强、超分辨率、医学影像增强、遥感图像处理等任务，能够增强多尺度特征提取能力，提高全局建模效果，同时恢复细节信息。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

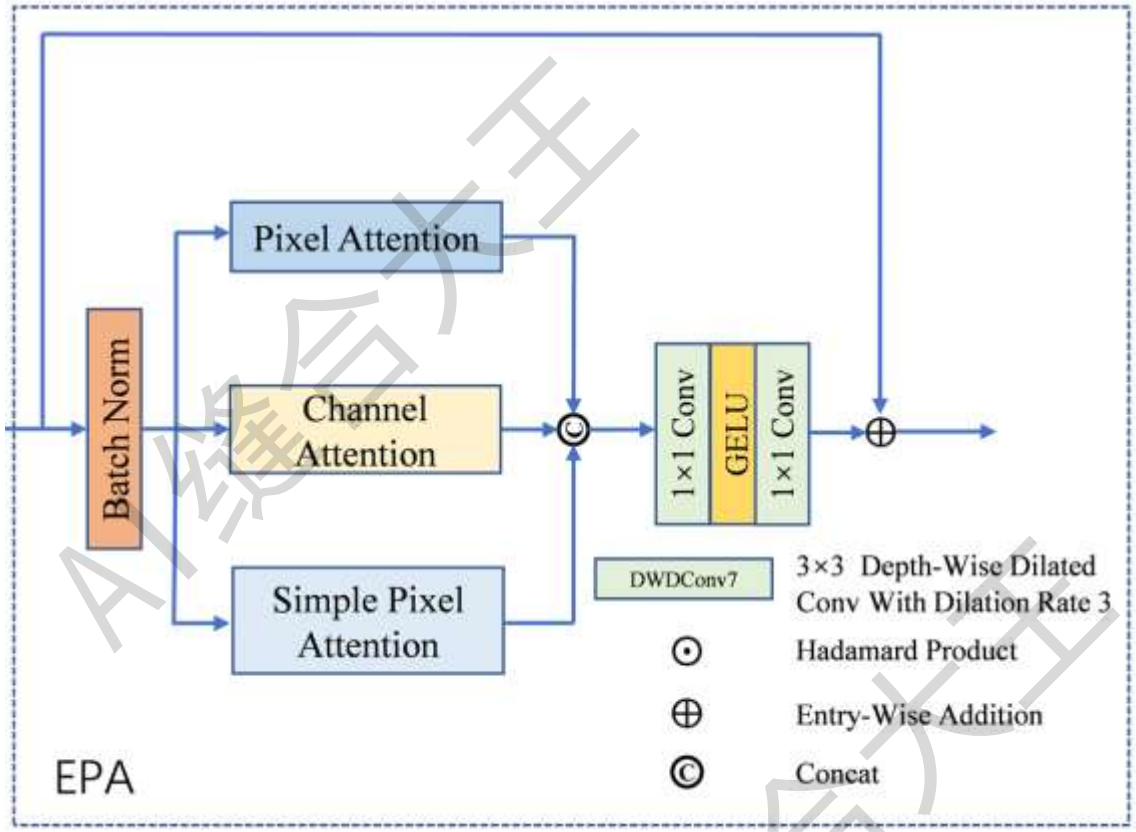

EPA 适用于去雾、去雨、去噪、超分辨率、医学影像、目标检测等多种视觉任务，能够同时提取全局与局部信息，提高去雾质量、目标检测精度和图像增强效果。它可以作为 即插即用”模块，直接替换传统注意力机制，增强深度学习模型的特征提取能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

TVConv: Efficient Translation Variant Convolution for Layout-aware Visual Processing

Jierun Chen[1], Tianlang He[1], Weipeng Zhuo[1], Li Ma[1], Sangtae Ha[2], S.-H. Gary Chan[1]
[1]The Hong Kong University of Science and Technology, [2]University of Colorado at Boulder
{jcheneh, theaf, wzhuo, lmaag, gchan}@cse.ust.hk, sangtae.ha@colorado.edu

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

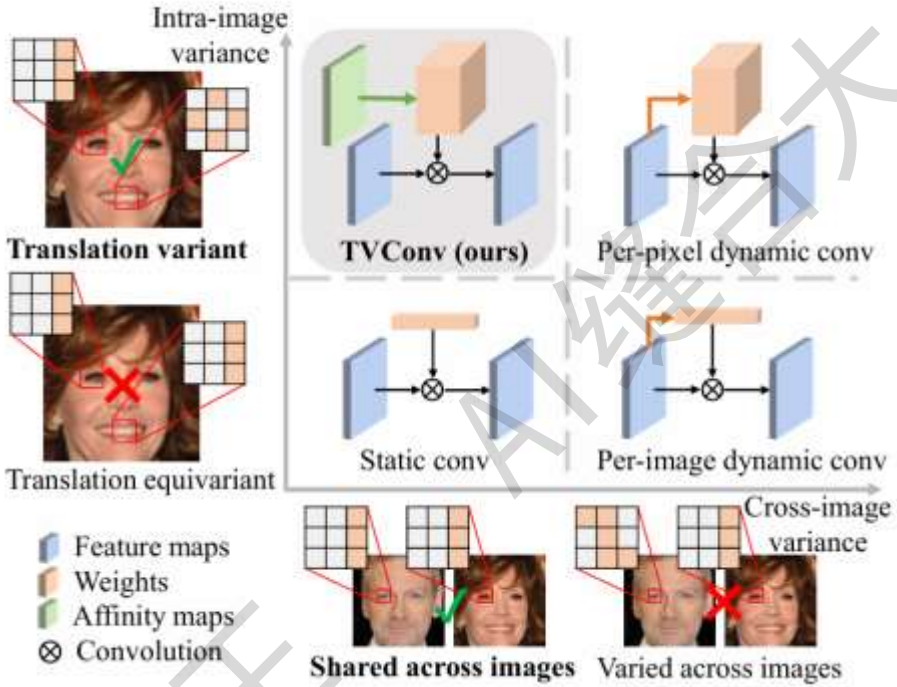

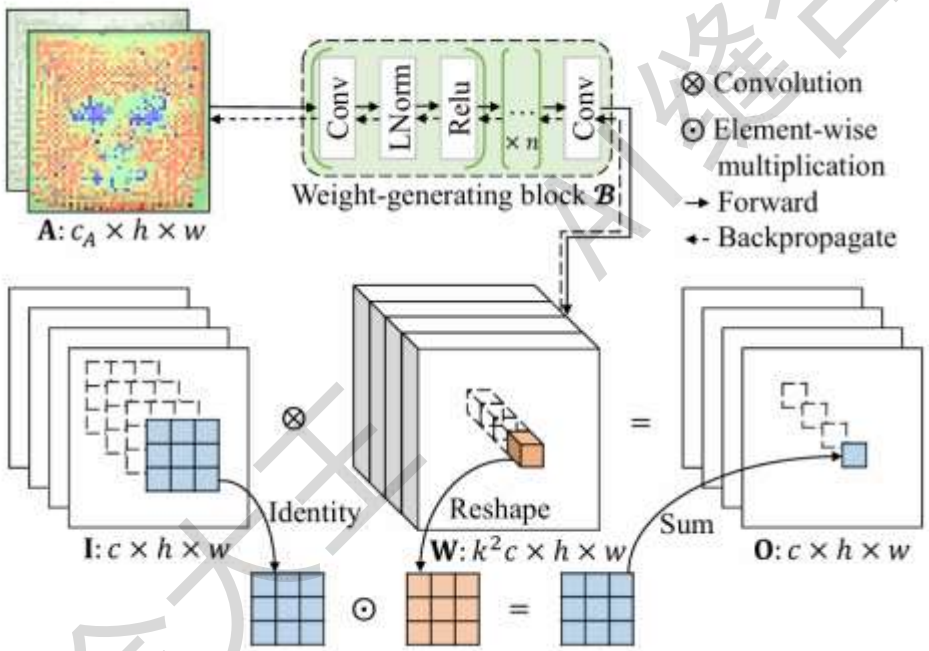

TVConv)主要作为卷积神经网络（CNN）中的一个高效替代模块，并可以无缝集成到现有的轻量级网络架构（如 MobileNetV2、ShuffleNetV2）。其核心结构由 亲和度映射（Affinity Maps） 和权重生成块（Weight-Generating Block） 组成。首先，亲和度映射通过学习不同区域的像素关系，捕捉图像的布局信息。然后，权重生成块基于这些映射生成空间自适应的卷积核权重，并在推理阶段进行高效查询和应用。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Init.	Error (%) for ×0.1	Error (%) for ×0.5	Error (%) for ×1.0
data statistics	2.92 ± 0.22	1.75 ± 0.18	1.62 ± 0.20
constant 1	**2.84 ± 0.11**	**1.73 ± 0.07**	**1.43 ± 0.12**

Table 3. Initialization from constant maps (*e.g.* constant 1) works better than initialization from the data statistics.

研究问题：如何初始化亲和度映射（Affinity Maps）会影响 TVConv 的性能？

实验结论：常数初始化（全 1）效果更优，表明 TVConv 在训练过程中可以自动学习合适的亲和度映射，而直接使用数据统计信息进行初始化可能会产生几何不匹配，影响性能。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

$\mathcal{B}$ #Chans.	Error (%)	$\mathcal{B}$ #Layers	Error (%)	**A** #Chans.	Error (%)
128	2.60 ± 0.10	4	2.49 ± 0.16	8	2.49 ± 0.16
64	**2.31 ± 0.12**	**3**	**2.31 ± 0.12**	**4**	**2.31 ± 0.12**
32	2.65 ± 0.21	2	2.44 ± 0.15	2	2.44 ± 0.19
8	2.65 ± 0.12	1	2.48 ± 0.27	1	2.52 ± 0.15

Table 4. Ablation under the varied number of channels and inter layers for weight generating block $\mathcal{B}$, as well as the varied number of channels for affinity maps **A**. We use hyper-parameters highlighted in bold as our default setting elsewhere in the paper.

研究问题：TVConv 的 权重生成块（Weight-Generating Block） 及 亲和度映射的通道数 如何影响性能？

实验结论：增加权重生成块的层数和宽度（参数量）可以提高精度，但如果过度膨胀，性能会略微下降（过拟合）。亲和度映射的通道数增加可以提高性能，但超过 4 个通道时，提升变得有限。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Stages	S1	S2	S3	S4	S5	S6	S7
Error(%)	4.01	3.73	3.42	3.43	3.34	3.25	3.39
Stages	Baseline	**S1-S7**	S2-S7	S3-S7	S4-S7	S5-S7	S6-S7
Error(%)	3.68	**2.31**	2.35	2.38	2.51	2.53	2.61

Table 5. Ablation of applying TVConv in different stages. Excluding the input layer, MobileNetV2 has 7 stages. Stages S1-S7 correspond to layers L1, L2-L3, L4-L6, L7-L10, L11-L13, L14-L16 and L17, respectively. Error SD is omitted for simplicity.

研究问题：在哪些网络层使用 TVConv 影响最大？

实验结论：仅在浅层（S1, S2）使用 TVConv 可能会影响性能，因为低层特征较通用，过早引入布局敏感性可能会降低泛化能力。在深层（S5-S7）使用 TVConv 效果最佳，表明其更适用于高层语义特征的提取。逐步在更多层级叠加 TVConv，误差不断降低，说明 TVConv 的全局布局感知特性对于整体网络性能有显著提升。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

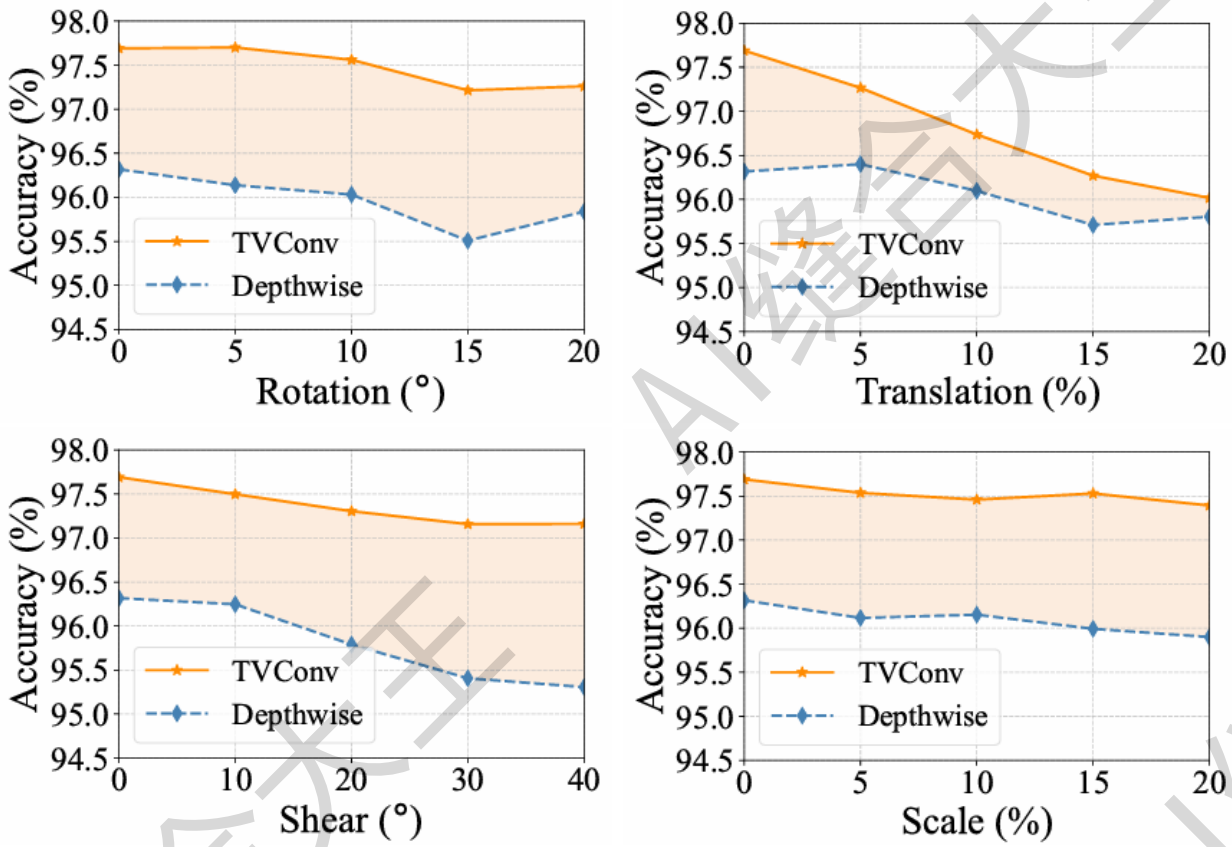

研究问题：TVConv 对 旋转、平移、缩放、剪切 等不同变换的敏感性如何？

实验结论：TVConv 对旋转、缩放和剪切变化具有较强的鲁棒性，相比深度可分离卷积（Depthwise Conv），性能下降更缓慢。对于平移，TVConv 的性能会逐渐退化，并最终退化为普通的深度可分离卷积，因为 TVConv 依赖于固定的亲和度映射，而平移会改变像素位置关系，影响其作用。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

(a) Mean (b) Std (c) D(mean) (d) D(std) (e) Learned

研究问题：TVConv 训练过程中，亲和度映射是如何学习的？

实验结果：
浅层（Early Layers）：亲和度映射在前几层几乎保持恒定，说明低层特征较通用。
深层（Deeper Layers）：亲和度映射逐渐形成明显的模式，例如面部轮廓，表明 TVConv 在高层能捕捉更丰富的布局信息。
训练早期 vs 训练后期：随着训练进行，亲和度映射由随机状态逐渐变得稳定，能够更精准地捕捉布局模式。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

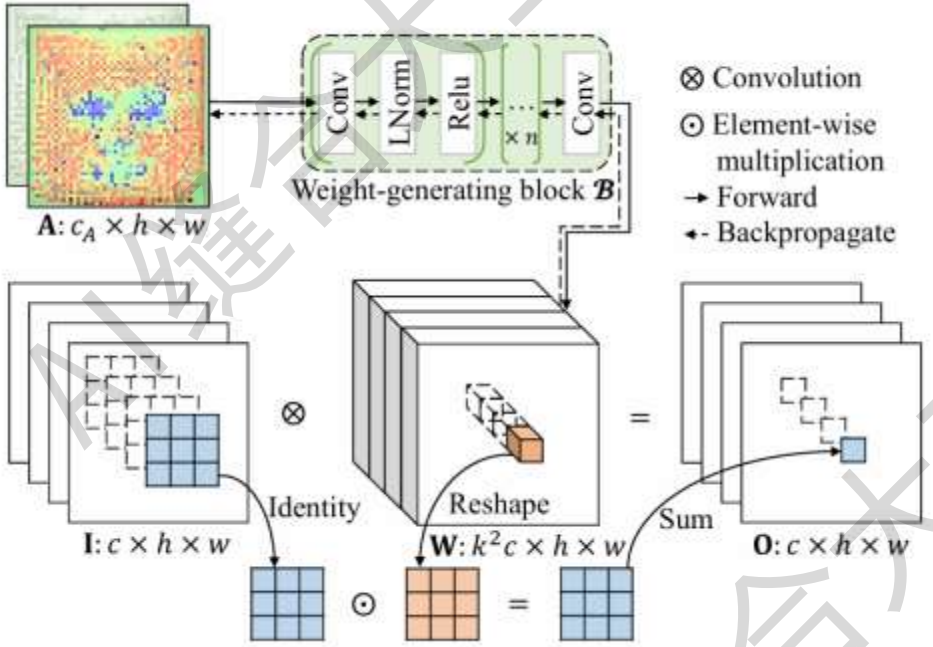

TVConv 适用于所有 涉及布局信息的视觉任务，相比于普通卷积，它能提高模型的计算效率，同时保留更强的布局感知能力，特别适用于资源受限的环境，如 智能手机、边缘计算设备、工业检测系统和医学影像分析 等应用。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

PolaFormer: Polarity-aware Linear Attention for Vision Transformers

Weikang Meng[1,2], **Yadan Luo**[3], **Xin Li**[2], **Dongmei Jiang**[2], **Zheng Zhang**[1*]
[1] Harbin Institute of Technology, Shenzhen, China
[2] Pengcheng Laboratory, China
[3] UQMM Lab, University of Queensland, Australia
zacharymengwk@gmail.com
darrenzz219@gmail.com

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

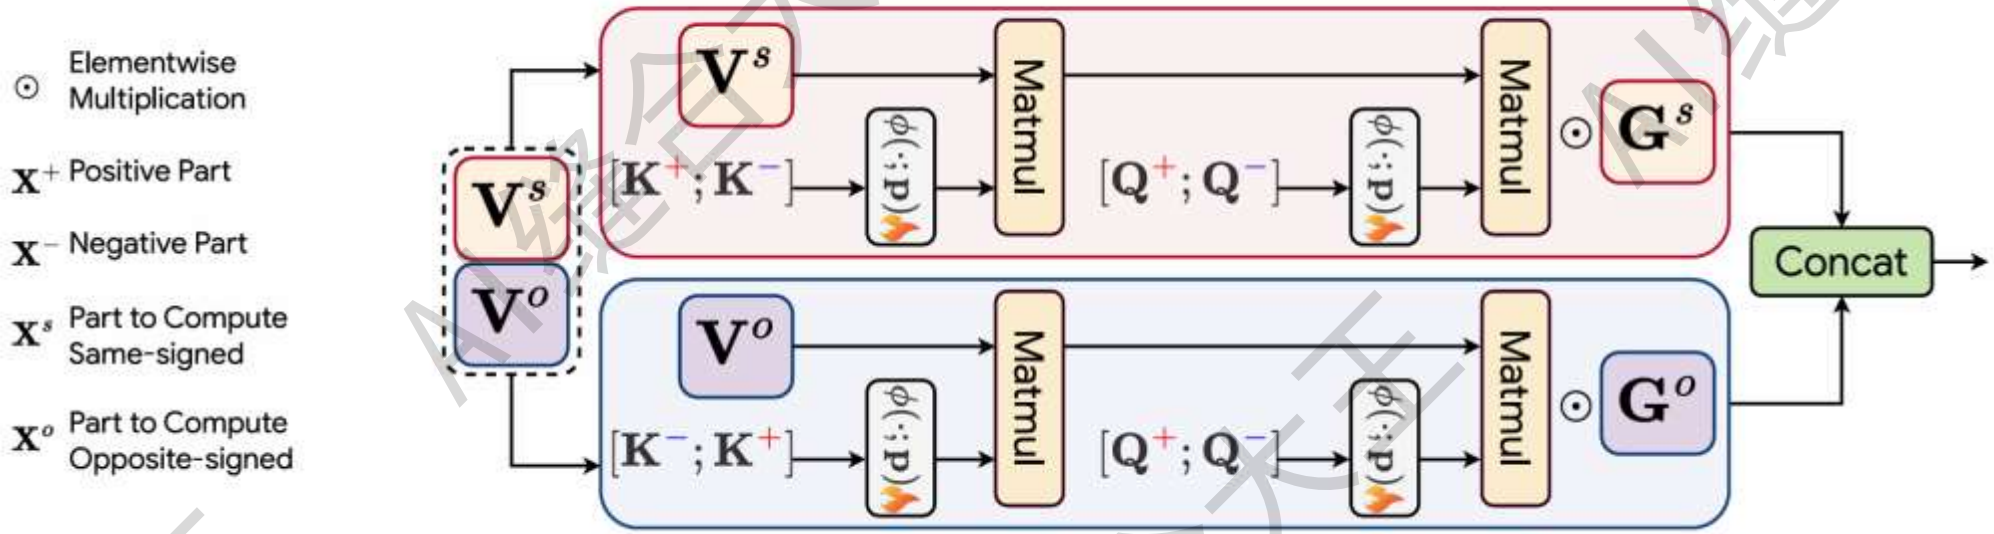

PolaFormer 的整体结构采用 极性感知线性注意力（Polarity-Aware Linear Attention）作为核心模块，针对传统线性注意力方法信息丢失的问题进行改进。其架构首先对查询（Query）和键（Key）向量进行极性分解，分别提取正负部分，然后将同号（正-正、负-负）和异号（正-负、负-正）交互分离，并通过两个可学习的矩阵（Gs 和 Go）进行加权融合，以完整地保留查询-键交互信息。此外，PolaFormer 采用可学习的通道级幂函数进行重新缩放，以降低注意力分布的熵，从而恢复 Softmax 机制的尖锐性。最终，经过线性投影，PolaFormer 以 线性复杂度（$O(Nd2)$）实现比传统 Transformer 更高效、更具表现力的注意力计算，并在多种视觉任务中展现了优越性能。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 3: Ablation study on each module using DeiT-T on ImageNet-1K.

POLARITY	G^s,G^o	DWC	DCN	ACC. (%)
✓	✓		✓	$61.9_{-12.7}$
✓				$68.1_{-6.5}$
✓		✓		$72.8_{-1.8}$
✓	✓	✓		74.6

目的：评估 PolaFormer 关键组件（极性分解、多尺度卷积、极性权重矩阵等）的贡献。

结论：仅使用极性分解（Polarity-aware attention）就可以带来 6.2% 的提升。增加 极性权重矩阵 Gs,Go 进一步提高了 4.7%，表明学习同号和异号交互权重的有效性。使用深度可分卷积（DWC）后，最终模型达到了 74.6%，相比基础线性注意力（61.9%）提升了 12.7%。可变形卷积（DCN）未被选为最终方案，表明深度可分卷积在计算效率和表现力之间取得了更好的平衡。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 4: Comparisons (%) between the proposed PolaFormer and other linear attention models on LRA, with the best results are highlighted in boldface.

MODEL	TEXT	LISTOPS	RETRIEVAL	PATHFINDER	IMAGE	AVERAGE
Transformer	61.55	38.71	80.93	70.39	39.14	58.14
LocalAttn	52.98	15.82	53.39	66.63	41.46	46.06
LinearTrans.	65.90	16.13	53.09	75.30	42.34	50.55
Reformer	56.10	37.27	53.40	68.50	38.07	50.67
Performer	65.40	18.01	53.82	**77.05**	**42.77**	51.41
Synthesizer	61.68	36.99	54.67	69.45	41.61	52.88
Longformer	62.85	35.63	56.89	69.71	42.22	53.46
Informer	62.13	37.05	79.35	56.44	37.86	54.57
Bigbird	64.02	36.05	59.29	74.87	40.83	55.01
Linformer	57.29	36.44	77.85	65.39	38.43	55.08
Kernelized	60.02	38.46	82.11	69.86	32.63	56.62
Cosformer	63.54	37.2	80.28	70.00	35.84	57.37
Nystrom	62.36	37.95	80.89	69.34	38.94	57.90
Skyformer	64.70	38.69	82.06	70.73	40.77	59.39
Hedgehog	64.60	37.15	**82.24**	74.16	40.15	59.66
PolaFormer$_{\alpha=3}$	**73.06**	37.35	80.50	70.53	42.15	**60.72**
PolaFormer$_{\alpha=5}$	72.33	**38.76**	80.37	68.98	41.91	60.47
PolaFormer$_{\alpha=7}$	71.93	37.60	81.47	69.09	**42.77**	60.57

目的：比较 PolaFormer 与其他线性注意力方法在 长序列任务（Long Range Arena, LRA） 上的表现，并分析不同超参数 α 对性能的影响。

结论：PolaFormer 在 LRA 上取得了 SOTA 结果（最高 60.72%），超过了所有其他线性注意力方法，尤其是在长文本分类（73.06%）和图像分类任务（42.77%）。适当调整幂函数的缩放参数 α 可以影响不同任务的表现：α=3在文本分类上效果最佳。α=5在逻辑运算（ListOps）任务上最优。α=7在图像分类任务上表现最强。说明 可学习的幂函数缩放 在不同任务上可以优化注意力分布，提高模型的任务适应能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

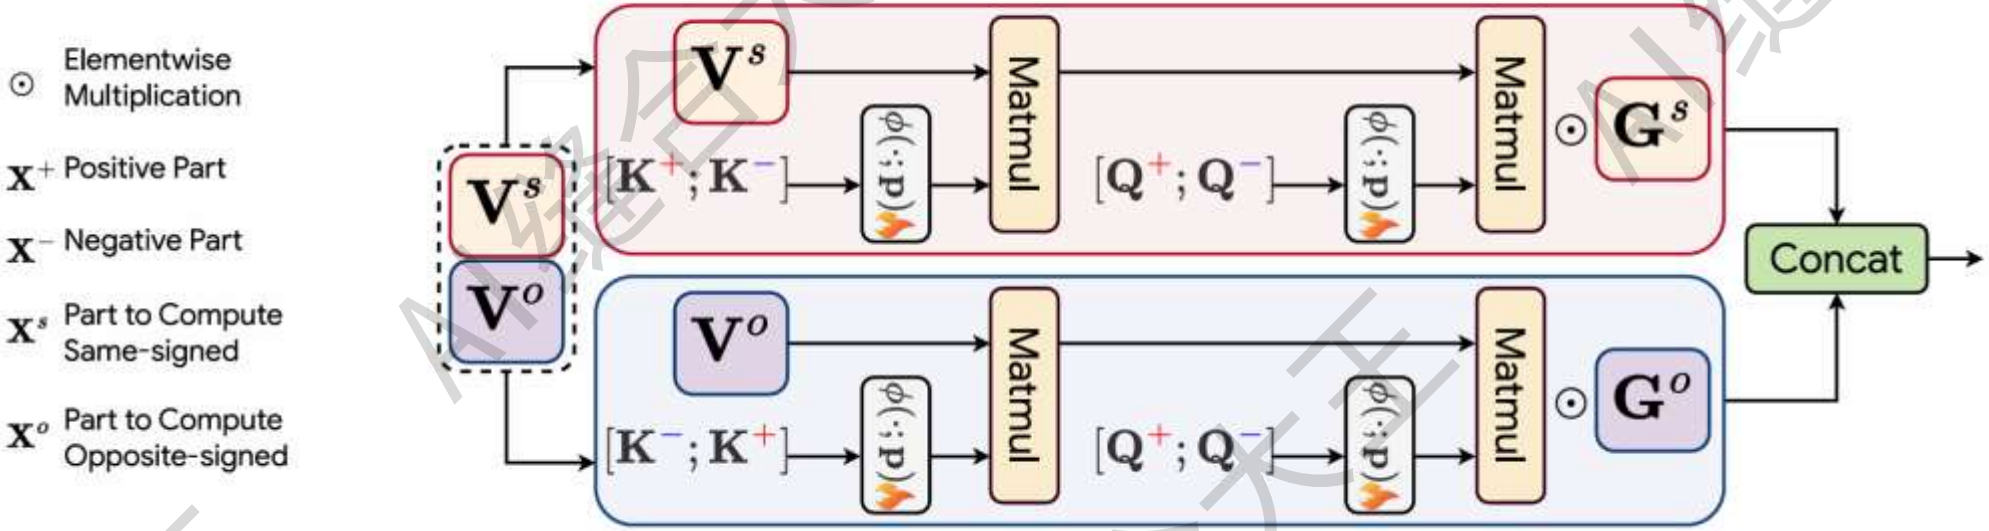

Polarity-Aware Linear Attention（PolaFormer）作为一个 即插即用模块，可以应用于计算受限环境、长序列任务、精准注意力任务，提升模型的注意力分辨能力，同时保持线性计算复杂度，适用于移动端 AI、长文本理解、目标检测、视频分析等多种应用场景。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Digit. Signal Process. 160 (2025) 105070

Contents lists available at ScienceDirect

Digital Signal Processing

journal homepage: www.elsevier.com/locate/dsp

A synergistic CNN-transformer network with pooling attention fusion for hyperspectral image classification

Peng Chen [a], Wenxuan He [b,a], Feng Qian [c], Guangyao Shi [d], Jingwen Yan [e,a,*]

[a] College of Engineering, Shantou University, Shantou, 515063, Guangdong, China
[b] School of Electronic Information and Communications, Huazhong University of Science and Technology, Wuhan, 430074, Hubei, China
[c] Changchun Institute of Optics, Fine Mechanics and Physics, Chinese Academy of Sciences, Changchun, 130033, Jilin, China
[d] School of Computer Science and Technology, Chongqing University of Posts and Telecommunications, Chongqing, 400065, China
[e] School of Intelligent Manufacturing and Electrical Engineering, Guangzhou Institute of Science and Technology, Guangzhou, 510000, Guangdong, China

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

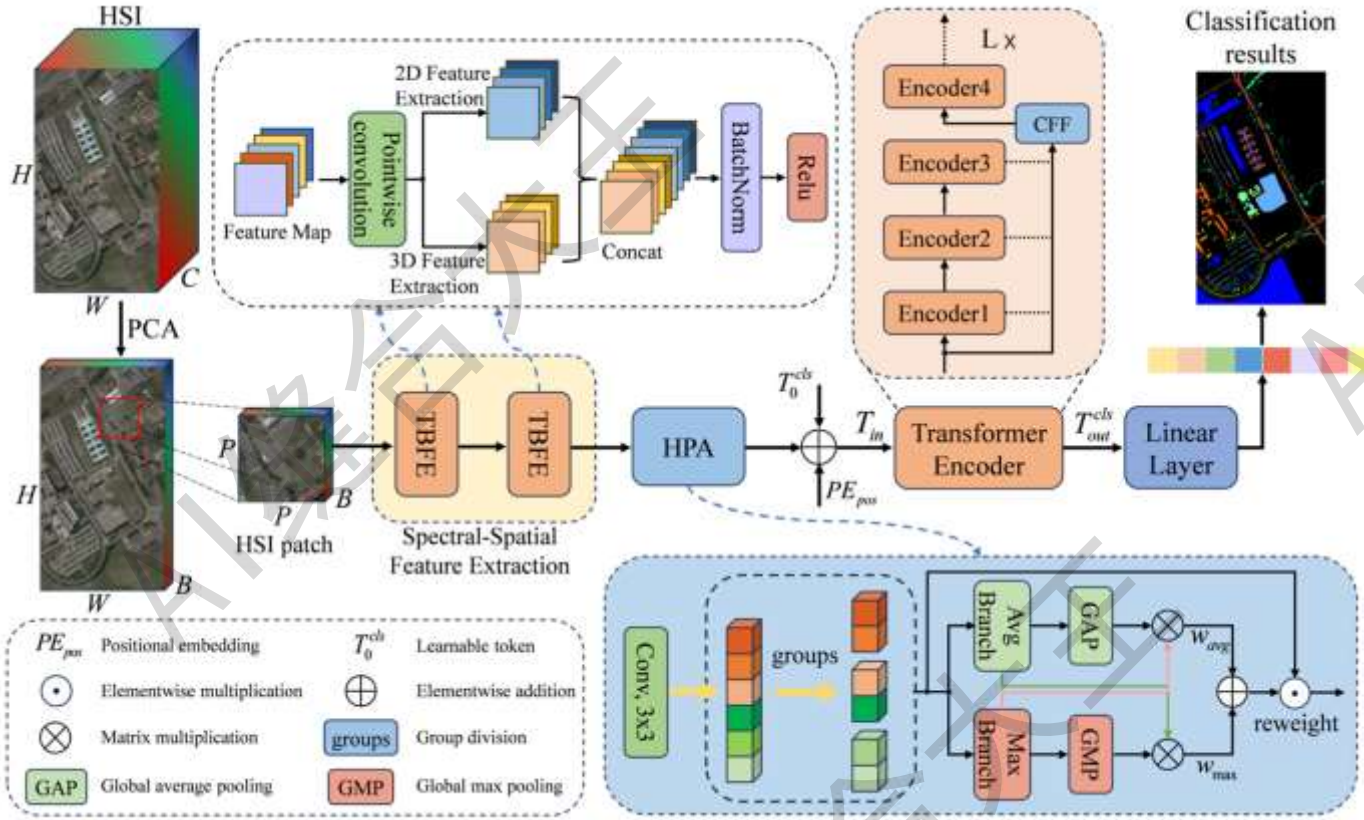

整体结构由多个模块组成：首先，对HSI数据进行PCA降维，并生成局部空间-光谱特征块；接着，通过双分支特征提取（TBFE）模块，利用3D卷积提取光谱特征，2D卷积提取空间特征，并进行特征融合；随后，混合池化注意力（HPA）模块通过平均池化和最大池化计算空间注意力，提高信息聚合效果；然后，特征进入级联Transformer编码器，通过自注意力机制捕捉长距离光谱相关性；最后，跨层特征融合（CFF）模块整合不同层的特征，以减少信息损失，并通过全连接层输出分类结果。这种架构结合了CNN的局部感受能力和Transformer的全局建模能力，实现了更精确的高光谱图像分类。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 6
Quantitative results of experiments with different number of encoders on five datasets. The best results are highlighted in bold.

Number of Encoders	Salinas		Pavia University		Houston2013		WHU-Hi-HanChuan		Houston2018		Number of Parameters
	OA(%)	$\kappa \times 100$	OA(%)	$\kappa \times 100$	OA(%)	$\kappa \times 100$	OA(%)	$\kappa \times 100$	OA(%)	$\kappa \times 100$	
1	97.87	97.63	99.43	99.25	99.34	99.30	98.18	97.87	97.59	96.83	**113.38k**
2	98.52	98.35	99.49	99.32	99.49	99.45	98.29	98.01	97.62	96.86	131.43k
3	**98.67**	**98.52**	99.46	99.28	99.46	99.39	98.33	98.06	97.57	96.79	149.47k
4	98.61	98.45	**99.92**	**99.89**	**99.65**	**99.62**	**98.37**	**98.09**	**97.72**	**96.99**	167.49 K
5	98.59	98.37	99.34	99.12	99.40	99.35	98.24	97.98	97.65	96.87	185.51k

该表展示了不同Transformer编码器层数（从1到5）对模型性能的影响，包括整体准确率（OA）、Kappa系数（κ）以及参数量。结果表明，增加编码器层数可以提高分类精度，但超过一定数量（如5层）后，精度反而下降，可能是因为引入了冗余信息或导致了过拟合。

在不同数据集中，最佳编码器层数有所不同，例如：Salinas 数据集在 3层 时效果最佳。Pavia University、Houston2013、WHU-Hi-HanChuan、Houston2018 数据集在 4层 时效果最佳。这表明，在HSI分类任务中，适当的编码器层数能够更好地建模光谱-空间特征，而过多的层可能会导致信息冗余或过拟合。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

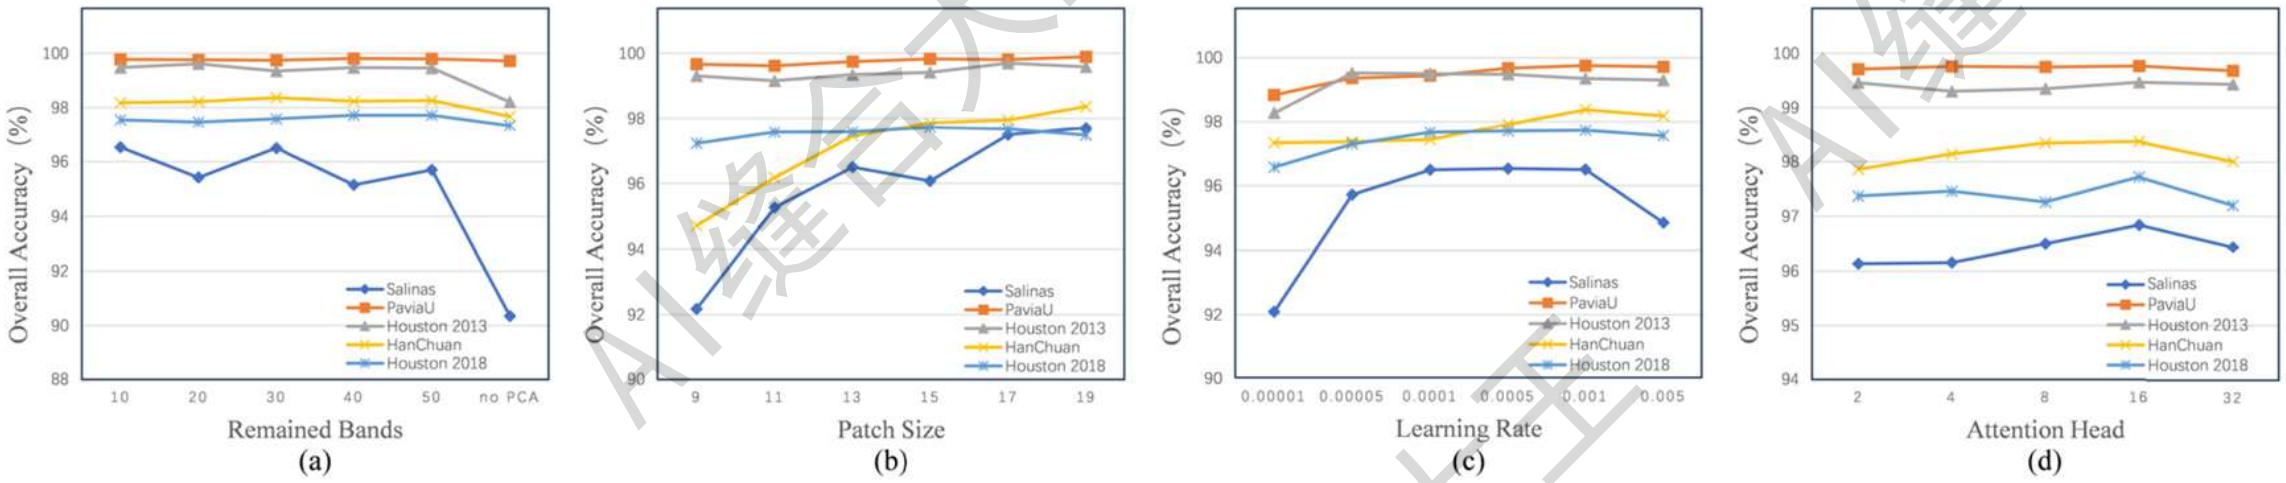

Fig. 4. The OA impact curves of different parameters. (a) Remained bands. (b) Patch size. (c) Learning rate. (d) Attention Head.

主要说明不同超参数对模型性能的影响，优化了光谱降维、Patch大小、学习率和注意力头数，确保模型在不同数据集上都能达到最佳效果。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

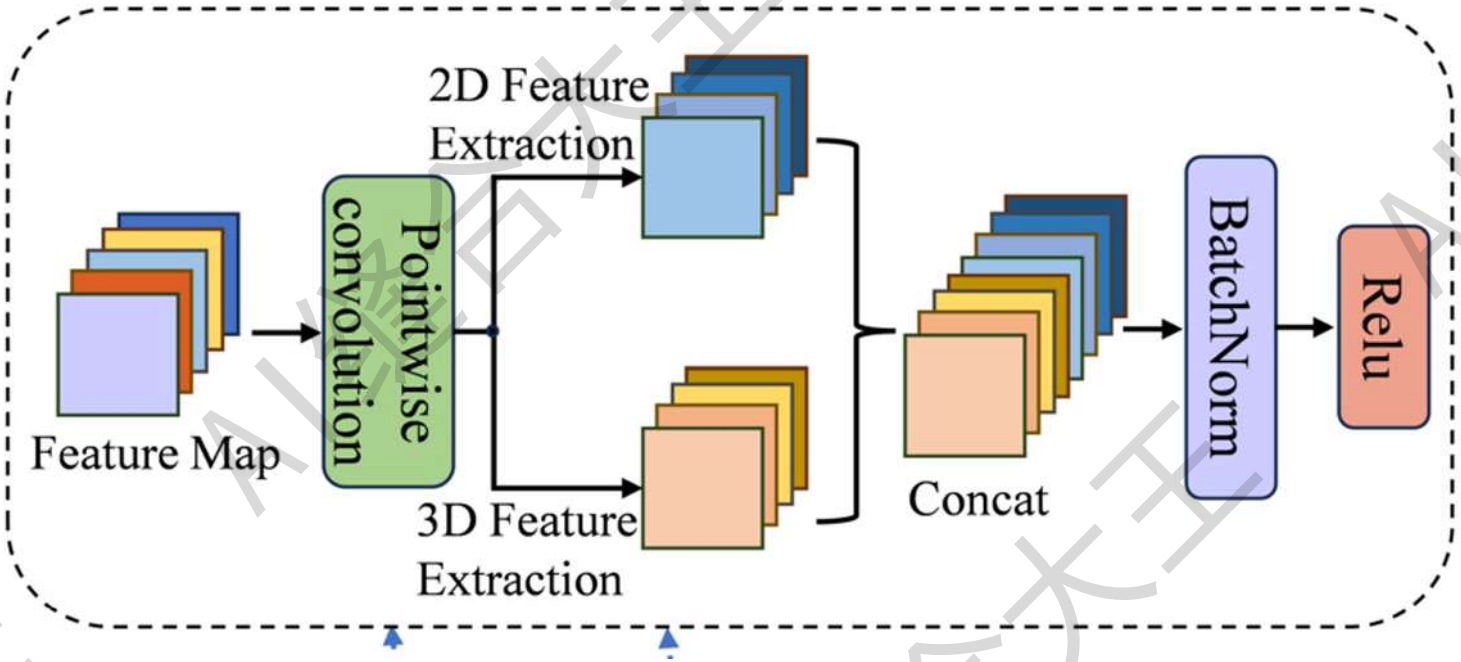

TBFE模块作为即插即用的特征提取组件，适用于高光谱图像分类、遥感、医学影像、工业检测、视频分析等领域，其主要作用是提取并融合局部空间信息和全局光谱信息，提高分类和检测精度，同时降低计算复杂度。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

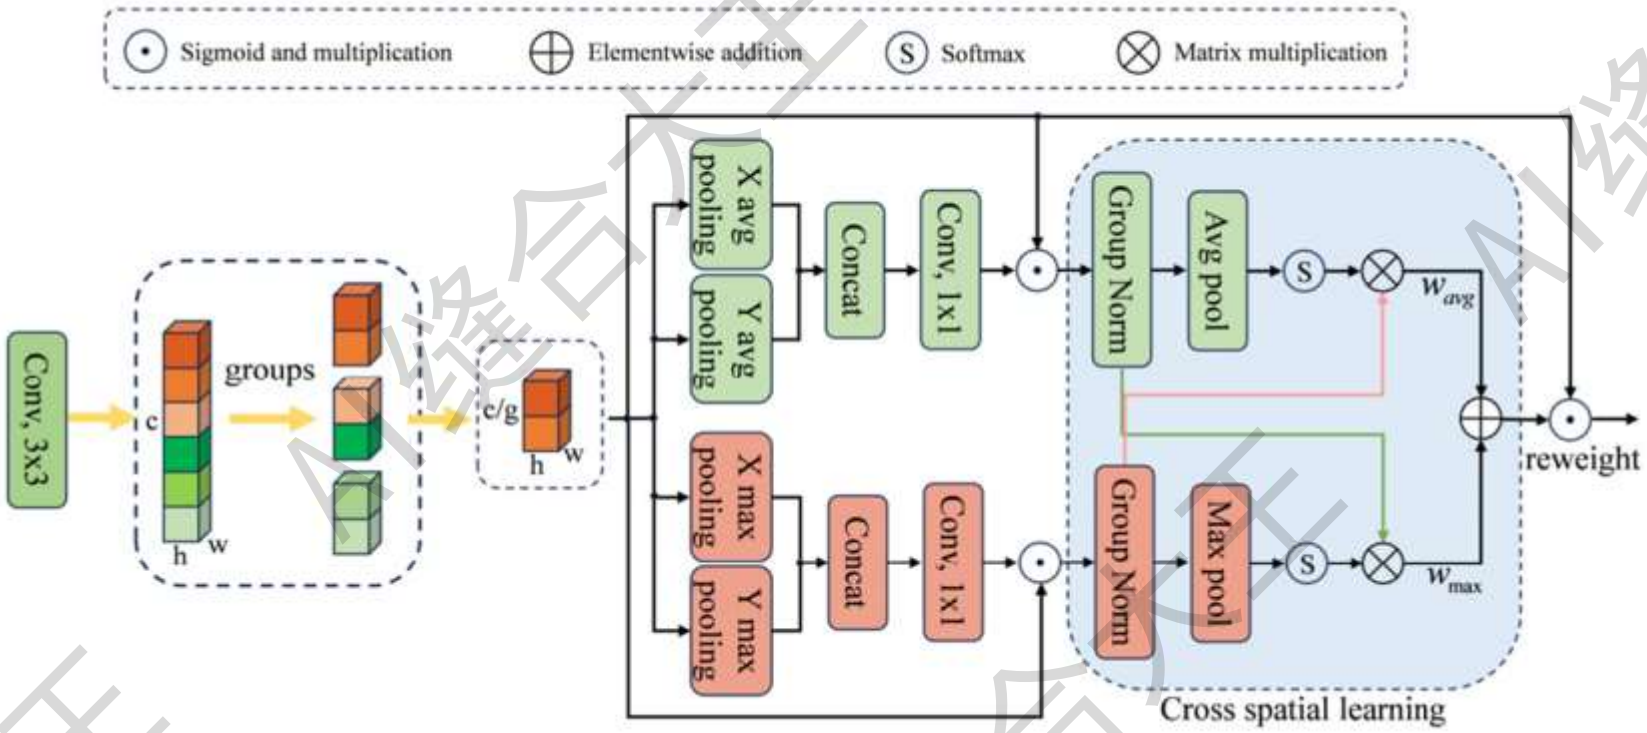

HPA模块作为即插即用的混合池化注意力机制，适用于高光谱分类、遥感、医学影像、目标检测、视频分析、NLP、多模态学习等领域，其主要作用是增强关键特征通道的权重，提升分类、检测、分割任务的准确性，同时降低计算复杂度。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

This WACV paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

CSAM: A 2.5D Cross-Slice Attention Module for Anisotropic Volumetric Medical Image Segmentation

Alex Ling Yu Hung Haoxin Zheng Kai Zhao Xiaoxi Du Kaifeng Pang Qi Miao
Steven S. Raman Demetri Terzopoulos Kyunghyun Sung
University of California, Los Angeles

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

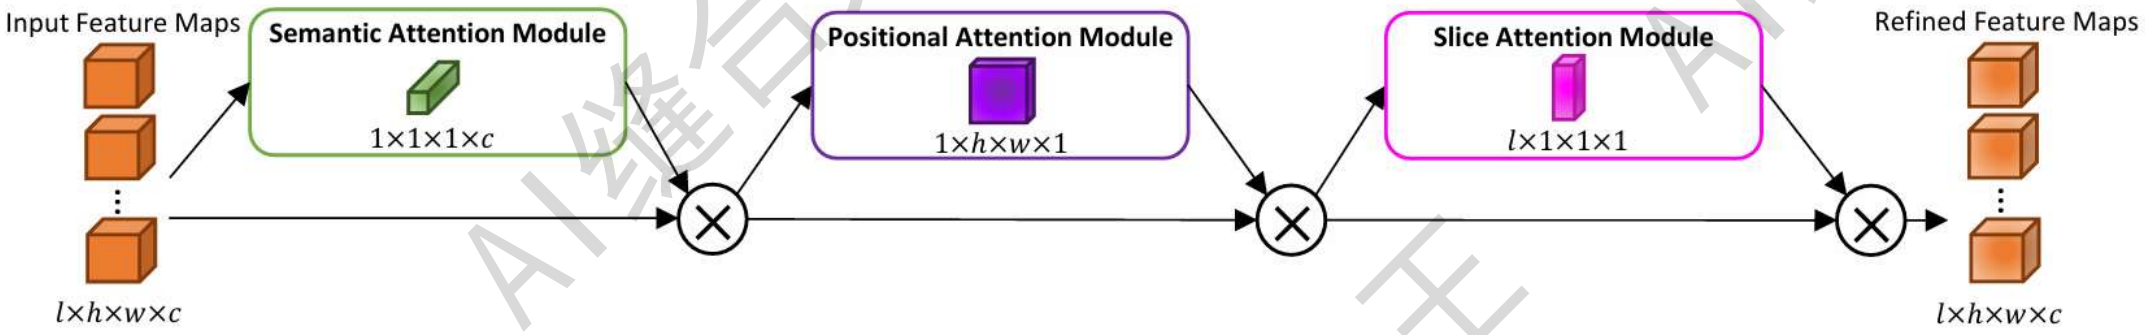

整体结构基于U-Net及其变体（nnU-Net、MSU-Net、nnU-Net++），并在编码器（Encoder）和解码器（Decoder）之间引入跨切片注意力模块（CSAM），用于高效捕捉3D医学图像中的跨切片信息。模型的输入为各向异性的医学图像体数据，首先通过2D CNN编码器提取多尺度特征，然后在不同尺度的特征图上应用CSAM，该模块依次执行语义注意力、位置注意力和切片注意力，分别关注全局语义信息、空间位置信息和不同切片间的信息相关性，同时利用切片不确定性建模提升鲁棒性。经过CSAM处理的特征图再通过2D CNN解码器进行逐步恢复，并最终输出分割结果。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Semantic	Positional	Slice	TZ	PZ
			87.9***	82.4***
✓			88.0***	83.2***
	✓		88.0***	83.0***
		✓	88.3***	83.7***
✓	✓		88.7***	84.2***
✓		✓	88.5***	83.9***
	✓	✓	88.4***	84.0***
✓	✓	✓	**89.9**	**85.2**

Table 1. Ablation study of zonal segmentation (DSC in %). Note: in this and subsequent tables, the labels *, **, *** indicate p-values of ≤ 0.1, ≤ 0.05, and ≤ 0.01, respectively. All the experiments involving cross-validation adhere to the same notation.

该表研究了CSAM的三个子模块（语义注意力、位置注意力、切片注意力）在前列腺MRI区域（TZ和PZ）分割任务中的影响。结果显示，单独使用任意一个注意力模块均能提高Dice分数（DSC），但组合使用多个注意力机制能进一步提升性能。

结论：每个注意力模块都对模型有贡献，而三者结合时性能最佳，说明CSAM的设计是有效的。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

	TZ	PZ
Slice without uncertainty	87.6***	82.8***
Slice with uncertainty	**88.3**	**83.7**
All without uncertainty	88.3***	84.7***
All with uncertainty	**89.9**	**85.2**

Table 2. Ablation study of the effect of using slice uncertainty (DSC in %).

该表进一步探讨了切片不确定性建模（Slice Uncertainty Modeling）对前列腺MRI分割的影响。结果表明，引入切片不确定性建模的CSAM在TZ和PZ的分割任务中均取得更好的表现（DSC分别提升至 89.9% 和 85.2%）。

结论：不确定性建模可以提高分割鲁棒性，减少切片间的不均衡影响，使得模型更适应各向异性医学图像。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

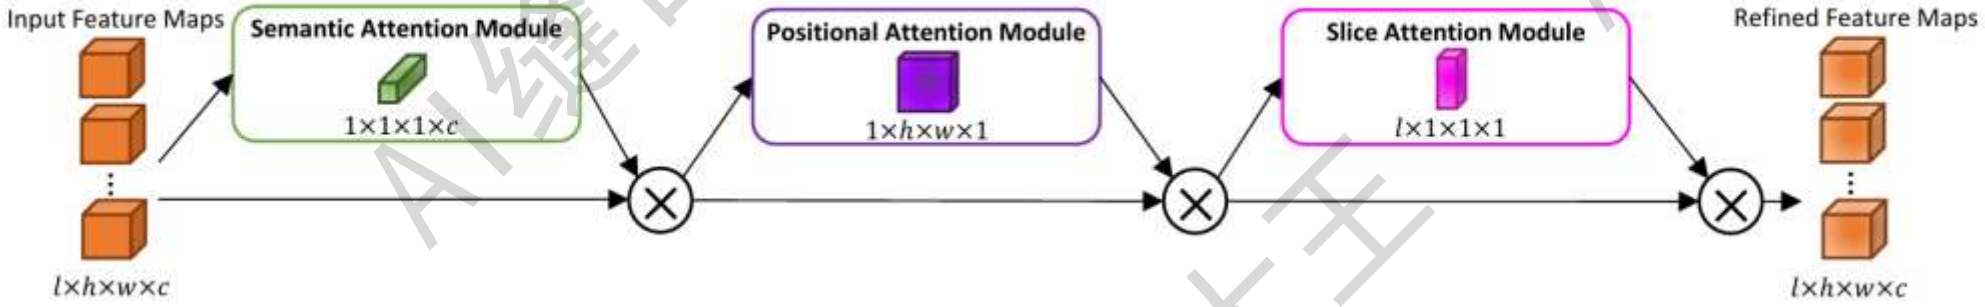

CSAM 作为一个即插即用的模块，主要适用于各向异性医学图像分割任务，特别是 MRI/CT 影像分析。它能增强跨切片信息建模，提高分割精度，同时减少计算成本，并提高模型的泛化能力和鲁棒性。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Image and Vision Computing 147 (2024) 105057

Contents lists available at ScienceDirect

Image and Vision Computing

journal homepage: www.elsevier.com/locate/imavis

ASF-YOLO: A novel YOLO model with attentional scale sequence fusion for cell instance segmentation

Ming Kang, Chee-Ming Ting *, Fung Fung Ting, Raphaël C.-W. Phan

School of Information Technology, Monash University, Malaysia Campus, Subang Jaya 47500, Malaysia

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

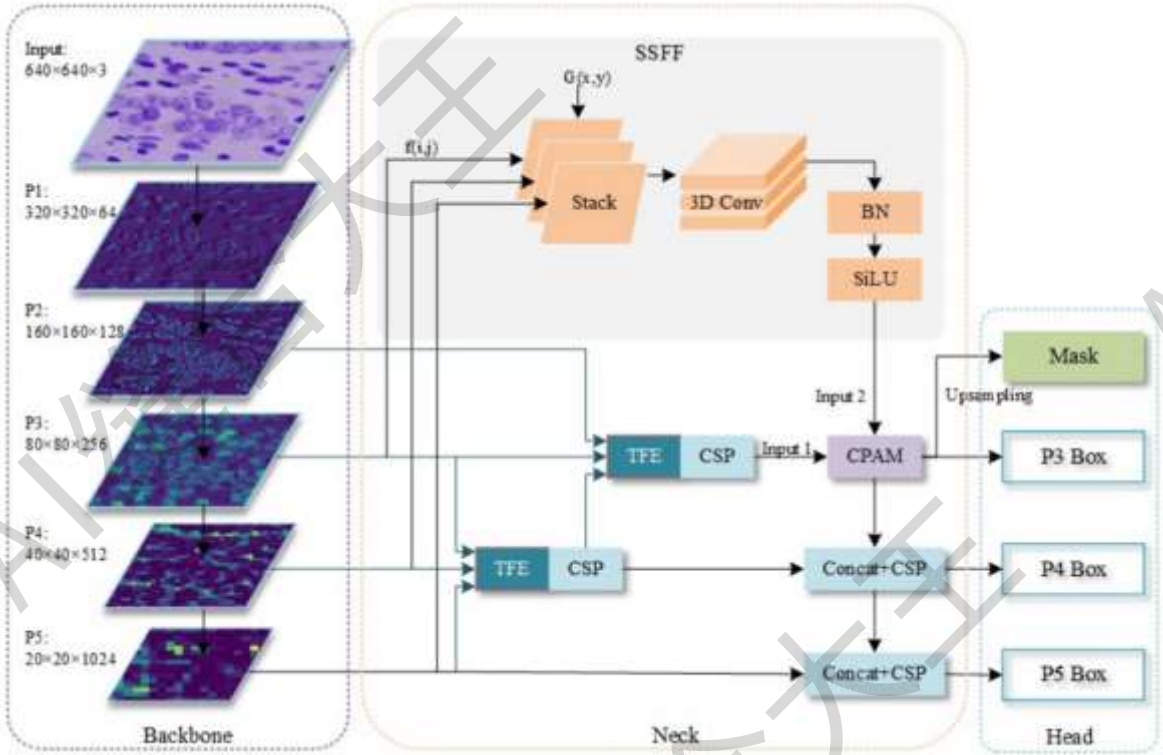

ASF-YOLO模型的整体结构基于YOLO框架，主要由CSPDarkNet53骨干网络、尺度序列特征融合模块（SSFF）、三重特征编码器（TFE）、通道与位置注意力机制（CPAM）、EIoU损失优化的检测头，以及Soft-NMS后处理组成。首先，CSPDarkNet53 作为骨干网络提取不同尺度的特征；然后，SSFF模块 通过尺度归一化、上采样和3D卷积整合多尺度特征信息，增强模型对不同大小目标的适应能力；接着，TFE模块 通过融合大、中、小尺度特征，提高密集小目标的检测能力；CPAM模块 则进一步优化特征信息的融合，使模型能够更精准地关注关键通道和空间位置；最后，EIoU损失 用于优化目标框回归，提高小目标的检测精度，而Soft-NMS 作为后处理方法，减少了密集目标之间的误检，确保ASF-YOLO在细胞实例分割任务上具备高精度和高速度的优势。

B站、小红书、微信公众号同步更新　　@ai缝合大王

ai缝合交流Q群：994264161

Table 3
Ablation study of main components of the ASF-YOLO on the DSB2018 dataset.

Method					Box		Mask	
Soft-NMS	EIoU	TFE	SSFF	CPAM	mAP_{50}	$mAP_{50:95}$	mAP_{50}	$mAP_{50:95}$
					0.876	0.616	0.855	0.502
✓					0.881	0.622	0.856	0.523
	✓				0.880	0.634	0.852	0.507
✓	✓	✓			0.891	0.653	0.867	0.542
✓	✓		✓		0.896	0.653	0.876	0.549
✓	✓	✓	✓		0.902	0.656	0.874	0.543
✓	✓	✓	✓	✓	0.910	0.676	0.887	0.558

目的：验证ASF-YOLO模型中各个模块（Soft-NMS、EIoU、TFE、SSFF、CPAM）对模型性能的贡献。
结果：仅使用YOLOv5l-seg（基础模型），Box mAP50 = 0.876，Mask mAP50 = 0.855。加入Soft-NMS 后，mAP50 提高到 0.881，说明Soft-NMS有效减少了小目标的误检和漏检。使用EIoU损失，mAP50:95（更严格的mAP评估）提高了1.8%，说明优化的目标框回归对小目标检测有帮助。加入TFE、SSFF、CPAM 模块后，Box mAP50 提高到 0.910，Mask mAP50 提高到 0.887，整体提升了分割精度，验证了这些模块的有效性。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 4
Effect of different attention mechanisms.

Method	mAP_{50}		Param (K)	FLOPs (M)
ASF-YOLO w/o attention (baseline)	0.902	0.874	0	0
+SENet [29]	0.901	0.879	+8.19	+1.65
+CBAM [35]	0.905	0.884	+16.48	+3.94
+CA [53]	0.903	0.8881	+12.32	+1.32
+CPAM (ours)	0.910	0.888	+12.23	+2.96

目的：对比不同注意力机制（SENet、CBAM、CA、CPAM）对ASF-YOLO模型性能的影响。

结果：不使用注意力机制（baseline）时，Box mAP50 = 0.902，Mask mAP50 = 0.874。SENet（通道注意力）对Mask mAP50提升较小（0.879）。CBAM（通道+空间注意力）提升较大，Box mAP50 = 0.905，Mask mAP50 = 0.884。CA（Coordinate Attention）也有效，但比CPAM稍差。CPAM（本文提出的注意力机制）取得最优效果（Box mAP50 = 0.910，Mask mAP50 = 0.888），表明其在通道和空间注意力优化方面更具优势。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 5
Effect of different convolution modules in the backbone of the proposed ASF-YOLO. The best results are in bold.

Dataset	Module	Box		Mask	
		mAP_{50}	$mAP_{50:95}$	mAP_{50}	$mAP_{50:95}$
DSB2018	C3	**0.910**	**0.676**	**0.887**	0.558
	C2f	0.867	0.633	0.859	0.558
BCC	C3	**0.911**	**0.737**	**0.898**	**0.645**
	C2f	0.855	0.619	0.835	0.570

目的：对比YOLOv5的C3模块和YOLOv8的C2f模块在ASF-YOLO中的表现。

结果：使用YOLOv5的C3模块时，Box mAP50 = 0.910，Mask mAP50 = 0.887。替换为YOLOv8的C2f模块后，Box mAP50下降到0.867，Mask mAP50下降到0.859。说明YOLOv5的C3模块更适合该任务，可能是因为C2f模块减少了通道连接，影响了多尺度特征的表达能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

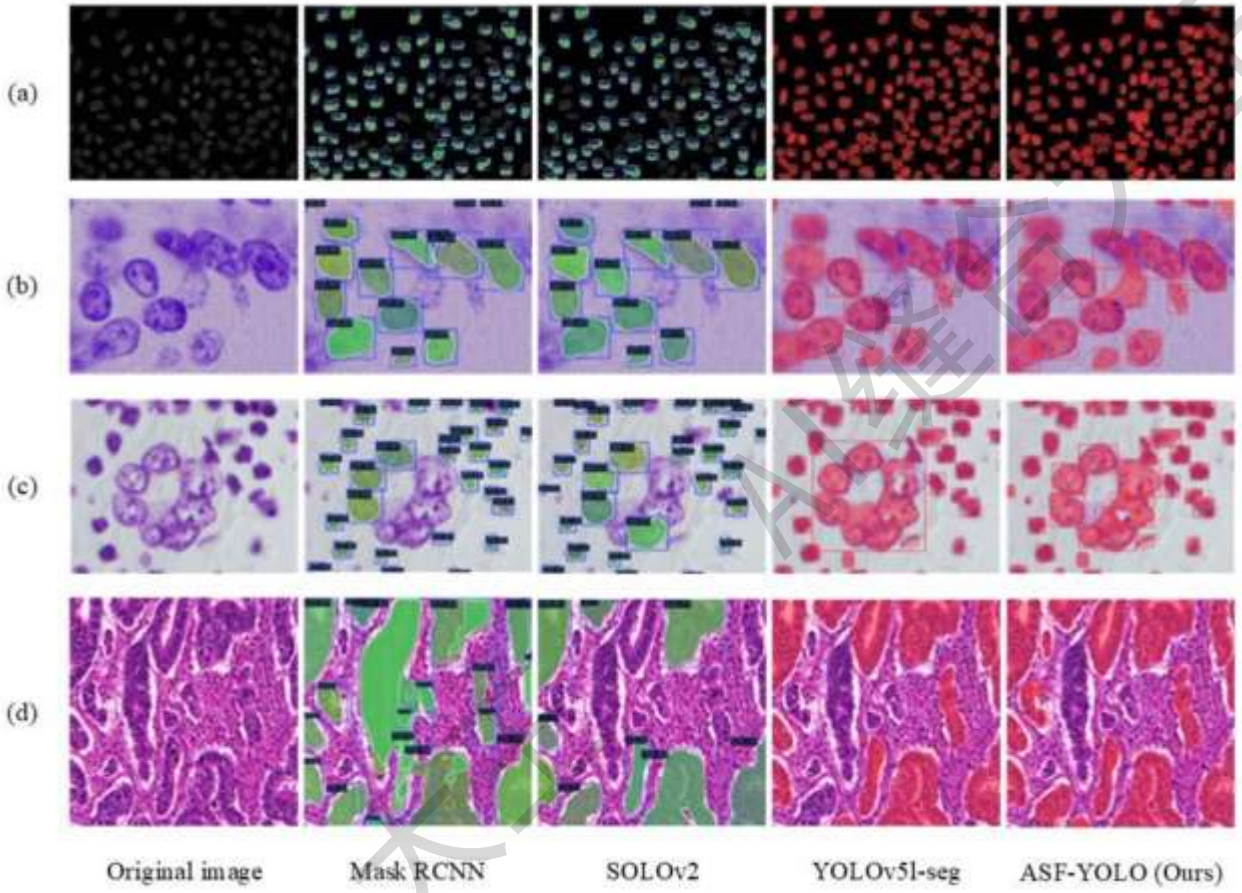

目的：展示ASF-YOLO与Mask R-CNN、SOLO、YOLOv5l-seg等方法在不同细胞图像上的分割效果。

结果：
在简单背景下（图6 a、b），各模型表现相似。
在复杂背景下（图6 c、d）：Mask R-CNN 出现较多误检，说明其两阶段架构在复杂情况下不够稳定。SOLO 出现较多漏检，无法捕捉所有小目标。YOLOv5l-seg 无法处理模糊边界的细胞。ASF-YOLO 对小目标检测和边界分割效果最好，证明其适用于密集小目标检测任务。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

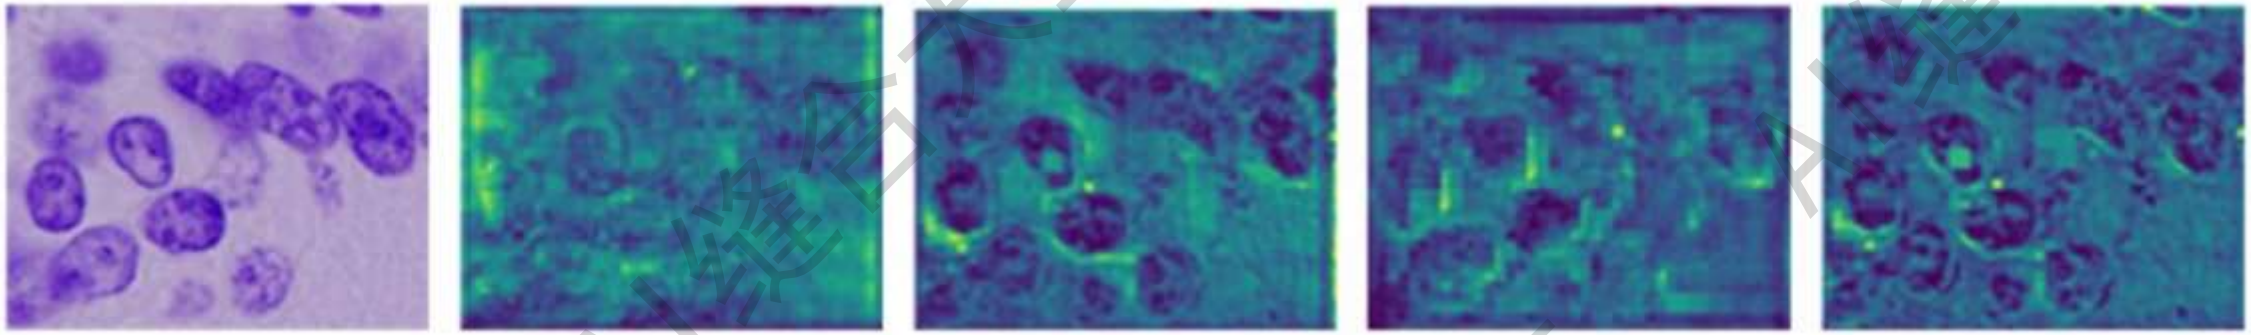

目的：可视化不同注意力机制（SENet、CBAM、CA、CPAM）对实例分割的影响。

结果：SENet仅优化了通道信息，分割边界仍有模糊。CBAM和CA对空间信息有所改进，但未能充分融合特征。CPAM生成的分割结果最清晰，能更好地提取小目标的特征。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

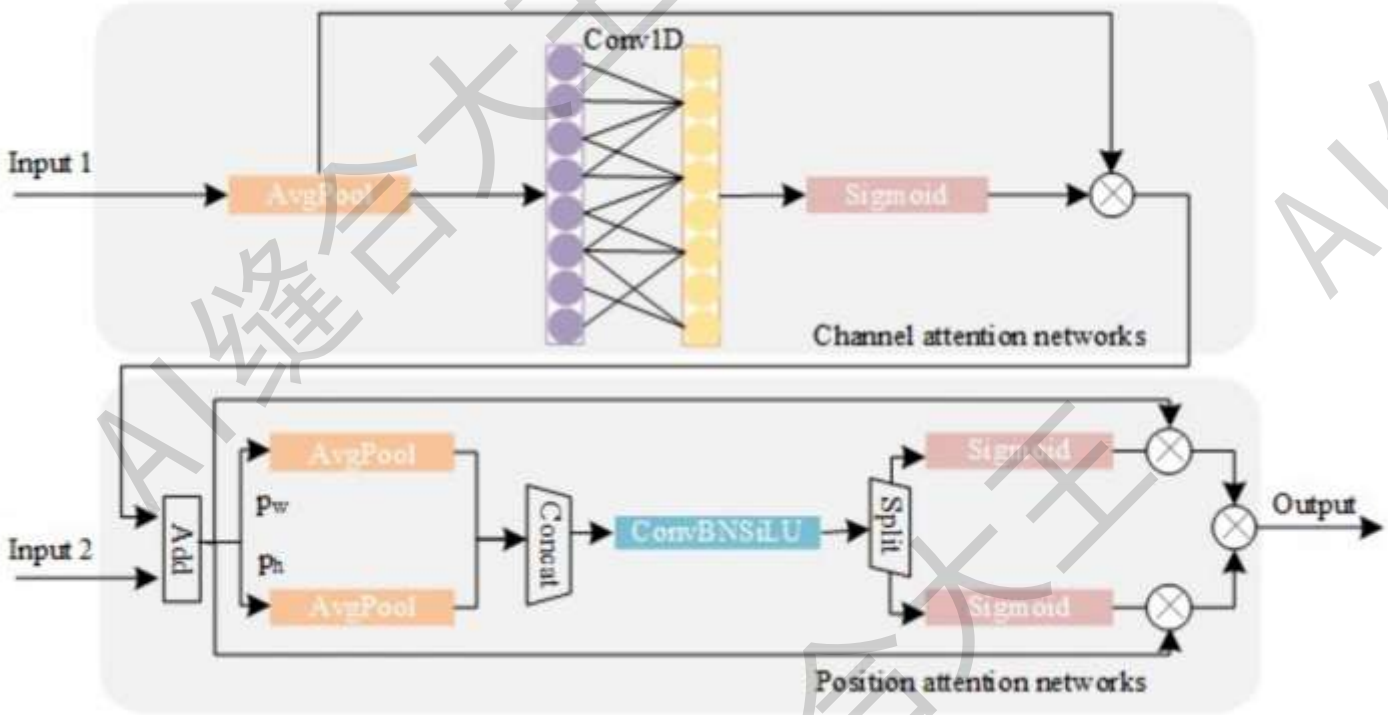

CPAM 作为一个即插即用的模块，主要适用于小目标检测、密集目标场景、多尺度目标检测和低对比度图像分割等任务。它通过结合通道注意力和位置注意力，能够有效提升目标检测、实例分割、医学影像分析和遥感目标识别的性能，且计算量低，适用于实时任务，使其成为高效的深度学习增强模块。

B站、小红书、微信公众号同步更新 @ai缝合大王