ai缝合交流Q群：994264161

FASTer: Focal Token Acquiring-and-Scaling Transformer for Long-term 3D Object Detection

Chenxu Dang Zaipeng Duan PeiAn Xinmin Zhang Xuzhong Hu Jie Ma*
Huazhong University of Science and Technology

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

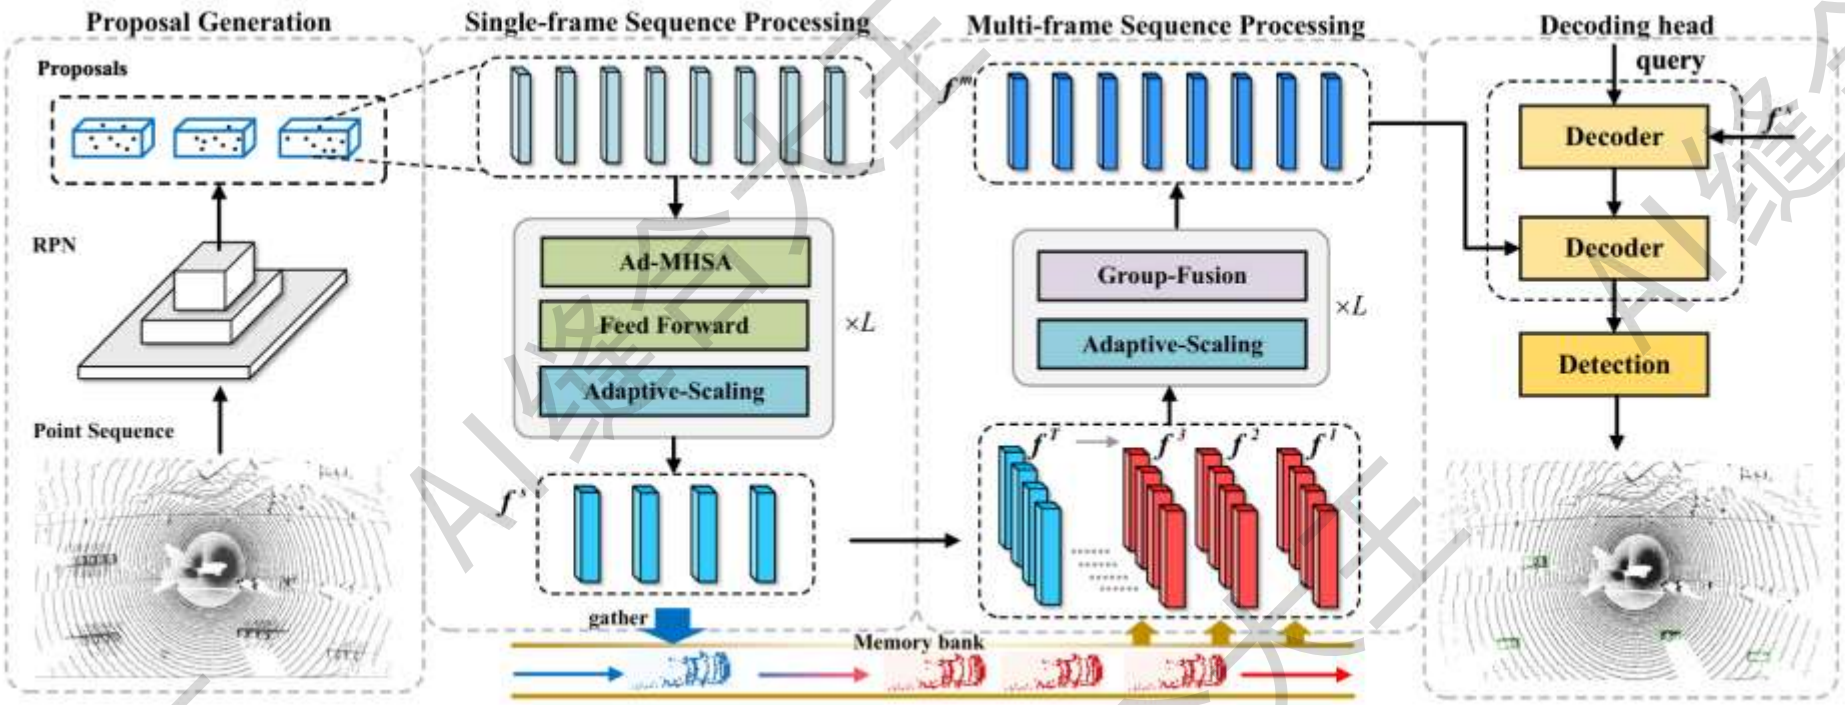

FASTer 模型通过 自适应焦点令牌获取（Adaptive Scaling）策略，动态筛选并存储关键点云信息，以降低计算和存储成本。在 单帧处理（SSP）中，它通过自适应缩放提取最具信息量的点，并进行特征编码；在 多帧处理（MSP）中，引入 分组分层融合（Grouped Hierarchical Fusion），高效整合长时序点云数据，增强全局信息交互。最终，采用 双层 Transformer 解码器 结合当前帧与历史帧信息，优化 3D 目标检测结果。该方法在 Waymo Open Dataset 上实现了 最优性能（SOTA），兼具高精度和高效率。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

SD	MD	IGF	ME	mAPH(L1)	mAPH(L2)
✓	✓	✓	✓	81.49	75.92
✗	✓	✓	✓	81.01(-0.48)	75.51(-0.41)
✓	✗	✓	✓	79.02(-2.47)	73.19(-2.73)
✓	✓	✗	✓	81.06(-0.43)	75.45(-0.47)
✓	✓	✓	✗	80.31(-1.18)	74.72(-1.20)

Table 5. Ablation experiments for the core components. **SD** and **MD** mean the decoder layers of SSP and MSP respectively while **ME** means the motion encoding.

该表评估了不同核心模块对模型性能的影响，分别去除 SSP 解码器（SD）、MSP 解码器（MD）、组内融合（IGF）和运动特征编码（ME），并观察其对 mAPH（L1 和 L2）的影响。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Config	Concat	Vehicle	Pedes	Cyclist
S-T Fusion	✗	75.57	76.61	75.58
Cross Atten[2]	✓	75.22	76.03	75.35
BiFA[8]	✓	75.01	75.97	75.25

Table 6. Comparative experiments of different temporal-spatial fusion paradigms. **Concat** means that all sequences are decoded separately and then concatenated. APH on Level2 is reported.

该表比较了不同的时空融合方法对 L2 mAPH 的影响，包括：直接拼接（Concat）时序特征（无融合）。使用 跨注意力（Cross Attention）方法进行特征融合。使用 双向特征聚合（BiFA）进行融合（参考 MSF）。使用 论文提出的 S-T 融合策略。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Strategies of Scaling	Vehicle	Pedestrian	Cyclist
	L1 / L2	L1 / L2	L1 / L2
Adaptive	82.77/75.57	83.35/76.61	78.37/75.58
Supervised	82.18/74.85	83.22/76.50	77.96/75.27
Atten Mask	81.95/74.60	83.21/76.50	77.80/75.12
Random	81.45/74.11	82.79/76.11	77.63/74.97

Table 7. Comparison of the effect of different scaling strategies.

该表比较了不同的点云采样策略对 L1/L2 mAPH 的影响，包括：Adaptive Scaling（论文提出的方法）Supervised Scaling（基于有监督学习的点云采样）Attention Mask（基于注意力掩码进行点筛选）Random Sampling（随机采样）

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Inputted Frames	L1	L2
	mAP / mAPH	mAP / mAPH
4	81.94 / 80.58	76.30 / 74.98
8	82.34 / 81.03	76.78 / 75.51
16	82.74 / 81.49	77.22 / 75.92
24	82.83 / 81.56	77.31 / 76.00
32	82.90 / 81.62	77.38 / 76.06

Table 8. Comparison of different numbers of historical frames.

该表研究了不同历史帧数对检测结果的影响，分别测试了 4、8、16、24 和 32 帧的情况。结果表明：L2 mAPH 随着帧数增加逐渐提高，从 4 帧的 74.98% 提升至 32 帧的 76.06%。但当帧数从 16 增加到 32 时，提升幅度开始减小，说明过长的时间窗口可能带来冗余信息，影响计算效率。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

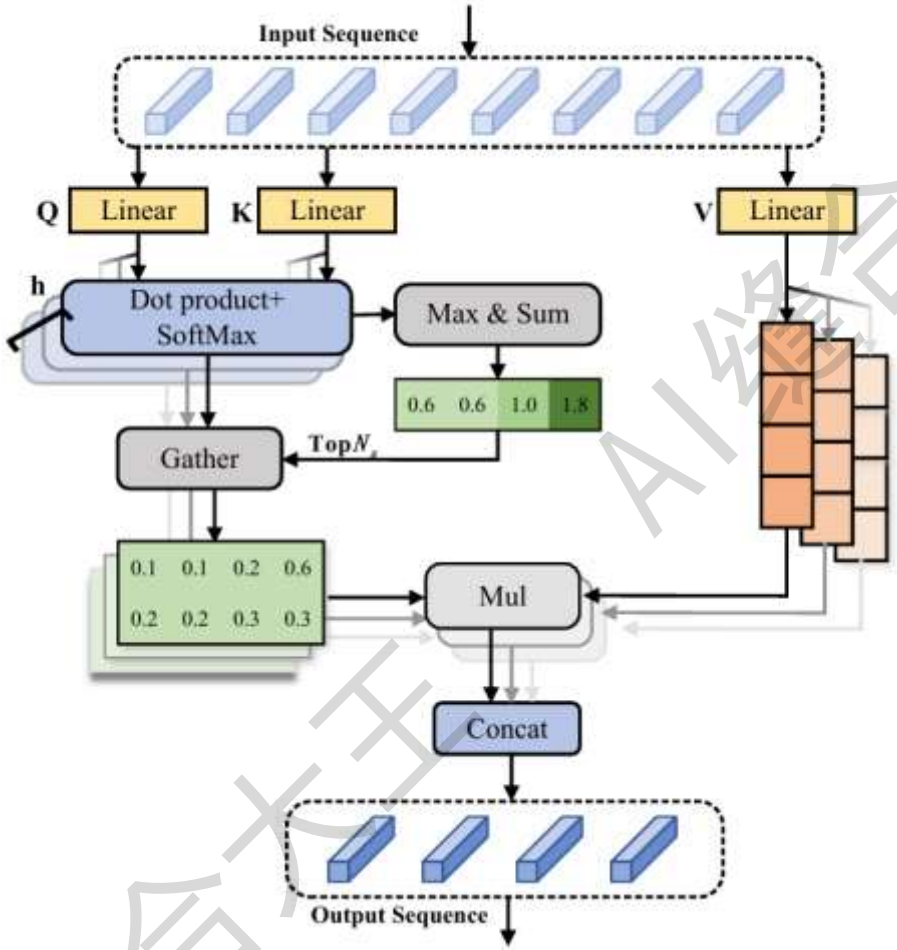

Ad-MHSA 作为即插即用的模块，适用于 3D 目标检测、语义分割、点云处理、视频分析、NLP 长文本处理等场景，主要作用是 筛选重要特征、降维和加速计算。它可以无缝集成到主流 Transformer 结构中，特别适用于 大规模数据、高计算量任务，在 自动驾驶、计算机视觉、多模态 AI 任务 中有广泛的应用前景。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

AutoLUT: LUT-Based Image Super-Resolution with Automatic Sampling and Adaptive Residual Learning

Yuheng Xu* Shijie Yang* Xin Liu Jie Liu✉ Jie Tang Gangshan Wu
State Key Laboratory for Novel Software Technology, Nanjing University, Nanjing 210023, China
superkenvery@gmail.com {sjyang,xinliu2023}@smail.nju.edu.cn {liujie,tangjie,gswu}@nju.edu.cn

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

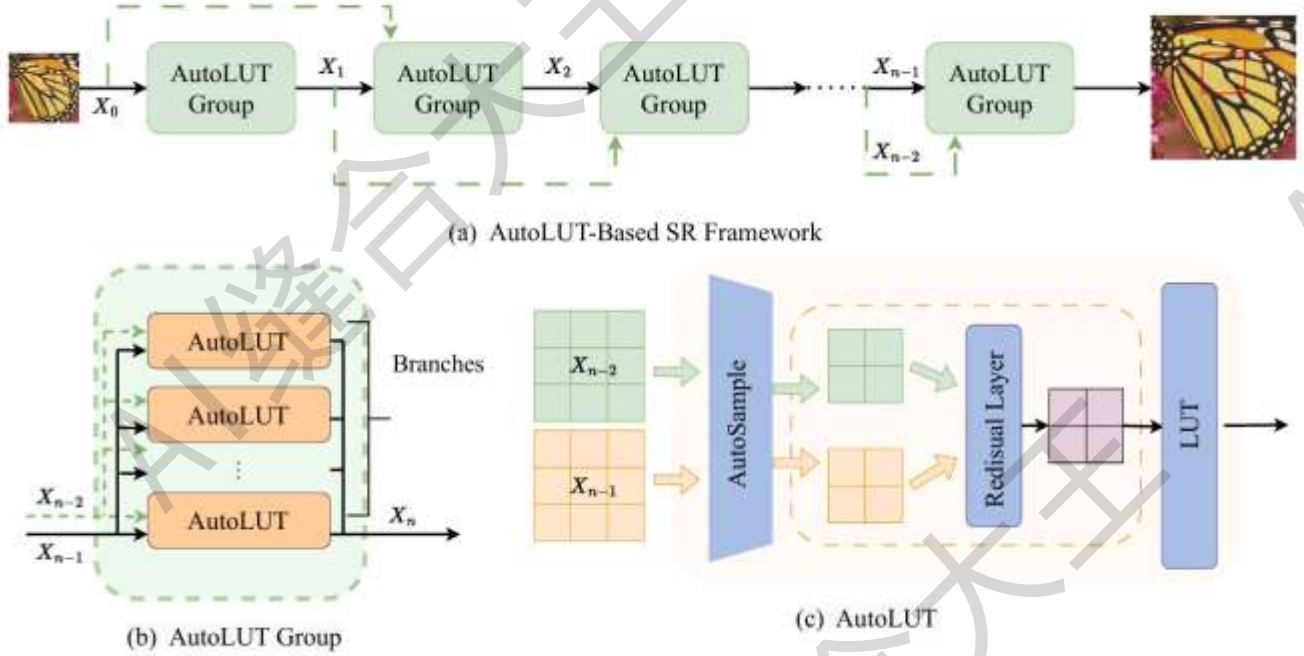

模型整体结构是一个基于AutoLUT的超分辨率框架，核心由自动采样（AutoSample）和自适应残差学习（AdaRL）两大即插即用模块组成。AutoSample通过可学习的卷积权重在训练中自适应地选择采样位置，动态扩展感受野，提升特征提取能力；AdaRL则在特征融合时引入加权残差连接，增强跨层信息流，同时保持输出在查找表（LUT）可接受的数值范围内。整体框架采用多分支结构，灵活调整分支数量与采样区域，实现更高效的像素级超分辨率重建，兼顾性能与低存储开销。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 2. Ablation study on different branch numbers and sample sizes for ×4 super-resolution on MuLUT.

	Configuration			PSNR/SSIM				
	Branches	**Sample Size**	**Storage Size**	**Set5**	**Set14**	**BSDS100**	**Urban100**	**Manga109**
①	2	3	2.710MB	30.73/0.8677	27.68/0.7566	26.92/0.7130	24.54/0.7233	28.14/0.8680
②		3	4.065MB	30.79/0.8693	27.72/0.7579	26.94/0.7142	24.57/0.7249	28.20/0.8696
③	3	5	4.067MB	30.85/0.8699	27.77/0.7584	26.96/0.7144	24.60/0.7257	28.27/0.8706
④		7	4.069MB	30.82/0.8694	27.72/0.7578	26.95/0.7146	24.58/0.7247	28.20/0.8693
⑤	4	3	5.424MB	30.83/0.8700	27.73/0.7586	26.96/0.7148	24.60/0.7262	28.26/0.8708

说明内容：该表探讨了“分支数量”和“采样尺寸”两个超参数对模型性能的影响。

实验结论：随着分支数量从2增加到3、4，PSNR指标逐步上升，说明更多分支能提取更丰富的特征，但存储开销也随之增加。当采样尺寸（sample size）由3增大到5时，PSNR继续提升，但增大到7时反而略微下降，说明过大的感受野可能引入冗余信息，导致性能轻微下降。最优配置为“3个分支 + 采样尺寸5”，在性能与存储之间取得良好平衡。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 3. Ablation study on AutoSample and AdaRL for ×4 super-resolution.

	Automatic Sampling	AdaRL	Set5	Set14	BSDS100	Urban100	Manga109
①	-	-	30.60/0.8653	27.60/0.7541	26.86/0.7110	24.46/0.7194	27.90/0.8633
②	✓	-	30.63/0.8657	27.63/0.7550	26.86/0.7112	24.49/0.7204	28.02/0.8627
③	-	✓	30.70/0.8687	27.67/0.7572	26.89/0.7136	24.51/0.7242	28.07/0.8685
④	✓	✓	30.79/0.8693	27.72/0.7579	26.94/0.7142	24.57/0.7249	28.20/0.8696

说明内容：该表研究了AutoSample和AdaRL两个模块各自及组合对性能的提升效果。

实验结论：单独使用AutoSample或AdaRL都能带来性能提升，其中AdaRL的提升幅度更大。同时使用AutoSample + AdaRL时，获得最优的PSNR和SSIM，说明两个模块具有互补性，结合后可最大化提升超分性能。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

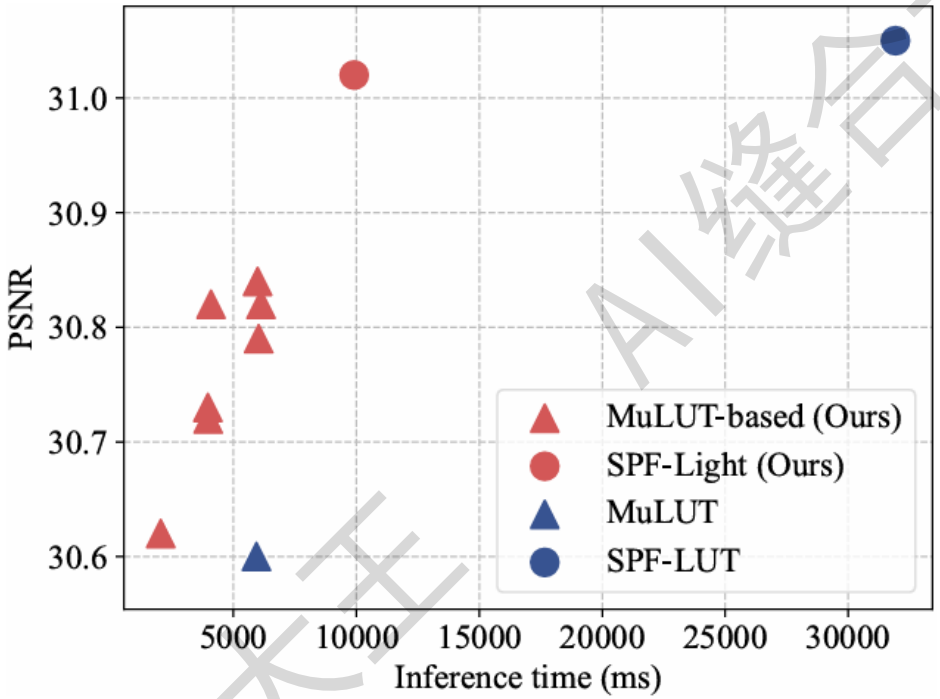

说明内容：这是一个 推理时间 vs PSNR”的散点图，展示了不同方法在移动设备上的效率与性能权衡。

实验结论：集成AutoSample和AdaRL的模型在推理速度和超分效果（PSNR）之间达到更优的Pareto最优解（图中红色区域）。相比原始MuLUT和SPF-LUT，论文提出的方案在保证甚至提升PSNR的前提下，大幅降低推理时间，验证了新模块对轻量化部署的有效性。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

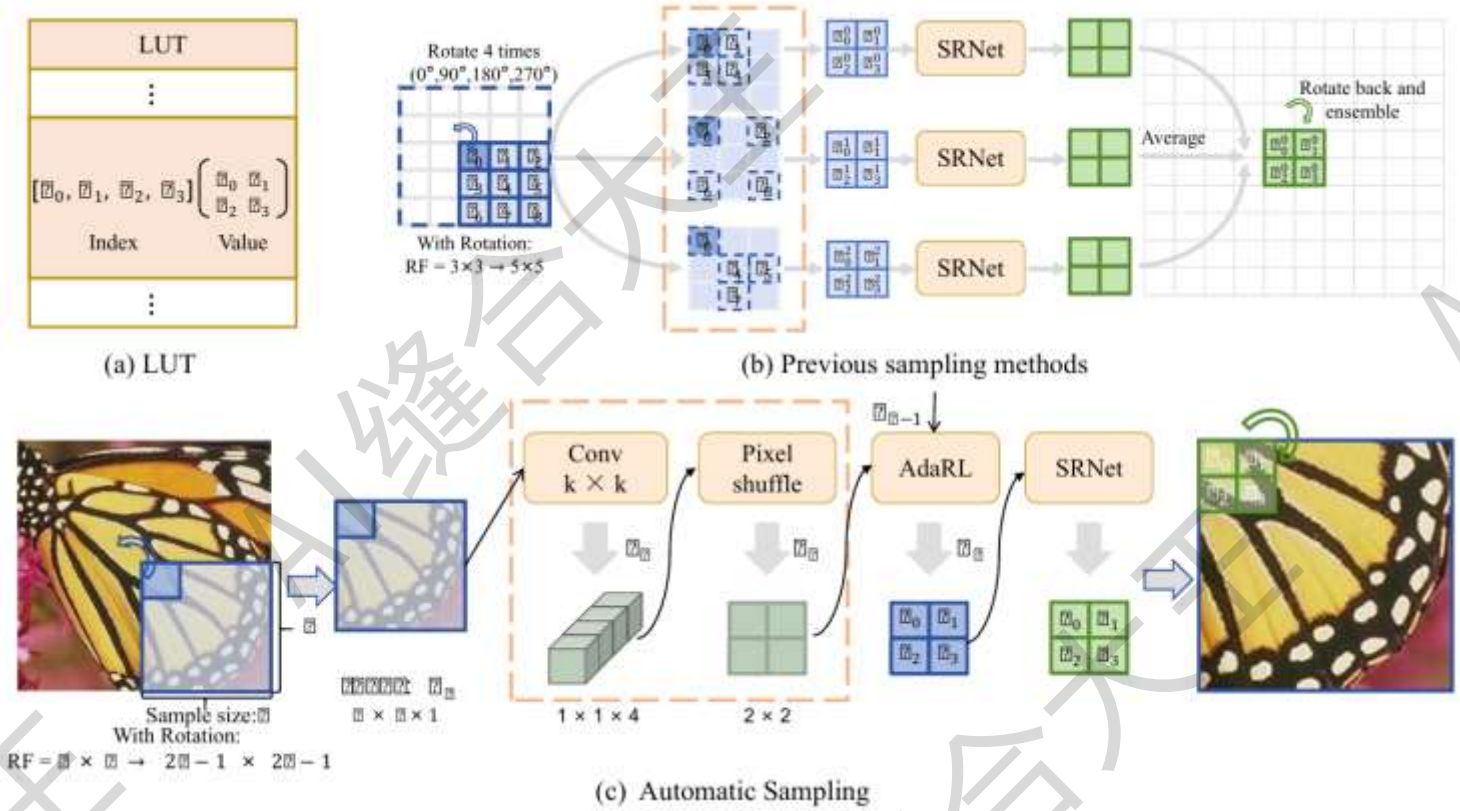

AutoSample是一个即插即用的自适应采样模块，专为LUT类超分辨率网络设计，特别适用于移动端、IoT设备等资源受限场景。它通过可学习的卷积权重在训练中动态调整采样策略，实现灵活扩展感受野并提升特征提取能力，取代传统固定采样方式。AutoSample不仅能减少分支数量，降低存储与计算开销，同时在推理阶段不引入额外负担，保持极高效率。整体上，它帮助LUT网络在轻量化条件下实现更优的性能、速度与存储平衡。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Efficient Visual State Space Model for Image Deblurring

Lingshun Kong[1], **Jiangxin Dong**[1], **Ming-Hsuan Yang**[2,3,4], **Jinshan Pan**[1]
[1]Nanjing University of Science and Technology
[2]University of California, Merced [3]Yonsei University [4]Google Research

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

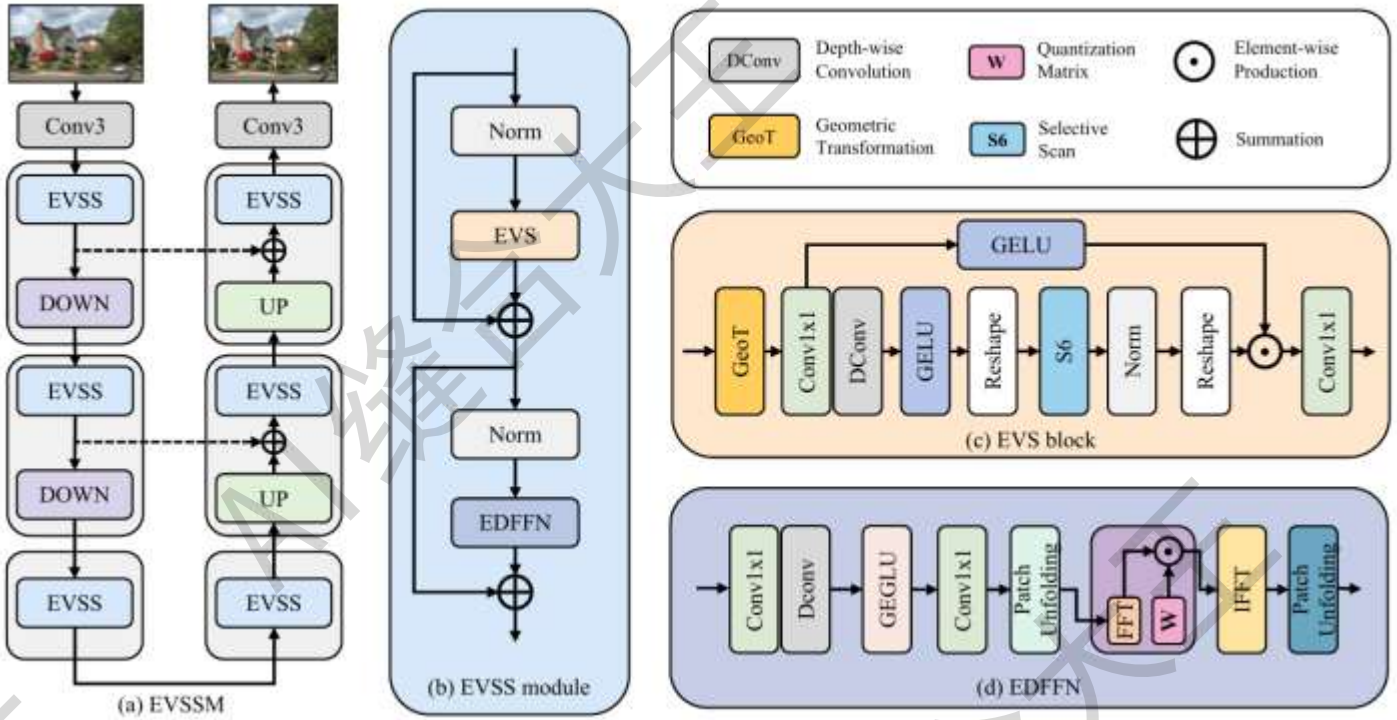

EVSSM（Efficient Visual State Space Model）是一种高效的图像去模糊模型，采用 编码-解码（encoder-decoder） 框架，并结合 状态空间模型（SSM） 以降低计算复杂度。核心创新在于 高效视觉扫描块（EVS block），通过 单方向扫描 + 几何变换（翻转或转置） 提取非局部信息，避免传统多方向扫描的高计算成本。此外，模型集成了 高效判别性频率域前馈网络（EDFFN），在 FFN 末端进行频率筛选，以增强清晰度。实验表明，EVSSM 在多个 benchmark 数据集上优于现有 CNN 和 Transformer 方法，同时具有更快的推理速度和更低的计算开销，使其成为高分辨率图像去模糊任务的高效解决方案。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 6: Effectiveness of the proposed EVS block, evaluated on the GoPro dataset [31].

Scanning mode	Parameters (M)	FLOPs (G)	Runtime (ms)	PSNR/SSIM
one-direction	17.1	126	87.9	33.99/0.9683
two-direction	18.3	135	122.7	34.08/0.9687
four-direction	20.1	148	182.6	34.05/0.9686
EVS (ours)	17.1	126	88.7	**34.13/0.9690**

比较了 单方向扫描（one-direction）、双方向扫描（two-direction）、四方向扫描（four-direction） 以及 EVS block（本文方法） 在 GoPro 数据集 上的表现。

评价指标：参数量（M）、FLOPs（G）、运行时间（ms）、PSNR/SSIM。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 7: Effectiveness of the geometric transformation, evaluated on the GoPro dataset [31].

Method	Scanning in one direction	Transpose	Flip	Parameters (M)	FLOPs (G)	Runtime (ms)	PSNR/SSIM
w/o F&T	✔	✗	✗	17.1	126	87.9	33.99/0.9683
w/o F	✔	✔	✗	17.1	126	88.4	34.05/0.9686
w/o T	✔	✗	✔	17.1	126	88.5	34.03/0.9684
EVSSM (ours)	✔	✔	✔	17.1	126	88.7	**34.13/0.9690**

研究了 仅使用单方向扫描（w/o F&T）、仅使用转置（w/o F）、仅使用翻转（w/o T）、同时使用翻转+转置（EVSSM）的去模糊效果。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 8: Model complexity of the top-performance methods on the GoPro dataset, evaluated on images with the size of 256 × 256 pixels. All the results are obtained on a machine with an NVIDIA RTX 3090 GPU.

Method	DMPHN [55]	IPT [2]	MPRNet-local [6]	Restormer-local [6]	GRL [25]	FFTformer [21]	EVSSM (ours)
Parameters (M)	21.7	114	20.1	26.1	20.20	**16.6**	17.1
FLOPs (G)	234	376	760	155	1289	131	**126**
Runtime (ms)	143	298	95	286	518	132	**89**

比较了不同方法的 参数量（M）、FLOPs（G）以及运行时间（ms）。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

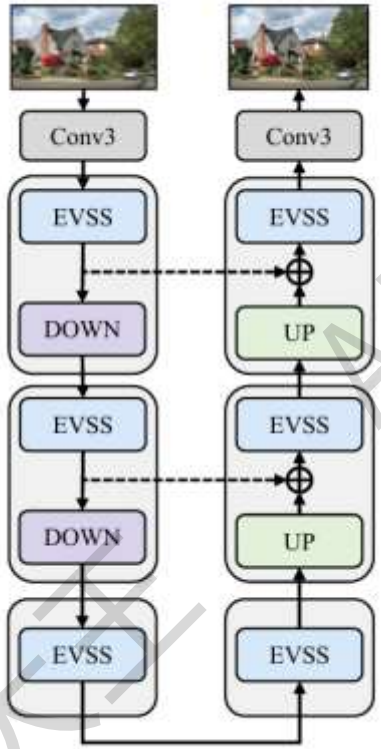

(a) EVSSM

EVSSM作为 即插即用（plug-and-play）模块，它的核心作用是 低计算量地提取非局部信息，从而提升图像恢复质量。适用于运动去模糊、超分辨率、去噪、去雨/去雾等高分辨率图像恢复任务，特别适用于 计算资源受限的场景，如 移动端、实时处理和边缘计算。它在 降低计算复杂度的同时，提升了全局特征提取能力，提供了一种比 Transformer 计算更轻量、比 CNN 更具全局感知能力的高效视觉建模方案。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

IMPROVED VIDEO VAE FOR LATENT VIDEO DIFFUSION MODEL

Pingyu Wu[1,2,*], **Kai Zhu**[1,2,†], **Yu Liu**[2], **Liming Zhao**[2], **Wei Zhai**[1,†], **Yang Cao**[1], **Zheng-Jun Zha**[1]
[1] University of Science and Technology of China [2] Tongyi Lab

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

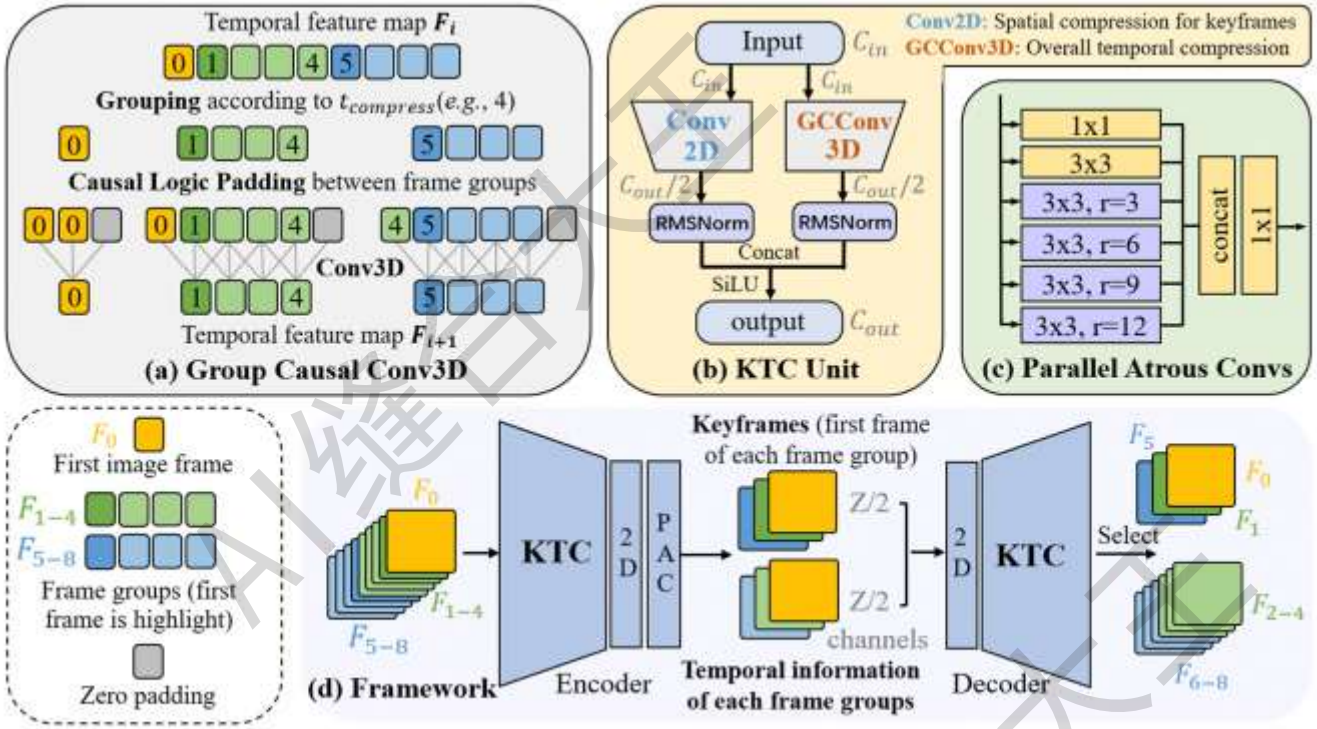

Figure 2: (a-c) **Basic components** of IV-VAE. (d) **Overall Framework**.

IV-VAE 是一种改进的 视频变分自编码器（Video VAE），采用 U-Net 结构，结合 关键帧驱动的时序压缩（KTC） 和组因果卷积（GCConv） 以优化视频的时空压缩能力。模型通过 双分支 KTC 结构，分别处理关键帧的空间压缩（2D 分支）和帧间的时间压缩（3D 分支），提高初始化质量并加快训练收敛速度。同时，GCConv 解决了传统因果卷积导致的帧间信息交互不均衡问题，使视频重建更加平滑。此外，模型引入 时间运动感知增强（TMPE），通过膨胀卷积和多重注意力机制提升对高速运动和高分辨率视频的感知能力，并采用 缓存机制 以优化长视频推理。实验结果表明，IV-VAE 在多个基准数据集上达到了 SOTA 级别的视频重建和生成能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 4: Left: **Ablation study**. (A) represents the baseline method Causal VAE. Right: **Training loss curves for different structures.** The training loss is the sum of MAE, LPIPS, and KL losses.

	Setting			Kinetics-600 val		
	GCConv	KTC	TMPE	PSNR↑	SSIM↑	LPIPS↓
(A)				31.29	0.9042	0.05233
(B)	✓			31.64	0.9082	0.05028
(C)		✓		31.86	0.9116	0.04865
(D)	✓	✓		32.12	0.9145	0.04744
(E)	✓	✓	✓	**32.24**	**0.9158**	**0.04725**

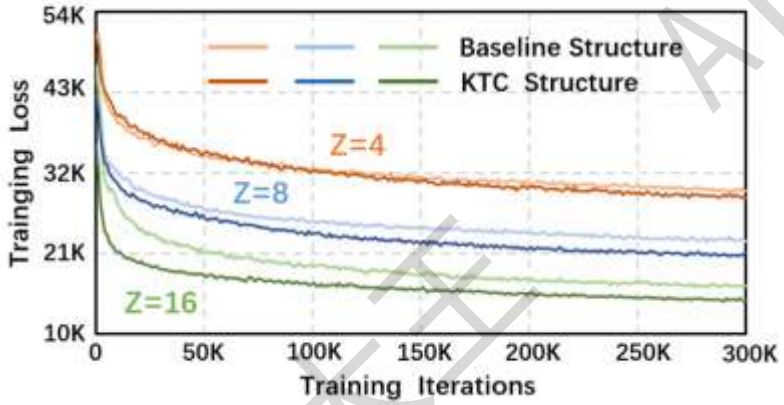

作用：验证 组因果卷积（GCConv）、关键帧驱动的时序压缩（KTC）和时间运动感知增强（TMPE） 的贡献。

结论：GCConv 可以有效提高视频帧间信息交互能力，减少帧间不均衡问题。KTC 结构能优化时空压缩初始化，提升模型的学习效率。TMPE 提升了对高分辨率和快速运动视频的感知能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 5: **Ablation for branch selection.**

	Params	PSNR↑	SSIM↑	LPIPS↓
(2D+3D)	**107M**	32.24	0.9158	0.04725
(3D+3D)	132M	**32.31**	**0.9163**	**0.04704**

作用：验证 KTC 结构中 双分支（2D+3D）是否比 双 3D 分支（3D+3D）更高效。

结论：3D+3D 仅带来 极小的 PSNR 提升（32.31 vs 32.24），但 参数量增加 23%。说明 2D+3D 结构更高效，在保持相似性能的情况下减少计算开销。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 6: **Increasing parameters**. The time is tested on one A800 GPU with BF16 precision.

Method	Params	Kinetics-600			A 25-frame 1024×1024 Video Reconstruction Time
		PSNR↑	SSIM↑	LPIPS↓	
CogX-VAE	215M	38.38	0.9677	0.02866	11.4s
Ours (Z=16, dim=64)	108M	39.02	0.9685	0.02280	**6.2s**
Ours (Z=16, dim=96)	242M	**39.57**	**0.9711**	**0.02054**	10.7s

作用：测试 更大模型（Z=16, dim=96）是否能进一步提升性能。

结论：增加参数量可以提升 PSNR 和 LPIPS，但计算开销更大（视频重建时间从 6.2s 增加到 10.7s）。IV-VAE 在参数量适中时（Z=16, dim=64）已超越其他 SOTA 方法。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 7: **Cache mechanism** vs **Overleap mechanism.**

Reconstruction approach	Input: A 49-frame 1024×1024 Video		
	Video clipping	Memory Usage	Time Usage
Single-Step	49-frame * 1	76.3G	**12.7s**
Overleap mechanism	5-frame * 12	14.3G	14.7s
Cache mechanism	1-frame + 4-frame*12	**14.1G**	13.0s

作用：对比 缓存机制 和 传统重叠机制 处理长视频的效率和内存占用。

结论：缓存机制比重叠机制更高效，减少了显存占用，同时避免了重复计算，提高长视频处理效率。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

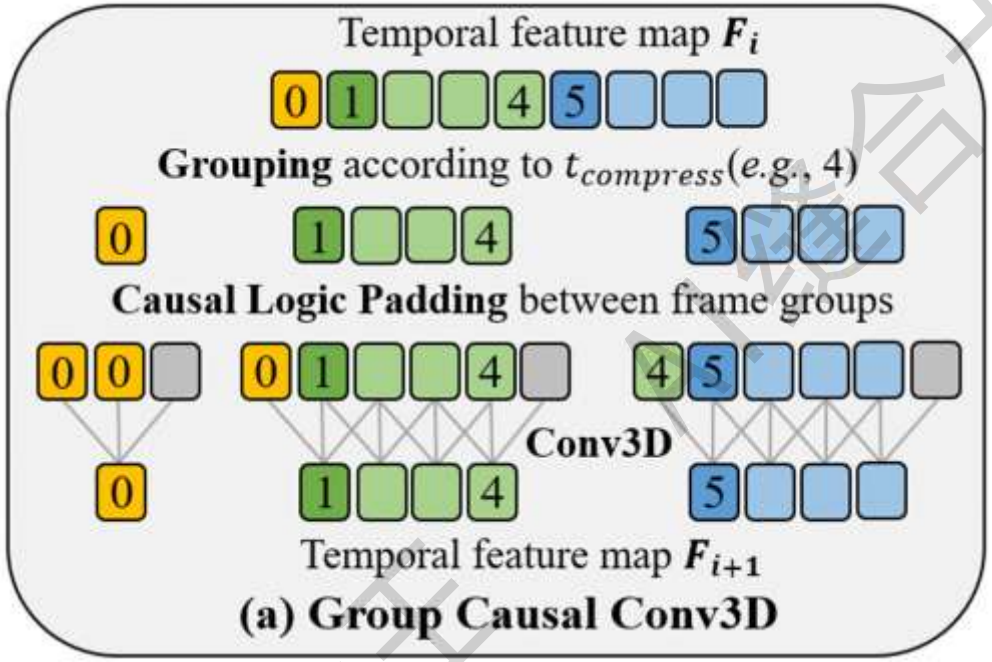

(a) Group Causal Conv3D

GCConv 作为 一个可即插即用的时序建模模块，适用于 视频压缩、插帧、动作识别、时间序列分析等任务，可以 改善帧间信息不均衡问题，减少帧间闪烁，提高模型的收敛速度和时空建模能力，在视频生成、长视频处理、时序数据建模等任务中具有广泛应用价值。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Cross-modal Causal Relation Alignment for Video Question Grounding

Weixing Chen[1] Yang Liu[1*] Binglin Chen[1] Jiandong Su[2] Yongsen Zheng[3] Liang Lin[1]
[1]Sun Yat-sen University [2]Shenzhen Institute of Advanced Technology
[3]Nanyang Technological University, Singapore
{chenwx228,chenblin9}@mail2.sysu.edu.cn,liuy856@mail.sysu.edu.cn
jiandong.laurence.su@gmail.com,yongsen.zheng@ntu.edu.sg,linliang@ieee.org

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

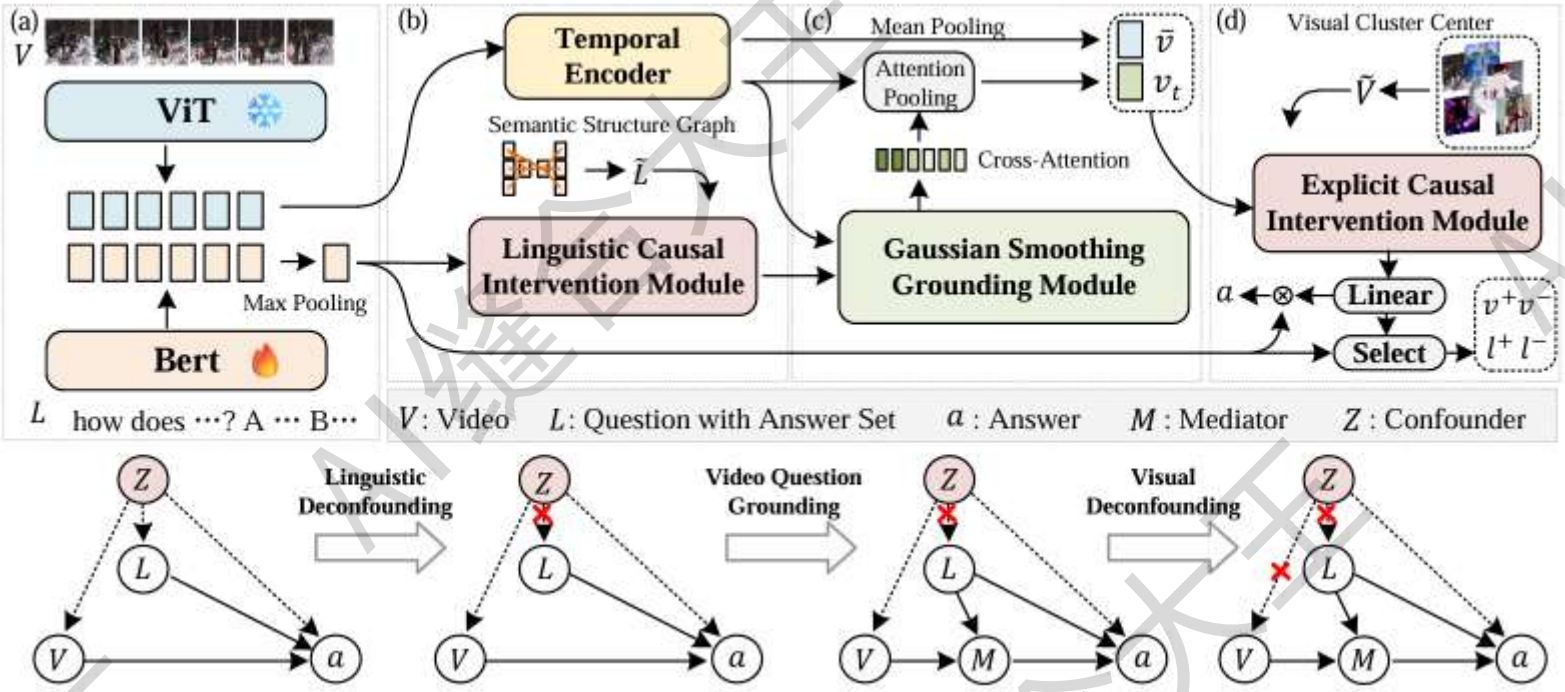

跨模态因果关系对齐（CRA）框架，旨在解决视频问题定位（VideoQG）中的伪相关性问题，提高问答任务的因果一致性。模型由 高斯平滑定位（GSG）模块 进行时间片段估计，跨模态对齐（CMA）模块通过双向对比学习增强视觉-语言特征匹配，显式因果干预（ECI）模块 采用前门和后门干预消除视觉和语言模态中的混淆因素。整个框架依托于弱监督学习，仅利用视频问答（VideoQA）数据进行训练，避免额外标注需求，并在 NextGQA 和 STAR 数据集上取得了显著的性能提升。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Method	Acc@GQA	Acc@VQA	TIoP@0.5	TIoU@0.5
CRA	18.2	61.1	28.5	10.6
w/o GSG	16.4 (↓1.8)	60.1 (↓1.0)	26.7 (↓1.8)	8.0 (↓2.6)
w/o CMA	16.2 (↓2.0)	60.0 (↓1.1)	26.3 (↓2.2)	9.3 (↓1.3)
w/o Causal	17.0 (↓1.2)	60.1 (↓1.0)	27.6 (↓0.9)	9.5 (↓1.1)
w/o LCI	17.8 (↓0.4)	60.9 (↓0.2)	28.2 (↓0.3)	10.4 (↓0.2)
w/o ECI	17.3 (↓0.9)	60.5 (↓0.6)	27.3 (↓1.2)	9.6 (↓1.0)

Table 9. Ablation studies of CRA on NextGQA dataset.

证明了 GSG、CMA 和 ECI 模块的有效性，其中 CMA 和 GSG 影响最大，而因果干预中的 视觉干预（ECI）比语言干预（LCI）贡献更大。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Method	Text	Acc@GQA	Acc@QA	TIoP@0.5
NG+	Qwen2.5-1.5B	15.0	65.2	21.5
CRA	Qwen2.5-1.5B	16.5	65.4	23.1

Table 10. Ablation of the LLM on NExT-GQA dataset

说明了更强的 LLM（Qwen2.5-1.5B）可以进一步提升因果一致性，但 CRA 的核心改进不依赖于 LLM。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Method	Vision	Text	Acc@GQA	Acc@QA	TIoP@0.5
IGV	ResNet	BT	10.2	50.1	18.9
CRA	ResNet	BT	13.2	51.5	23.9

Table 11. Comparison with IGV on NExT-GQA dataset

说明了 CRA 在相同主干网络下优于 IGV，证明了其在因果推理方面的优势。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

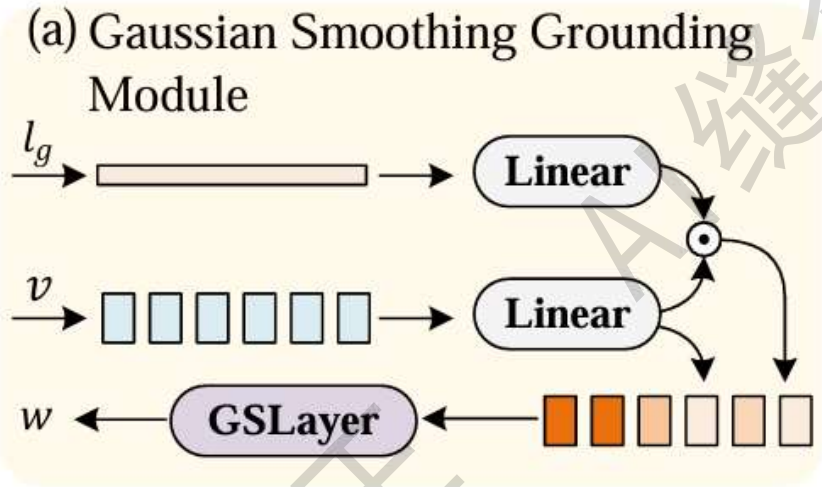

GSG 适用于 时间序列、多模态对齐、视频问答、弱监督时间定位等任务，其主要作用是：平滑时间注意力，减少时间抖动，提高定位稳定性；消除无关时间信息，提高关键片段的准确性；提升弱监督时间任务的效果，使模型更鲁棒；模块化设计，可无缝集成到各种多模态任务中。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

CATANet: Efficient Content-Aware Token Aggregation for Lightweight Image Super-Resolution

Xin Liu Jie Liu✉ Jie Tang Gangshan Wu
State Key Laboratory for Novel Software Technology, Nanjing University, Nanjing 210023, China
xinliu2023@smail.nju.edu.cn {liujie,tangjie,gswu}@nju.edu.cn
https://github.com/EquationWalker/CATANet

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

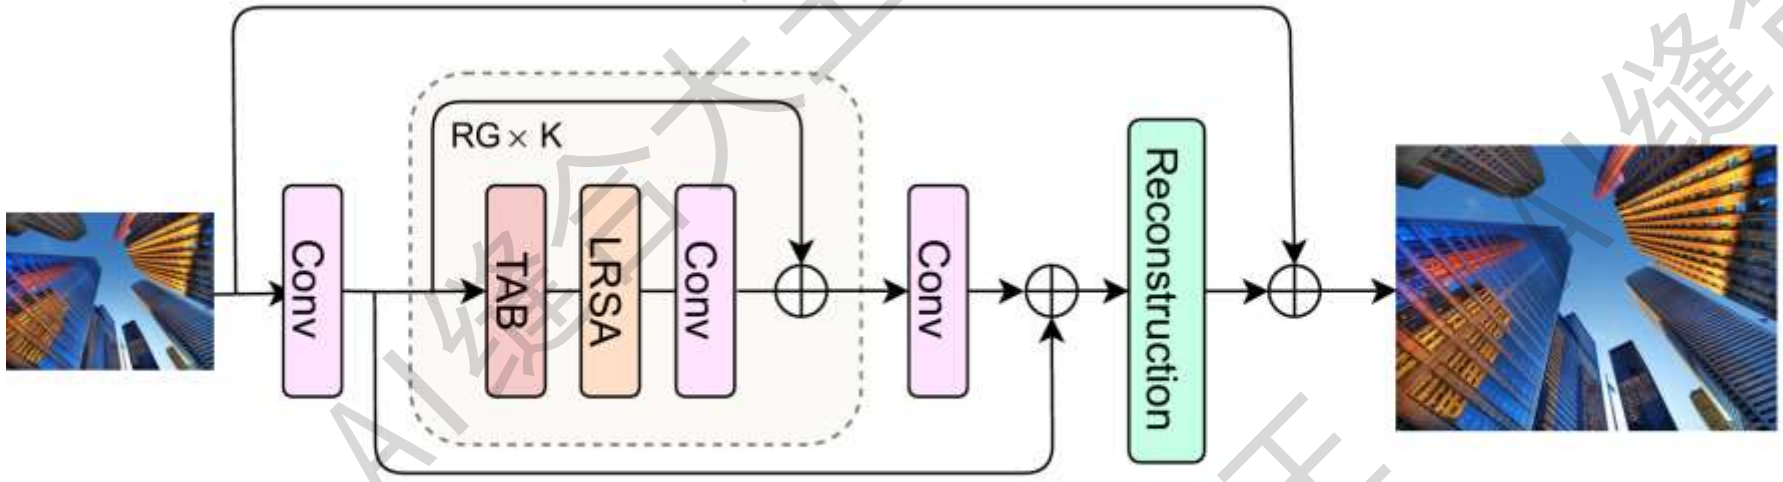

(a) Overall Architecture

CATANet 是一个轻量级图像超分辨率模型，整体结构由浅层特征提取、深层特征提取和图像重建三部分组成。核心在于深层的多个残差组 (RG)，每个 RG 包含一个 Token Aggregation Block (TAB) 用于内容感知的长距离 token 聚合、Intra-Group Self-Attention 和 Inter-Group Cross-Attention 实现细粒度和全局信息交互，辅以 Local-Region Self-Attention (LRSA) 增强局部细节，最终通过重建模块输出高分辨率图像。CATANet 在提升全局建模能力的同时，显著降低了推理复杂度。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 1. Ablation study attending to consecutive subgroups. PSNR are calculated with a scale factor of 4.

Method	Params	Multi-Adds	Urban100	Manga109
Not Attend	536K	46.8G	26.85	31.26
Attend (ours)	536K	46.8G	26.87	31.31

内容：对是否允许子组（subgroup）跨组 attention 的效果进行验证。

说明：结果显示，当允许子组 attend 到相邻子组时，PSNR 在 Urban100 和 Manga109 数据集上有轻微提升（例如 Urban100 提升了 0.02dB），表明跨子组交互能有效增强特征建模。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 3. Ablation Study on IASA and IRCA. PSNR are calculated with a scale factor of 4.

IASA	IRCA	Params	Multi-Adds	Set5	Set14	B100	Urban100	Manga109
✗	✗	366K	37.3G	32.26	28.63	27.68	26.46	30.81
✓	✗	511K	46.8G	32.47	28.75	27.75	26.85	31.24
✓	✓	535K	46.8G	32.58	28.90	27.75	26.87	31.31

内容：验证 IASA 和 IRCA 两个模块对模型性能的贡献。

说明：依次加入 IASA 和 IRCA，模型在 Set5、Set14、B100、Urban100 和 Manga109 上的 PSNR 均有显著提升，说明这两个模块能够有效提升长距离依赖和全局信息的利用能力。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 4. Ablation Study on different designs of TAB. PSNR are calculated with a scale factor of 2.

Method	Set5	Set14	B100	Urban100	Manga109
Clustered Attention [43]	32.25	33.84	32.33	32.96	39.30
TCformer [54]	38.06	33.87	32.32	32.90	39.17
NLSA [37]	37.67	33.29	31.96	31.22	37.78
CATANet (ours)	38.28	33.99	32.37	33.09	39.37

内容：对比 CATANet 的 TAB 与其他 token 聚合机制（如 Clustered Attention、TCFormer、NLSA）。

说明：结果表明 CATANet 的 TAB 在各个数据集上均优于其他方法，验证了 CATA + IASA + IRCA 的联合设计在内容感知聚合和长距离建模方面更具优势。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 5. Ablation Study on fusion approach of IASA and IRCA. PSNR are calculated with a scale factor of 4.

Method	Params	Multi-Adds	Set5	Urban100	Manga109
concat	548K	47.6G	32.49	26.82	31.28
add (ours)	535K	46.8G	32.58	26.87	31.31

内容：探讨 TAB 中 IASA 和 IRCA 的融合方式（相加 vs 拼接）。

说明：结果显示，采用 相加 (add) 的融合策略能在保持更低计算量的前提下，取得更高的 PSNR，表明相加更适合轻量化设计。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

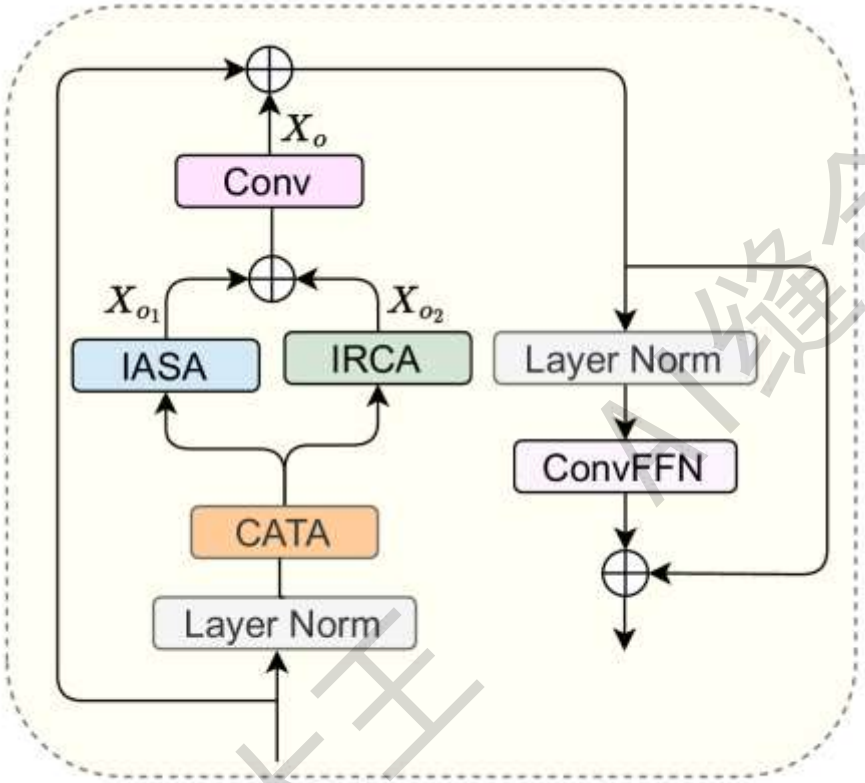

(b) Token Aggregation Block (TAB)

TAB 作为一个即插即用的模块，适用于轻量化图像复原、超分辨率、去噪、去模糊等低层视觉任务，特别适合在局部 attention 框架下补充长距离依赖建模能力，提升跨区域特征感知，广泛应用于移动端和边缘计算等对算力敏感的场景。其通过内容感知的 token 聚合机制（CATA）和 IASA + IRCA 结构，实现了高效的跨空间 token 关联和全局信息交互，显著增强模型的特征表示和图像重建能力，同时保持低计算开销，弥补了传统轻量网络全局建模能力不足的问题。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

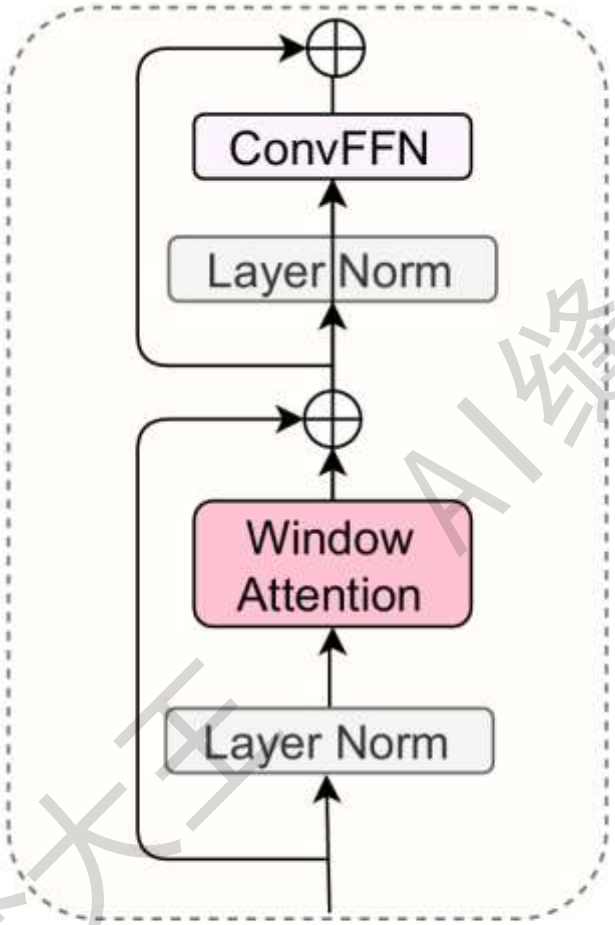

(c) Local Region Self-Attention (LRSA)

IRCA 作为一个即插即用的模块，适用于轻量化图像超分辨率、图像复原、图像去噪等对资源有限制但需全局建模能力的视觉任务，特别适合补充传统局部 attention 框架的长距离依赖建模能力。其主要作用是通过分组 token 与全局 token centers 之间的 cross-attention，增强跨区域特征融合，提升全局信息交互能力和图像细节还原效果，同时相比全局 self-attention 保持更低的计算复杂度，适合嵌入各种轻量化模型，提升整体感知与重建性能。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

HVI: A New Color Space for Low-light Image Enhancement

Qingsen Yan[1*] Yixu Feng[1*] Cheng Zhang[1*]
Guansong Pang[2] Kangbiao Shi[1] Peng Wu[1] Wei Dong[3] Jinqiu Sun[1] Yanning Zhang[1†]
[1]Northwestern Polytechnical University [2]Singapore Management University
[3]Xi'an University of Architecture and Technology

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

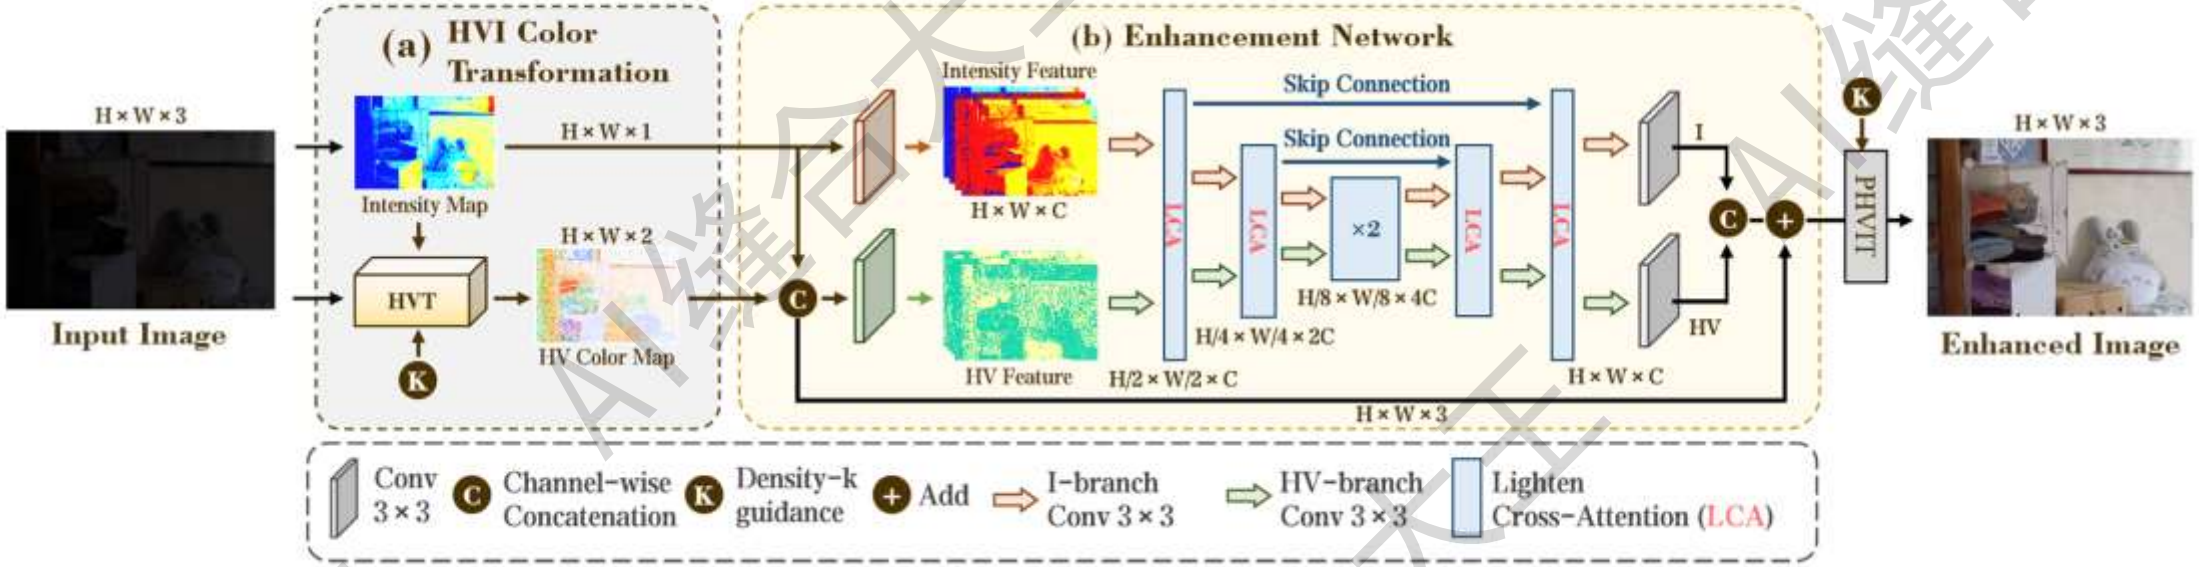

该论文提出了一种新的低光图像增强方法，核心创新点在于 HVI 颜色空间 和 CIDNet 网络。HVI 颜色空间通过 极化 Hue-Saturation (HS) 平面 来减少红色断点噪声，并引入 可学习的强度塌陷函数 以消除黑色噪声。基于 HVI 颜色空间，CIDNet 采用 双分支架构（HV-Branch 处理颜色、I-Branch 处理亮度）并结合 Lighten Cross-Attention (LCA) 机制，实现颜色和亮度的解耦优化。最终，通过 Perceptual-inverse HVI Transformation (PHVIT) 将增强后的图像转换回 sRGB 颜色空间。实验结果表明，该方法在多个数据集上超越 SOTA 方法，同时具备 更高效、更轻量、更具泛化性 的特点。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Table 4. Model ablation. Dual denotes the dual-branch network.

Metrics		PSNR↑	SSIM↑	LPIPS↓
Color Space	sRGB	20.062	0.825	0.137
	HSV	21.349	0.801	0.167
	HVI (w/ Polarization Only)	21.558	0.821	0.149
	HVI (w/ C_k Only)	21.536	0.825	0.179
Structure	UNet Baseline [46]	19.306	0.778	0.222
	SelfAttn [71]	22.313	0.835	0.126
	Dual+SelfAttn [71]	23.159	0.856	0.116
Loss	HVI Only	23.221	0.854	0.132
	sRGB Only	23.319	0.857	0.123
Full Model (HVI-CIDNet)		24.111	0.871	0.108

通过不同颜色空间（sRGB、HSV、HVI 变体）的对比，表明完整 HVI 颜色空间（HS 极化 + 亮度塌陷）能有效减少红色和黑色噪声，提高增强效果。同时，网络架构对比显示，双分支 + Cross-Attention 机制显著提升 PSNR 和 SSIM，增强了亮度和颜色信息的协同优化。损失函数实验则证明，结合 HVI 颜色空间损失和 sRGB 约束的完整模型，在 PSNR、SSIM 和 LPIPS 指标上均达到最佳效果。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

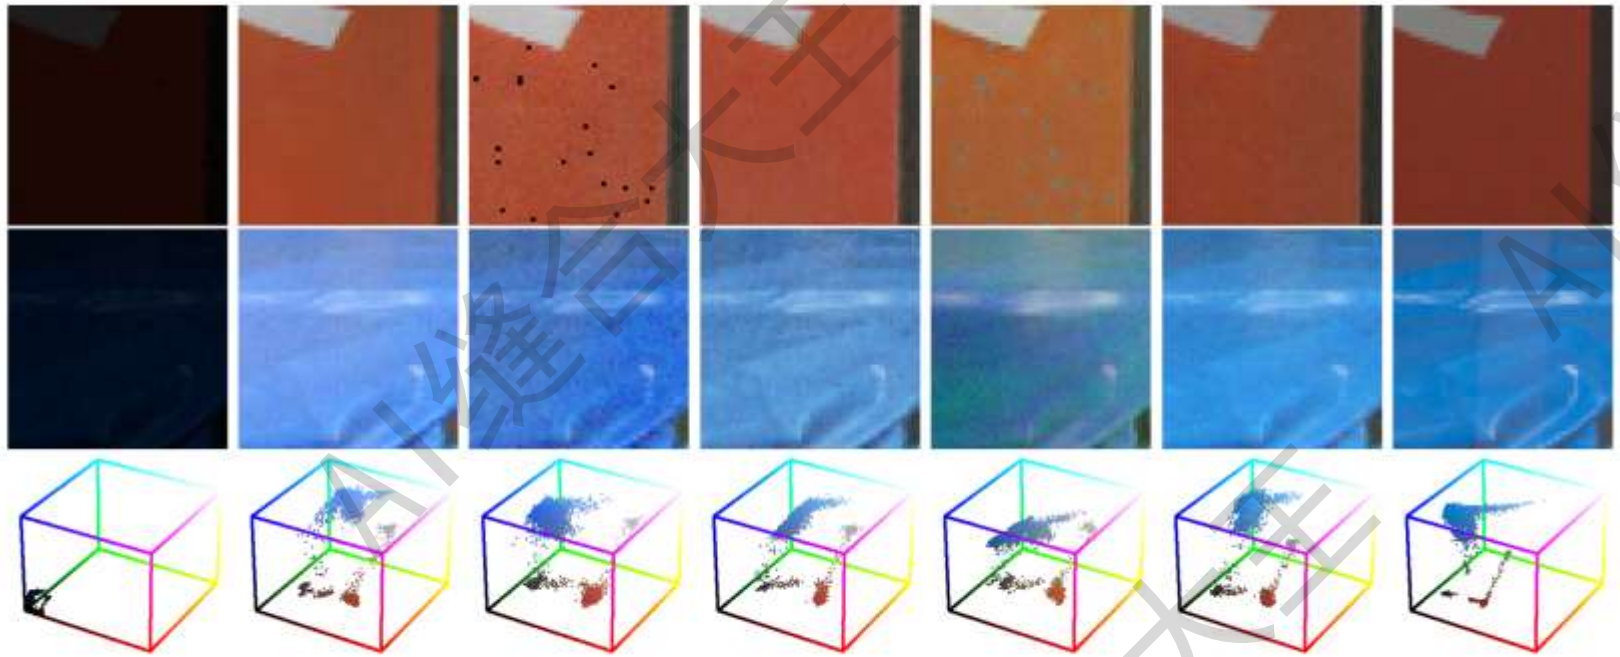

(a) Input (b) sRGB (c) HSV (d) w/ Polarization (e) w/ C_k (f) HVI (g) GroundTruth

展示了不同颜色空间（sRGB、HSV 和 HVI 变体）对低光增强的影响，结果表明 sRGB 亮度不足、HSV 存在红色断点噪声，而完整 HVI 颜色空间能在增强亮度的同时，减少颜色失真和黑色噪声，最终提供最佳的视觉效果。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

SelfAttn　　Dual + Self　　Dual + Cross　　GroundTruth

Figure 6. Results of using different structures on LOLv2-Real.

通过对比 Self-Attention、双分支结构（Dual）以及双分支 + Cross-Attention（完整模型），证明了双分支结构能更稳定地增强亮度，而 Cross-Attention 进一步优化了颜色和亮度，使增强效果最自然、最接近真实场景。

B站、小红书、微信公众号同步更新　　@ai缝合大王

ai缝合交流Q群：994264161

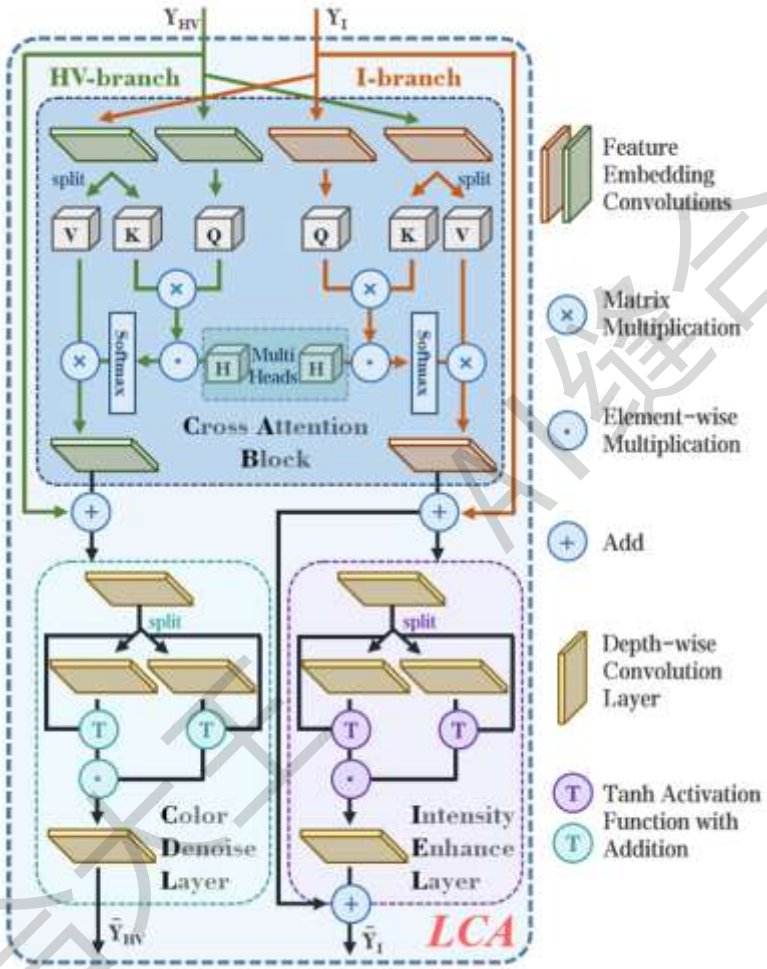

LCA（Lighten Cross-Attention）是一种高效的跨注意力机制，适用于低光图像增强（LLIE）、图像去噪与颜色恢复、HDR 细节增强、图像风格转换 & 对比度增强以及多光谱图像融合（如夜视、红外、遥感等）任务。

作为即插即用模块，LCA 通过亮度信息引导颜色增强，防止低光增强过程中的颜色失真，同时抑制局部颜色漂移与过曝光，保持自然色彩。此外，LCA 还能去除黑色噪声和红色断点噪声，提升图像清晰度，并且增强模型的适应性与泛化能力，能够与不同深度学习架构结合，提升跨数据集的表现。因此，LCA 既是低光图像增强的理想选择，也可作为通用模块应用于其他图像增强、去噪和风格迁移任务。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

Breaking the Low-Rank Dilemma of Linear Attention

Qihang Fan[1,2], Huaibo Huang[1*], Ran He[1,2]
[1]MAIS & CRIPAC, Institute of Automation, Chinese Academy of Sciences, Beijing, China
[2]School of Artificial Intelligence, University of Chinese Academy of Sciences, Beijing, China
fanqihang.159@gmail.com, huaibo.huang@cripac.ia.ac.cn,
rhe@nlpr.ia.ac.cn

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

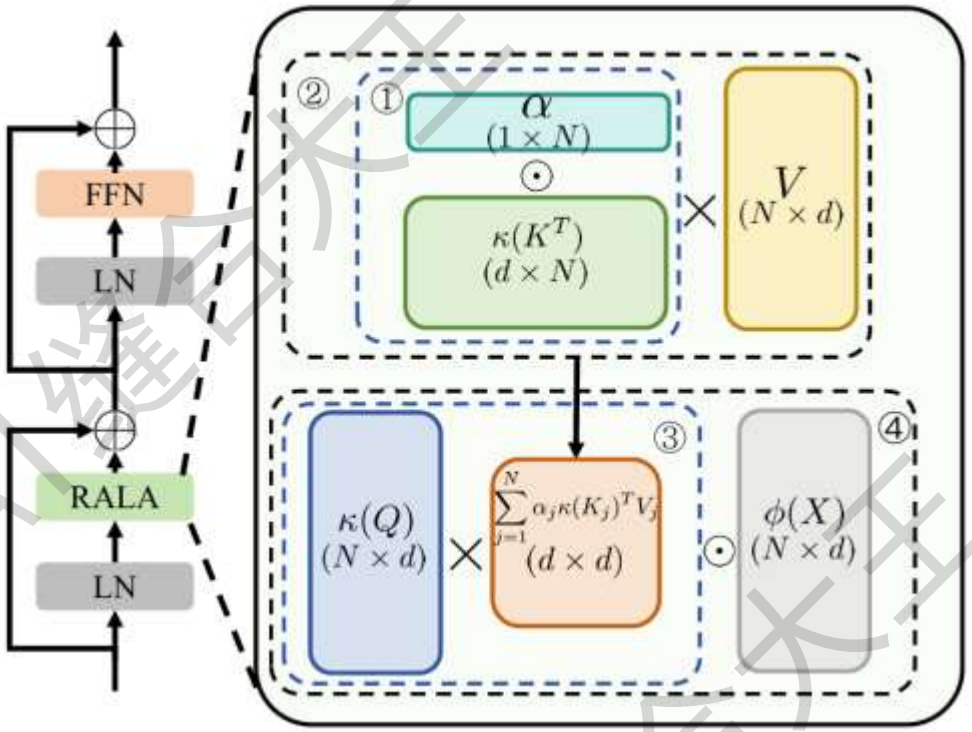

Rank-Augmented Linear Attention (RALA)，通过增强 KV buffer 和 输出特征 的秩，解决了传统 Linear Attention 低秩导致性能下降的问题。在此基础上，构建了 Rank-Augmented Vision Linear Transformer (RAVLT)，提升了视觉任务中的建模能力，同时保持线性计算复杂度。实验表明，RAVLT 在 图像分类、目标检测和语义分割 任务上均超越现有 Linear Attention 方法，并在某些情况下达到 Softmax Attention 级别的性能，兼顾了计算效率与表现。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

	Params	FLOPs	Top1	AP^b	AP^m	mIoU
	15	2.4	82.8	47.3	42.7	47.9
w/o KV aug	15	2.4	82.1(-0.7)	43.7(-3.6)	39.0(-3.7)	43.6(-4.3)
w/o out aug	15	2.4	82.5(-0.3)	46.3(-1.0)	41.6(-1.1)	47.0(-0.9)
w/o CPE	15	2.4	82.7(-0.1)	47.0(-0.3)	42.5(-0.2)	47.6(-0.3)
ϕ: proj→ identity	15	2.4	82.8(-0.0)	47.2(-0.1)	42.5(-0.2)	48.1(+0.2)
ϕ: proj→ tanh	15	2.4	82.7(-0.1)	47.2(-0.1)	42.7(-0.0)	47.7(-0.2)
κ: ELU + 1 → ReLU	15	2.4	82.8(-0.0)	47.3(-0.0)	42.8(+0.1)	47.7(-0.2)
κ: ELU + 1 → Softmax	15	2.4	82.7(-0.1)	47.1(-0.2)	42.7(+0.0)	47.8(-0.1)

Table 9. Ablation on RAVLT-T. The results show that performance improvements stem from our RALA's augmentation of matrix's rank, rather than the selection of specific functions.

作用：分析了不同模块对 RAVLT-T（Tiny 版本）模型性能的影响，涉及 KV buffer 增强、输出特征增强、位置编码 (CPE) 以及不同 ϕ(.) 和 κ(.) 选择的影响。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

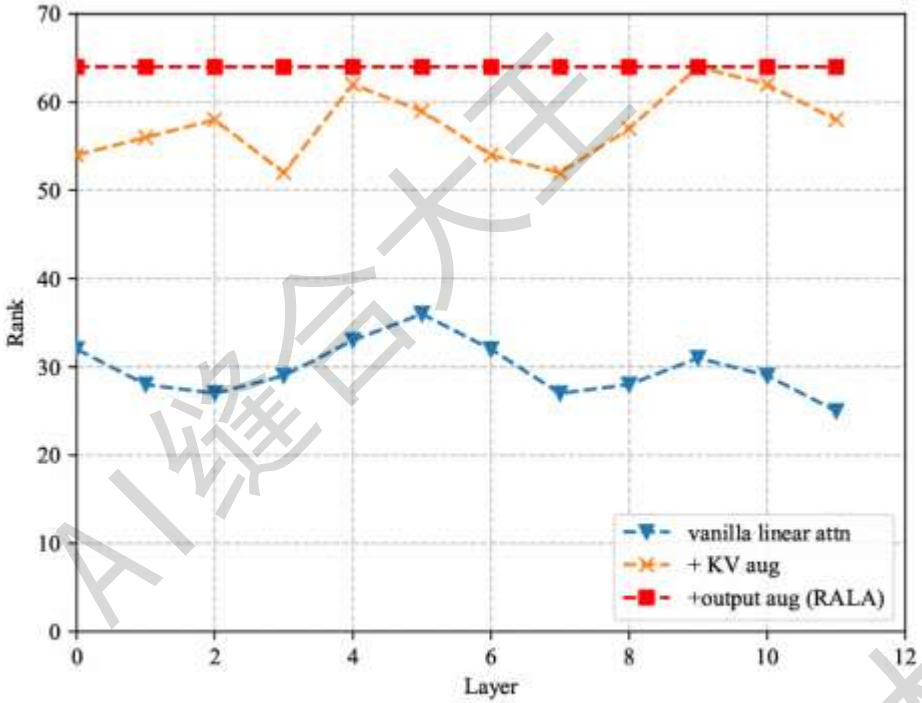

Figure 8. Analysis of the rank across different model layers. RALA's augmentation of the KV buffer and output feature effectively increases the rank of the output features at each layer.

作用：展示了不同 Transformer 层的输出特征秩对比，验证 RALA 在多个层次上的有效性。结论：Vanilla Linear Attention（未增强）的秩较低，且层数增加后仍然无法达到满秩。仅增强 KV buffer 后，秩有一定提高，但仍未达到满秩。KV buffer + 输出特征增强（RALA）明显提高了所有层的秩，使模型能够学习更丰富的特征。

B站、小红书、微信公众号同步更新 @ai缝合大王

ai缝合交流Q群：994264161

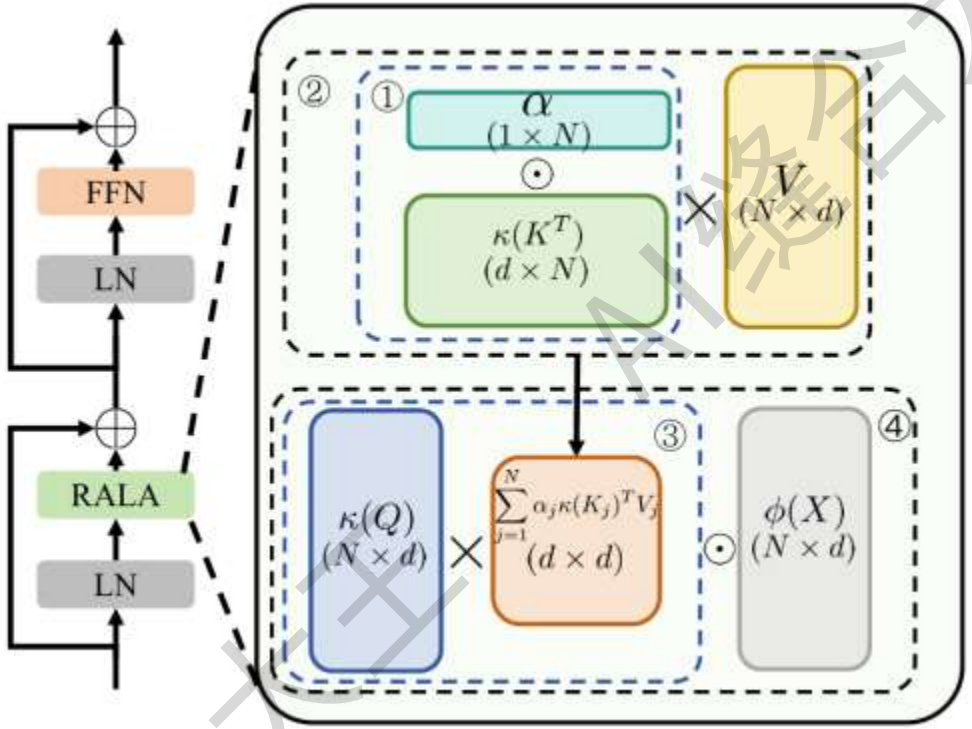

RALA 作为 Rank-Augmented Linear Attention 机制，可作为即插即用模块，适用于 高效视觉任务、长序列建模及计算受限环境。它在 图像分类、目标检测、语义分割、视频理解、多模态任务、NLP 长文本建模、强化学习及机器人视觉 等场景中，能够有效提升 Linear Attention 的特征表达能力，使其接近 Softmax Attention，同时保持 线性计算复杂度 $O(Nd^2)$，降低计算成本，适用于 高分辨率任务、边缘设备及实时推理。RALA 可无缝集成至 ViT、Swin Transformer、DeiT、ConvNeXt、RetinaNet 等模型，增强其空间建模能力，实现 高效与高性能兼顾。

B站、小红书、微信公众号同步更新 @ai缝合大王